



Universidad Politécnica
de Madrid



**Escuela Técnica Superior de
Ingenieros Informáticos**

Grado en Ingeniería Informática

Trabajo de Fin de Grado

**Aplicación de un espacio
reducido a clasificación de
imágenes de Teledetección.
Investigación de la Deforestación
en la zona del Amazonas**

Alumno: Jaime Díez-Hochleitner Suárez

Tutora: María Estíbaliz Martínez

Madrid, junio 2022

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado

Grado en Ingeniería Informática

Título: Aplicación de un espacio reducido a clasificación de imágenes de Teledetección. Investigación de la Deforestación en la zona del Amazonas.
junio 2022

Autor: Jaime Díez-Hochleitner Suárez

Tutora:

María Estíbaliz Martínez

Departamento de Arquitectura y Tecnología de Sistemas Informáticos

ETSI Informáticos

Universidad Politécnica de Madrid

Resumen

En este trabajo se presenta un estudio temporal de una zona deforestada próxima al río Amazonas (Brasil). Para ello, se utilizan imágenes registradas por satélites de media/alta resolución espacial y una buena resolución espectral. Las imágenes utilizadas son de libre distribución adquiridas a través de dos plataformas, la plataforma USGS (EEUU, NASA) para descargar imágenes Landsat 8 y la plataforma Open Access Hub (Europa, ESA) para descargar imágenes Sentinel 2. El estudio se ha basado en una detección de cambios post-clasificación. El algoritmo de clasificación utilizado es un algoritmo supervisado llamado *Random Forest* (bosques aleatorios). Las áreas de entrenamiento se seleccionan en base a un espacio reducido generado a partir del cálculo mediante operaciones algebraicas entre bandas, para obtener un índice espectral. Este índice es el denominado NDVI (Normalized Difference Vegetation Index). La distinción de zonas en este índice mediante fronteras de valores ha permitido seleccionar las áreas de interés que alimentan al algoritmo de clasificación. La evaluación de los resultados se ha llevado a cabo mediante la matriz de error y los resultados obtenidos han sido satisfactorios.

Abstract

In this project it is presented a temporal study of a deforested zone near the Amazon (Brazil). For this study, there will be used registered satellite images of medium/high spatial resolution and an adequate spectral resolution. The used images are of free distribution acquired through 2 platforms, USGS (USA, NASA) to download Landsat 8 images and Open Access Hub (Europe, ESA) to download Sentinel 2 images. The study is based on a detection of post-classification changes. The classification algorithm used is a supervised algorithm called Random Forest. The training areas are chosen based on a reduced space generated from the calculation of algebraic operations between bands, to obtain a spectral index. This index is called NDVI (Normalized Difference Vegetation Index). The zone distinction of this index from value frontiers has allowed to choose areas of interest which feed the classification algorithm. The assessment of the results has been carried out through the matrix error and the obtained results have been satisfactory.

Tabla de contenidos

1. Introducción y objetivos.....	1
2. Estado del arte	2
2.1. Teledetección.....	2
2.2. Satélites	2
2.2.1. Satélites artificiales	2
2.2.2. Sensores y Programas Espaciales.....	4
2.3. El Programa Copernicus.....	6
2.3.1. Servicios de Copernicus	6
2.3.2. Constelación Sentinel.....	10
2.4. El Programa Landsat	10
2.4.1. Misiones Landsat	11
2.5. Algoritmos para clasificación supervisada de imágenes	15
2.5.1. Introducción	15
2.5.2. Algoritmo de bosques aleatorios	16
3. Impacto con Objetivos de Desarrollo Sostenible	24
4. Metodología	25
4.1. Actividad con SeNtinel Application Platform (SNAP).....	25
4.1.1. Cómo descargar imágenes.....	25
4.1.2. Obtener imágenes	25
4.1.3. Funciones básicas de SNAP	27
4.2. Clasificación de imágenes [45].....	33
4.2.1. Obtención de mapa NDVI.....	33
4.2.2. Obtención de áreas de entrenamiento	37
4.2.3. Información de las áreas	39
4.3. Clasificación con Random Forest.....	43
4.4. Validación de los datos obtenidos.....	52
5. Selección de datos	58
5.1. Introducción.....	58
5.2. Categorización de niveles de deforestación	62
5.3. Recortado de imágenes.....	64
5.4. Selección de áreas de entrenamiento	66
5.5. Aplicación del algoritmo de Random Forest	68
6. Estudio de resultados	75
6.1. Porcentajes de clases.....	75
6.2. Estudio individual de las zonas	77

6.2.1.	Zona urbana	77
6.2.2.	Zona de agua	80
6.2.3.	Zona de vegetación de grado 0	81
6.2.4.	Zona de vegetación de grado 1	82
6.2.5.	Zonas de vegetación de grado 2.....	83
6.2.6.	Zonas de vegetación de grado 3.....	84
6.3.	Validación de resultados	87
6.3.1.	Zona urbana	87
6.3.2.	Zona de agua	90
6.3.3.	Grado 0.....	92
6.3.4.	Grado 1.....	94
6.3.5.	Grado 2.....	96
6.3.6.	Grado 3.....	98
6.3.7.	Análisis de resultados	101
7.	Conclusiones	102
8.	Bibliografía	105
9.	Anexo	109

1. Introducción y objetivos

La propuesta se basa en la aplicación de un algoritmo de clasificación de imágenes de Teledetección. Las técnicas de clasificación se utilizan para categorizar los píxeles de las imágenes registradas mediante el proceso de teledetección. El objetivo final es diferenciar las diversas características de las coberturas terrestres en función de su respuesta espectral. Esta técnica es muy utilizada para generar el mapa de usos de suelo. La selección previa del conjunto de datos puede ser un factor crítico para el resultado final. En este sentido, trabajar con un conjunto de datos dimensionalmente reducido puede resultar muy útil para realizar una supervisión. Aun cuando subespacios de menor dimensión, derivados del espacio original, permiten hacer una buena descripción y supervisión de los datos con un menor coste computacional, siempre es necesario realizar un análisis final de la clasificación. El objetivo general de este proyecto es establecer y desarrollar una metodología de clasificación con las premisas indicadas. El objetivo final es el desarrollo de una solución competitiva que ayude a mejorar la productividad en proyectos I+D del ámbito. El proceso metodológico para establecer en este trabajo deberá estar basado en técnicas de procesamiento de las imágenes que de manera tradicional estén contempladas en software comercial y de libre distribución. Se pretende optimizar y/o modificar los procedimientos para sacar el mayor partido posible a las técnicas de análisis que se ofrezcan en el software utilizado.

Lista de objetivos concretos:

- O1. Determinar cuál/es de los algoritmos presentes en la literatura, pueden ser más adecuados para aplicar en el proceso metodológico propuesto.
- O2. Establecer las fuentes de información, de acuerdo con las imágenes disponibles en cuanto a su resolución, que resulten más adecuadas para realizar el proyecto.
- O3. Establecer la metodología para una serie de casos de pruebas.
- O4. Evaluar y analizar resultados.
- O5. Elaborar el informe final.

2. Estado del arte

2.1. Teledetección

Los humanos utilizamos los 5 sentidos para percibir el mundo que nos rodea. Sin embargo, no todos estos sentidos interactúan de manera directa con la información que reciben. A diferencia del gusto y del tacto, tanto la vista, el olfato como el oído, reciben de forma *remota* la información. En eso consiste la teledetección [16], en obtener información a distancia, utilizando sensores. Estos sensores reciben radiación electromagnética como respuesta espectral desde el objetivo de teledetección y, dependiendo del tipo de que se trate, se pueden clasificar en **activos** o **pasivos** (Figuras 1 y 2) [12]. Los sensores pasivos reciben la respuesta espectral producto de la interacción de ondas electromagnéticas de una fuente de energía natural como pudiera ser el Sol, con la corteza terrestre. En el caso de los sensores implicados en teledetección activa, la fuente de irradiación es artificial. Esta fuente de energía artificial proviene del mismo satélite, convirtiéndolo en un receptor y emisor simultáneo.

Passive Sensors




Figura 1: Ejemplo de sensor pasivo
(tomado de <https://jmarcano.com/ciencias-tierra/teledeteccion/principios/>)

Active Sensors




Figura 2: Ejemplo de sensor activo

2.2. Satélites

2.2.1. Satélites artificiales

Los satélites artificiales son dispositivos creados por el hombre que orbitan alrededor de la Tierra para recopilar, procesar y transmitir información muy diversa. Los satélites se pueden clasificar de varias formas: según finalidad y según altura de órbita.

2.2.1.1. Según finalidad

Existen satélites equipados con componentes distintos dependiendo de la labor que estén destinados a hacer (Figuras 3, 4 y 5). Esta finalidad puede ser: científica, militar o de recolección y transmisión de datos.

Los satélites de finalidad **científica** suelen desplegarse para registrar información del espacio exterior, para trasladar seres vivos y monitorizar los efectos del espacio en ellos, para registrar actividad meteorológica o de captura de imágenes con fines cartográficos o medioambientales de la superficie de la Tierra.



Figura 3: Satélite de experimentos biológicos Bion1 (tomado de <https://hmong.es/wiki/Bion-M>)




Figura 4: Satélite meteorológico METEOSAT (tomado de http://concurso.cnice.mec.es/cnice2006/material121/unidad3/sat_mete.htm)



Figura 5: Satélite de observación terrestre Sentinel-1 (tomado de <https://sentinels.copernicus.eu/web/sentinel/missions/sentinel-1/overview>)

Por otro lado, los satélites de finalidad **militar** (Figura 6) se despliegan específicamente para fines militares y/o bélicos. En este ámbito, existen satélites espías o los antisatélite. Los satélites espías se enfocan en interceptar señales enemigas o escanear zonas enemigas para geolocalizar objetivos. Los satélites antisatélite tienen una finalidad principal que es la de destruir objetos espaciales que puedan ser un obstáculo para otros satélites, no obstante, también se pueden usar para destruir otros satélites.



Figura 6: Satélite espía Lacrosse (EEUU) (tomado de <https://www.gtd.es/es/blog/desvelados-los-nombres-en-clave-de-los-satelites-espias-norteamERICANOS>)

Finalmente están los satélites de **distribución y recolección de datos** (Figura 7). Estos satélites se usan principalmente como servicio de GPS, o para propagar señales provenientes de la Tierra para aumentar su alcance.




Figura 7: Satélite GPS Estados Unidos-309 (tomado de <https://en.wikipedia.org/wiki/USA-309>)

2.2.1.2. Según órbita

La distancia a la Tierra de un satélite es relevante si se quieren evaluar diferentes tipos de datos o información (Figura 8). Es decir, para un satélite de localización de GPS, es necesario que esté más cerca para que la geolocalización sea lo más precisa posible. Sin embargo, para satélites de recolección de datos meteorológicos puede ser importante que estén a una distancia más alejada para poder captar más información por barrido. Por tanto, existen:

1. Órbita terrestre baja (LEO): 150-2000 km de distancia. Frecuentemente usada por satélites de observación terrestre.
2. Órbita terrestre media (MEO): 2000-35786 km de distancia. Utilizada por satélites de GPS.
3. Órbita geosíncrona (comúnmente órbita geoestacionaria): 35786 km de distancia. Utilizada por satélites de medición meteorológica.
4. Órbita terrestre alta (HEO): Más de 35786 km de distancia.




Figura 8: Ilustración tipos de órbitas (tomado de <https://slideplayer.es/slide/2269910/> Slide: 6)

2.2.2. Sensores y Programas Espaciales

Como ya se ha visto anteriormente, los satélites de teledetección que registran imágenes de la Tierra a distintas longitudes de onda del espectro electromagnético, utilizan sensores como elementos que captan la información. Estos sensores pueden ser de diferentes tipos, de acuerdo con el registro de la información. Como se ha comentado se dividen en activos y pasivos. Los sensores activos tienen bastantes ventajas con respecto a los sensores pasivos por varios motivos:

- funcionan en cualquier momento del día ya que no requieren de luz solar
- son menos sensibles a las variaciones de la atmósfera y fenómenos meteorológicos

Sin embargo, los sensores pasivos, utilizan la energía solar y la captación de la información se verá restringida a un horario solar.

Los **sensores multiespectrales** [13] permiten captar información en varias zonas del espectro electromagnético, generando datos multiespectrales, que se codifican en imágenes multibanda o multiespectrales (Figura 9). Estas imágenes están disponibles para su uso y se distribuyen libre o comercialmente.




Figura 9. Ilustración del escáner multispectral (tomado de <https://www.e-education.psu.edu/geog480/node/494>)

Los Programas Espaciales presentan misiones de satélites frecuentemente utilizados en el ámbito de la Teledetección aplicada, ya que proporcionan mucha información con una buena resolución espacial, espectral, radiométrica y temporal. Por ejemplo, se pueden mencionar el programa **SPOT** (*Satellite Pour l'Observation de la Terre*), aprobado en Francia en 1978, desarrollado por CNES (Centro Nacional de Estudios Espaciales) francés, junto con Bélgica y Suecia, con un conjunto de satélites civiles de observación terrestre. También es mencionable el Programa **Landsat**, la misión más larga de satélites de la historia, desde 1972, construidos y puestos en órbita por EEUU, o el Programa Copernicus, de la Agencia Espacial Europea (ESA). El programa Copernicus se apoya en una familia de satélites llamados Sentinel. El primer satélite fue lanzado en 2014 (Sentinel-1A). Los Sentinel son una nueva flota de satélites diseñada específicamente para proporcionar los abundantes datos e imágenes de los que se nutre el programa Copernicus, de la Comisión Europea.

Los Sentinel-2 llevan una innovadora cámara multispectral de alta resolución, con 13 bandas espectrales que aportan una nueva perspectiva de la superficie terrestre y la vegetación (Figura 10).

Banda	Longitud de onda (μm)	Resolución (m/px)
Banda 1- Aerosol	0,43 - 0,45	60
Banda 2 -Azul	0,45 - 0,52	10
Banda 3 - Verde	0,54 - 0,57	10
Banda 4 - Rojo	0,65 - 0,68	10
Banda 5 - Rojo	0,69 - 0,71	20
Banda 6 - Ultrarojo	0,73 - 0,74	20
Banda 7 - Rojo lejano	0,77 - 0,79	20
Banda 8 - Infrarojo cercano	0,78 - 0,90	10
Banda 8A - Infrarojo cercano 2	0,85 - 0,87	20
Banda 9 - Vapor de Agua	0,93 - 0,95	60
Banda 10 - Cirrus	1,36 - 1,39	60
Banda 11 - Onda corta infrarroja	1,56 - 1,65	20
Banda 12 - Onda corta infrarroja 2	2,10 - 2,28	20

Figura 10: Especificaciones de las bandas de Sentinel-2 (tomado de <https://www.cursosteledeteccion.com/caracteristicas-de-las-diferentes-misiones-de-sentinel/>)

Sentinel-2 tiene como características [15] alta resolución y buenas capacidades espectrales, así como un campo de visión que abarca 290 kilómetros de anchura, además de un periodo de revisita frecuente. La misión se basa en una constelación de dos satélites idénticos en la misma órbita, separados por 180 grados, para lograr una cobertura y una descarga de datos óptimos. Cada cinco

días los satélites cubren todas las superficies terrestres, grandes islas y aguas costeras.

2.3. El Programa Copernicus

El programa *Copernicus* [1] no se entiende sin la ESA que es la institución desarrolladora del programa de observación terrestre más ambicioso. Se trata de una organización internacional dedicada a la exploración espacial de la cuál forman parte 22 países de la Unión Europea. La principal función es la exploración pacífica y el uso de satélites en beneficio de todos. Entre sus principales programas destaca el programa de observación de la Tierra, bautizado con el nombre de Copernicus que es desarrollado conjuntamente por la Comisión europea y la ESA a través de la Agencia del Medioambiente. El programa Galileo por otro lado, pretende reducir la dependencia de los sistemas de navegación GPS por satélites americanos, otorgando a los ciudadanos servicios de *geolocalización*¹ precisa en todo momento.

Los satélites proporcionan una nueva y útil perspectiva de la Tierra ya que son nuevas tecnologías que nos permiten hacer un seguimiento más precisos de la evolución de temas como: el cambio climático, desarrollo de infraestructuras o ciudades a lo largo del tiempo, crecimiento de cultivos o de la vegetación, incendios forestales, inundaciones, etc. El programa Copernicus, por tanto, está destinado a llevar un seguimiento de evaluación de estos ámbitos mediante fuentes de datos precisas y actualizadas. Este programa genera día a día unos 150,000 GB de datos diariamente. Para hacerse una idea, Instagram genera aproximadamente 2,850 GB al día. Esto significa que este Programa genera aproximadamente, 52 veces más de datos que Instagram al día (suponiendo que se suben una media de 95 millones de posts al día y que cada post ronda los 30 MB). Todos estos datos son gratis y sin restricciones a cualquier persona ya sea un particular, una Empresa o cualquier otro tipo de institución. Son datos de libre uso.

Como se ha comentado anteriormente, Copernicus realiza el seguimiento de diversos factores y evolución de la superficie terrestre. En este aspecto, se pueden encontrar 6 categorías principales que luego se ramificaran en categorías más especializadas respectivamente. Entre las principales categorías se diferencian: vigilancia atmosférica, vigilancia marina, vigilancia terrestre, cambio climático, seguridad y finalmente emergencias. Entre las múltiples aplicaciones de las misiones, existen satélites concretos para misiones concretas.

2.3.1. Servicios de Copernicus

Copernicus tiene 6 misiones principales para ayudar a recolectar datos sobre distintos ámbitos de la superficie de la Tierra. A continuación, se pueden ver cada uno de los *servicios* [2] en mayor profundidad, observando cómo se puede aprovechar cada una de las especializaciones para mejorar o predecir distintos comportamientos de meteorológicos, infraestructuras, etc.

2.3.1.1. Vigilancia atmosférica

El servicio de *vigilancia atmosférica* [3] está relacionado con la recolección de datos sobre la composición atmosférica de manera continua. Este servicio tiene en cuenta registros de datos históricos, así como los actuales para que se puedan realizar de forma independiente modelos predictivos de comportamiento de los fenómenos atmosféricos. Además, a pesar de que estos datos son únicamente de interés científico y predictivo de análisis, los datos recopilados de la atmósfera también pueden ser estudiados y utilizados para otros ámbitos

como: la salud, la eficiencia de las energías renovables, la meteorología, etc. Este servicio se centra pues en 5 áreas:

- Calidad del aire y composición de la atmósfera
- Capa de ozono y radiación ultravioleta
- Emisiones y flujos de superficie
- Radiación solar
- *Forzamiento climático*²

Ejemplos concretos de esas áreas pueden ser la de proporcionar información diaria sobre la composición global de la atmósfera mediante el seguimiento y la previsión de sus componentes: dióxido de carbono y metano, gases reactivos, ozono y aerosoles etc. Además, Copernicus puede hacer un análisis en tiempo real sobre la calidad del aire en Europa, así como previsiones a cuatro días y el reanálisis de los datos.

2.3.1.2. Vigilancia marina

Este servicio está relacionado con la recolección de datos sobre: el estado físico y *biogeoquímico*³, la variabilidad y la dinámica de los ecosistemas oceánicos y marinos referida a todo el océano, haciendo hincapié en los mares situados en Europa[6]. Estos datos al igual que los referidos a la vigilancia atmosférica, son recopilados regular y sistemáticamente. Este servicio es capaz de realizar predicciones sobre la evolución de los puntos mencionados anteriormente.

Este servicio se centra en 4 áreas:

- Seguridad marítima
- Recursos marinos
- Costas y medio marino
- Meteorología, previsiones estacionales y clima

En cuanto a la **seguridad marítima**, en Copernicus se pueden realizar búsquedas de personas o ayudar en operaciones de rescate, sabiendo tanto las corrientes como las condiciones meteorológicas más favorables para poder realizar el rescate de la forma más eficiente y segura. Asimismo, este área puede ayudar a monitorizar y analizar el tráfico marítimo, evaluando las rutas marinas o la densidad de navíos según la fecha.

Para ayudar a sostener y evaluar los **recursos marinos**, Copernicus se puede utilizar para la acuicultura o la pesca (toma de decisiones, sostenibilidad...).

Para dar soporte a las **aplicaciones medioambientales costeras y marinas**, Copernicus da servicio para poder monitorizar el estado del océano/mar. De esta forma se puede controlar e informar cuando la calidad del agua no es la adecuada o cuando el nivel del mar aumenta de una forma predecible. Este aumento da una indicación directa al impacto que tiene la actividad del ser humano en el calentamiento global.

En cuanto a la relación entre el servicio de vigilancia marina y **la meteorología, el clima y las previsiones estacionales**, Copernicus recoge todos los datos posibles sobre estos para poder dar informes sobre la evolución a lo largo del tiempo. Estos datos se usan mayoritariamente para comprobar, de nuevo, el impacto en el cambio climático.

2.3.1.3. Vigilancia terrestre

Copernicus también se especializa en el reconocimiento y evaluación de imágenes geográficas. Este servicio fue implementado de forma conjunta en

2012 por la Agencia Europea de Medio Ambiente y del Centro Común de Investigación de la Comisión Europea(JRC). Copernicus puede evaluar distintos tipos de fenómenos y superficies como: construcción de infraestructuras urbanas o territoriales, gestión forestal y del agua, agricultura y seguridad alimentaria, restauración de la naturaleza, desarrollo rural, evolución del cambio climático, etc.

Este servicio se centra en 4 áreas:

- Seguimiento de los parámetros biofísicos
- Cartografía de la ocupación y uso del suelo
- Cartografía temática de “puntos calientes”
- Imágenes y datos de referencia

En cuanto al **seguimiento de los parámetros biofísicos**, Copernicus, lo que realiza es un estudio de los productos biogeofísicos y de la evolución de la superficie de la Tierra. Esto se refiere a llevar un análisis continuo de la vegetación, presupuesto energético, ciclo del agua, etc. La obtención de estos datos suele estar en un intervalo menor a 2 semanas con una resolución intermedia, no obstante, a lo largo del tiempo se van añadiendo imágenes de mejor calidad.

La **cartografía de la ocupación y el uso del suelo** se centran en la clasificación del suelo. En este aspecto se pueden diferenciar distintos tipos de superficies ya sean bosques, prados, agua, etc.

El **tratamiento de imágenes cartográficas de puntos calientes** se refiere al estudio de zonas donde existe una situación o fenómeno único o de gran interés. Ya sea la evolución de la erupción de un volcán, inundaciones, tornados, etc.

Por último, Copernicus ofrece, en el ámbito de la **vigilancia terrestre**, mosaicos de imágenes por satélite de alta definición.

2.3.1.4. Cambio Climático

Es evidente que el calentamiento global ha ido aumentando más y más a lo largo de los años. Los datos son indiscutibles, la Tierra se está calentando rápidamente. Tan solo en los últimos 10 años, la temperatura global ha aumentado en 0,5°C. A continuación, se muestra la evolución de las temperaturas en Europa y el mundo desde 1850 hasta 2020 (Figura 11).




Figura 11. Gráfico de evolución de las temperaturas de Europa y del mundo (tomado de <https://www.eea.europa.eu/data-and-maps/figures/global-left-and-european-land>)

A la izquierda se puede observar la temperatura del planeta y a la derecha la temperatura media de Europa en el intervalo anual indicado. Se debe tener en cuenta que las emisiones de CO₂ generadas en Europa son evidentemente más altas debido a la alta densidad de población y ciudades que hay en Europa frente al resto del mundo. Por eso, esta estadística, indica que, la temperatura no parece que vaya a dejar de subir de aquí a muchos años. Es por ello por lo que incontables organizaciones se han embarcado en la lucha contra el cambio climático. Copernicus, al ser un programa dentro del ámbito de *Big Data* que gestiona datos de cientos de miles de bytes al día sobre factores que afectan al calentamiento global, se ha convertido en una de las fuentes más apreciadas y eficaces de información disponible con respecto al seguimiento del cambio climático [4]. Además, al ser de libre uso y gratis para todo el mundo, incentiva la investigación particular. El Servicio de Cambio Climático de Copernicus (C3S) se encarga de difundir la información del estado actual, pasado y futuro sobre el clima y medioambiente. Estos datos se encuentran disponibles en su repositorio de datos climáticos.

2.3.1.5. Seguridad

El programa Copernicus procura fomentar la seguridad [8] en diversas situaciones.

Este servicio se centra en 3 áreas:

- Vigilancia de fronteras
- Vigilancia marítima
- Apoyo a la acción exterior de la UE

El objetivo principal de la **vigilancia de fronteras** [7] es el de garantizar la seguridad de los inmigrantes ilegales que intentan cruzar la frontera por mar, aumentar la seguridad en el interior de la Unión Europea y luchar contra la delincuencia transfronteriza. Además, se lleva un registro continuo de la situación en las inmediaciones de las fronteras para garantizar la seguridad, servicio proporcionado con ayuda de Frontex (EUROSUR). Este servicio está operacional desde 2016, uniendo información e informes de las actividades de I+D financiados por los proyectos FP7 de la UE en 2013.

En cuanto a la **vigilancia marítima**, la motivación principal es la de monitorizar y con suerte ayudar a: reducir la contaminación marina, llevar un control de la pesca y garantizar que las leyes marítimas se cumplan con rigurosidad.

Finalmente, el **apoyo a la acción exterior de la UE** [5] se refiere a que Copernicus apoya, junto a la UE a que, países no miembros de la UE (pero con algún tipo de alianza), estén protegidos en caso de que se diera una situación de crisis o hubiera una situación que pudiera provocar la inestabilidad a escala global. Este servicio es lanzado principalmente desde el Centro de Satélites de la Unión Europea (SatCen).

2.3.1.6. Emergencias

Por último, pero no menos importante está el Servicio de Gestión de Emergencias de Copernicus [9] (EMS, *Emergency Management Service*). Está supervisado directamente por la Comisión Europea y DG ECHO (*Directorate-General for European Civil protection and Human aid Operation*). Este servicio se encarga primordialmente de mandar avisos y evaluaciones de riesgo sobre: incendios forestales, inundaciones y otros desastres naturales. El análisis de

estos acontecimientos está activo antes, durante y después de la situación. De esta forma, proporciona información importantísima, ya que la gente que se encargue de llevar a cabo la gestión o acceso a dichas zonas afectadas pueden tener mejores opciones a la hora de realizar su trabajo.

De la misma manera, los datos recogidos pueden servir en un futuro para saber cómo prevenir, reaccionar y actuar ante esos desastres si se llegaran a producir de nuevo. Este servicio se encuentra operacional todo el tiempo y es el único servicio en el mundo que proporciona ayuda por satélite de manera inmediata.

Este servicio se centra en 2 áreas:

- Componente de Alerta Temprana
- Sistema europeo de alerta contra inundaciones/incendios

El **Componente de Alerta Temprana** proporciona información geoespacial para determinar el impacto y saber cómo responder ante los desastres naturales. Este servicio opera de 2 maneras distintas: Mapeo Rápido, para emergencias que requieren respuesta instantánea, y el Mapeo de Riesgo y Recuperación, para situaciones no tan urgentes como el análisis de la prevención y riesgo de desastre o las actividades de recuperación.

El **Sistema europeo de alerta contra inundaciones o incendios** (EFAS y EFFIS respectivamente) son sistemas que proporcionan información sobre el impacto ecológico de estos desastres. El EFAS [10] monitoriza Europa mientras que el EFFIS [11] estudia además el impacto ecológico de los incendios en Oriente Medio y el norte de África. No obstante, ambos sistemas están destinados a estar repartidos por todo el mundo, el EFAS pasaría a llamarse GloFAS y el EFFIS pasaría a llamarse GWIS.

2.3.2. Constelación Sentinel

El programa Copernicus dispone de 7 misiones de satélite, llamado *la Constelación Copernicus*. Esta misión dispone de 14 satélites separados en grupos de 2 para poder cubrir de la forma más eficaz la superficie de la Tierra. Cada par de satélites están separados un ecuador y van haciendo un barrido secuencial de la Tierra, completando el análisis hasta estar completo. Las misiones son: Sentinel 1, Sentinel 2, Sentinel 3, Sentinel 4, Sentinel 5, Sentinel 5P, Sentinel 6.

2.4. El Programa Landsat

El programa Landsat, es un programa conjunto entre el Servicio Geológico de los Estados Unidos (UGS) y la NASA. Originalmente, se creó en 1972 bajo el nombre de *Earth Resources Technology Satellite*, pero más tarde, se renombró como Landsat 1 en 1975. Este programa dispone de 10 satélites: Landsat 1, Landsat 2, Landsat 3, Landsat 4, Landsat 5, Landsat 6, Landsat 7, Landsat 8, Landsat 9, Landsat NeXt. Landsat, junto con el programa Copernicus, ofrece de los catálogos más grandes de imágenes de la Tierra a nivel global, es completamente gratis y de uso público. Dispone de una gran variedad de aplicaciones y, a lo largo del tiempo, ha sido una herramienta vital para todo aquel que necesitara la información recogida por las imágenes por satélite.

Desde agricultores, investigadores del calentamiento global o de la deforestación hasta servicios de emergencia en caso de desastre, Landsat proporciona información de todo tipo al público. Este programa ha recogido, según la NASA, 8 millones de escenas del mundo.

2.4.1. Misiones Landsat

A continuación, se verá una breve descripción de las misiones de Landsat junto con sus características principales:

Landsat 1 (Figura 12) : Fue el primero de los satélites, lanzado en la fecha de creación de la organización, el 23 de julio de 1972. Este fue el primer satélite de la historia cuya misión era exclusivamente la de observar y recopilar información de la Tierra, fue una revolución en su tiempo. Su previsión inicial fue que duraría 1 año, no obstante, acabó durando 5 años más hasta que se retiró. Un dato notable, que afectaría al resto de satélites de, no solo el programa Landsat, sino del resto de programas espaciales de observación, es que al Landsat 1 [34] se le aprovisionó de 2 sensores: el principal *Return Beam Vidicon* (RBV) y como secundario llevaba el *Multi-Spectral Scanner*. Al finalizar la misión los investigadores se dieron cuenta de que los resultados devueltos por el RBV eran mucho menos valiosos que los datos devueltos por el MSS. De ahí que, incluso a día de hoy, el MSS [14], sea uno de los sensores más utilizados en satélites modernos.



Figura 12. Esquema de Landsat 1 (tomado de <https://landsat.gsfc.nasa.gov/satellites/landsat-1/>)

Landsat 2 (Figura 13) : Como el Landsat 1, no consiguió captar imágenes de toda la Tierra (captó alrededor de un 75% de la superficie), se decidió lanzar un satélite auxiliar el 22 de julio de 1975 llamado ERTS-B, sin embargo, más tarde se renombró como Landsat 2 [35]. Al igual que el Landsat 1, superó el año de previsión de uso y acabó siendo utilizado durante 7 años. Además, el Landsat 2 fue el primer satélite del programa Landsat cuya información se empezó a divulgar fuera de la propia investigación del Landsat. Después de 1972, la Unión Soviética fue forzada a comprarle trigo a los Estados Unidos y, como consecuencia se formó el Experimento de Inventario de Gran Área de Cultivos o

LACIE. LACIE, junto con la NASA y la Administración Nacional Oceánica y Atmosférica (NOAA), se empezaron a analizar las imágenes proporcionadas por el programa Landsat. Poco a poco, los satélites de los programas del mundo irían proporcionando más y más información hasta que se convirtieran en datos de libre acceso para todos. Este satélite usaba al igual que el Landsat 1, sensores RBV y MSS.



Figura 13. Esquema de Landsat 2 (tomado de <https://landsat.gsfc.nasa.gov/satellites/landsat-2/>)

Landsat 3 (Figura 14) : Inicialmente, el programa Landsat estaba destinado a lanzar solo 2 satélites, pero, viendo la gran utilidad que ofrecieron los dos primeros, decidieron seguir expandiendo el programa. Landsat 3 [36] fue una evolución de los dos satélites que le precedieron, incluyendo mejoras sustanciales en sus sensores. En el RBV se duplicó la resolución de las imágenes pasando de 80 metros a 40 metros. El MSS por otro lado incluyó una banda térmica infrarroja. Su misión principal era la de seguir recopilando información de la Tierra para continuar con la labor de los 2 satélites anteriores.




Figura 14. Imagen de Landsat 3 (tomado de <https://landsat.gsfc.nasa.gov/satellites/landsat-3/>)

Landsat 4 (Figura 15) : Su lanzamiento fue el 16 de julio de 1982. Su lanzamiento y construcción fueron supervisadas por la NASA. El NOAA supervisó la misión al principio, pero, más tarde, tomó el relevo la Compañía de Satélites de Observación de la Tierra (EOSAT). Este satélite se lanzó a una órbita

mucho menor que la de sus satélites predecesores, no obstante, su campo de visión era mayor, lo que hizo que no afectara a su capacidad de captar imágenes [37]. Estaba equipado con un sensor MSS y con un instrumento de Mapeo Térmico (MP) y, a diferencia de los otros, no contenía un RBV.



Figura 15. Modelo de Landsat 4 (tomado de <https://landsat.gsfc.nasa.gov/satellites/landsat-4/>)

Landsat 5 (Figura 16) : Su lanzamiento fue el 1 de marzo de 1984[38]. Su misión iba a durar tan solo 3 años, pero, como el resto, superó las expectativas con creces, no solo superando su tiempo de uso, sino estableciendo un récord Mundial estando casi 29 años en funcionamiento. Estaba equipado, al igual que el Landsat 4, con un MSS y un TM.




Figura 16. Modelo de Landsat 5 (tomado de <https://landsat.gsfc.nasa.gov/satellites/landsat-5/>)

Landsat 6: Su lanzamiento fue el 5 de octubre de 1993, no obstante, no llegó a la órbita, fue fallido. Estaba equipado con equipamiento mejorado con respecto al Landsat 4 y 5 [39] e incluía una banda pancromática de 15 metros.

Landsat 7 (Figuras 17 y 18): Su lanzamiento fue el 15 de abril de 1999. Estaba equipado con una versión mejorada de lo que iba diseñado y fabricado en el Landsat 6 [40], un sensor denominado *Enhanced Thematic Mapper Plus* (ETM+) así como la banda pancromática de 15 metros y algunas mejoras más. Este satélite fue uno de los primeros satélites del programa Landsat fue el primero en verdaderamente distribuir de manera gratuita sus imágenes al público ya que, en 2008, la USGS hizo que todas las imágenes del Landsat 7 fueran

gratuitas y para todo el mundo. Poco después, todas las imágenes del programa Landsat se entregaban gratuitas.



Figura 17. Imagen de Landsat 7 (tomado de <https://landsat.gsfc.nasa.gov/satellites/land-sat-7/>)



Figura 18. Imagen de Landsat 7 (tomado de <https://eosps.gsfc.nasa.gov/missions/landsat-7> [17])

Landsat 8 (Figura 19a) : fue lanzado el 11 de febrero de 2013. Tiene dos sensores OLI (Operational Land Imager) y TIRS (Thermal Infrared Sensor) [41]. Estos dos sensores brindan cobertura estacional de la masa terrestre global con una resolución espacial de 30 metros (visible, NIR, SWIR); 100 metros (térmico); y 15 metros (pancromática) (Figura 19b).



Figura 19a. Imagen de Landsat (tomado de <https://landsat.gsfc.nasa.gov/satellites/landsat-8/>)

	Bands	Wavelength (micrometers)	Resolution (meters)
Landsat 8 Operational Land Imager (OLI) and Thermal Infrared Sensor (TIRS) Launched February 11, 2013	Band 1 - Coastal aerosol	0.43 - 0.45	30
	Band 2 - Blue	0.45 - 0.51	30
	Band 3 - Green	0.53 - 0.59	30
	Band 4 - Red	0.64 - 0.67	30
	Band 5 - Near Infrared (NIR)	0.85 - 0.88	30
	Band 6 - SWIR 1	1.57 - 1.65	30
	Band 7 - SWIR 2	2.11 - 2.29	30
	Band 8 - Panchromatic	0.50 - 0.68	15
	Band 9 - Cirrus	1.36 - 1.38	30
	Band 10 - Thermal Infrared (TIRS) 1	10.60 - 11.19	100
	Band 11 - Thermal Infrared (TIRS) 2	11.50 - 12.51	100

Figura 19b. Características de las bandas de Landsat 8 (tomado de <https://www.usgs.gov/media/images/landsat-8-band-designations>)

Landsat 9 (Figura 20) : Su lanzamiento fue el 27 de septiembre de 2021. Mejorando el equipamiento anterior, llevaba un sensor OLI-2 y un TIRS-2. El OLI-2 proporciona datos para 9 bandas espectrales (B1-B9) con una resolución de 30 metros salvo para la banda pancromática, que tiene 15 metros. La mejora con respecto al TIRS se diferencia en la calidad que presenta TIRS-2, con sus dos bandas espectrales, la Banda 10 y la Banda 11 con una resolución de unos 100 metros (Figura 21). Landsat 9 [42] recopila unas 750 escenas al día y se procesan en la *Landsat Collection 2* en el *Worldwide Reference-2* (WIRS-2).



Figura 20. Imagen de Landsat 9 (tomado de <https://landsat.gsfc.nasa.gov/wp-content/uploads/2019/09/L9-factsheet-web.pdf>)

- Band 1 Visible (0.43 - 0.45 μm) 30-m
- Band 2 Visible (0.450 - 0.51 μm) 30-m
- Band 3 Visible (0.53 - 0.59 μm) 30-m
- Band 4 Red (0.64 - 0.67 μm) 30-m
- Band 5 Near-Infrared (0.85 - 0.88 μm) 30-m
- Band 6 SWIR 1 (1.57 - 1.65 μm) 30-m
- Band 7 SWIR 2 (2.11 - 2.29 μm) 30-m
- Band 8 Panchromatic (PAN) (0.50 - 0.68 μm) 15-m
- Band 9 Cirrus (1.36 - 1.38 μm) 30-m

Figura 21. Características de las bandas de Landsat 9 (tomado de <https://www.usgs.gov/landsat-missions/landsat-9>)

2.5. Algoritmos para clasificación supervisada de imágenes

2.5.1. Introducción

Los algoritmos de inteligencia artificial modernos permiten generar programas que no requieren de interacción continua del programador para que otorguen resultados esperados, de esta manera, según un histórico de datos, pueden predecir los resultados que deberían dar mediante algoritmos predictivos. Este es el funcionamiento de *Machine Learning* [20]: utilizar la inteligencia artificial para generar software que determine de manera precisa resultados sin que el programador interfiera de manera directa. El tipo de algoritmo dependerá del cómo el algoritmo aprende para generar los resultados.

En este sentido, existen 4 tipos de aprendizaje [18]: aprendizaje supervisado, aprendizaje no supervisado, aprendizaje semi-supervisado y aprendizaje de refuerzo.

El aprendizaje supervisado se caracteriza porque el programador “entrena” al algoritmo dándole como datos de entrada, etiquetas del algoritmo junto con la respuesta correcta. Esto le permite al algoritmo realizar un modelo predictivo basado en la entrada y la salida para categorizar los datos nuevos que le entren y ver si existe una correlación entre esos datos de entrada y la salida del histórico.

Estos algoritmos suelen utilizarse para distintas finalidades, como pueden ser:

Clasificación: que puede dividir los conjuntos de salida de datos en dos o más clases. Los algoritmos de clasificación suelen usarse para la identificación de dígitos, diagnóstico en Medicina (detectar en imágenes), clasificadores de correo electrónico de *spam* y, en el caso de esta investigación, clasificación de coberturas terrestres en imágenes de satélite.

Modelos de regresión: para predecir valores continuos. Se establece un análisis estadístico para proporcionar una tendencia de un conjunto de datos. Algunos de los usos para los modelos de regresión podrían ser: la predicción de precio de la vivienda, el tiempo de permanencia de un empleado en una empresa, estimación de ventas de productos, etc.

Ensamblado: utiliza las predicciones de varios modelos de *Machine Learning*.

En este caso, se utilizarán los **algoritmos supervisados de clasificación** [19] para realizar las categorizaciones de las coberturas en imágenes. Se pueden

diferenciar varios tipos de algoritmos distintos: regresión logística, máquinas de vectores de soporte, redes neuronales y de aprendizaje profundo y árboles de decisión.

Para la clasificación de imágenes en esta investigación, se utilizará el **algoritmo de bosques aleatorios** (*Random Forest*) que es una subcategoría de los algoritmos supervisados de clasificación de árboles de decisión, utilizando software libre (SNAP, Sentinel Application Platform).

2.5.2. Algoritmo de bosques aleatorios

Los algoritmos de árboles de decisión tienen una estructura formada por ramas y nodos. Estas ramas y nodos representan sentencias *if-else* y se usan en gran cantidad de proyectos de *Machine Learning* ya que están considerados como uno de los algoritmos más precisos y eficientes actualmente. El algoritmo de *bosques aleatorios* [21] [25] es una variación de los algoritmos de árboles de decisión, siendo la diferencia que, en lugar de un solo árbol, se dispone de muchos anidados como un bosque.

2.5.2.1. Historia

Inicialmente, se desarrolló el algoritmo de “bosques de elección aleatoria” en 1995 por Tin Kam Ho un científico informático de *IBM Watson Health* que trabajo en los campos de *Machine Learning*, *Data Mining* y *Data Classification*.

El algoritmo de bosques aleatorios fue desarrollado por Leo Breiman, un prestigioso científico estadístico de la Universidad de California, Berkeley, cuyo trabajo ayudó a unir los conocimientos de Estadística con el mundo del software, y por Adele Cutler otra científica de Estadística de la Universidad Estatal de Utah.

2.5.2.2. Utilización

Los algoritmos de árboles de decisión son ampliamente utilizados para realizar predicciones en el ámbito del marketing, la venta de productos a clientes (para poder determinar los perfiles de los clientes más adecuados o para ofrecer ciertas ofertas) o predecir el consumo de un determinado perfil a lo largo del tiempo. No obstante, este algoritmo también se puede utilizar para categorizar distintos tipos de superficies según datos de entrada.

En la herramienta SNAP, se seleccionan diversas áreas de entrenamiento en un mapa determinado y se dan las etiquetas, por lo que el resultado hará referencia a esas etiquetas. En ese sentido, si se generan varios polígonos como áreas de interés o entrenamiento, que representan coberturas terrestres, el algoritmo de bosques aleatorios, cuando se le enfrente a la información correspondiente en una imagen digital, a una superficie entrenada o conocida, deberá clasificarla o discriminarla adecuadamente. Podría darse el caso de que, al intentar clasificar una superficie dada, la clasifique erróneamente confundiéndola con otra superficie de características espectrales parecidas. Esto se debe a que este algoritmo aprende según el número de muestras que se introduzcan etiquetadas para que aprenda. En principio, se puede pensar que cuantas más muestras iniciales, mejores serán los resultados de clasificación, ya que tendrá una base de conocimiento mayor y le será más fácil distinguir conjuntos. Sin embargo, pasado un umbral sobre el número de muestras de aprendizaje, el algoritmo puede perder su efectividad [43].

2.5.2.3. Ventajas y desventajas

Las ventajas que ofrecen los algoritmos de bosque aleatorio son muchas. Se enumeran algunas a continuación:

- Es capaz de usar gran cantidad de variables de entrada e identificar las más significativas
- Apenas hay suposiciones, por lo tanto, apenas hay que preparar los datos
- Tiene una precisión elevada de aciertos de resultados
- Se ejecuta eficientemente aún con gran cantidad de datos
- Identifica cuáles son las variables más relevantes para la clasificación
- Puede aprender cualquier correspondencia entre datos de entrada y resultado a predecir
- Se puede usar como un aprendizaje no supervisado (en algunos casos)
- Una de las salidas del modelo puede ser la importancia de las variables

No obstante, también tiene desventajas donde otros algoritmos puede que no las tuvieran:

- Es bueno para la clasificación, pero no sirve adecuadamente para la regresión
- No hay mucho control sobre lo que hace el modelo durante la ejecución
- La interpretación respecto a otros modelos como un árbol de decisión puede llegar a ser más confusa

2.5.2.4. Funcionamiento del algoritmo

Bagging

Es una técnica usada para reducir la varianza de las predicciones a través de la combinación de los resultados de varios clasificadores, cada uno de ellos modelados con diferentes subconjuntos tomados de la misma población.

El algoritmo de bosques aleatorios es un algoritmo que usa *bagging* [22]. Los métodos que lo utilizan son métodos donde, los algoritmos sencillos que se emplean se ejecutan paralelamente (Figura 22). La idea principal es que se minimicen los errores en cada una de las partes. De esta forma, se puede comparar la salida de las N partes trabajando en paralelo para poder aprender de sí mismo y evaluar un promedio de los valores y tener el criterio necesario para eliminar salidas erróneas. Por tanto, al utilizar esta técnica, varios árboles ven distintas porciones de los datos. Así, cada árbol entrena con muestras distintas para clasificar la misma superficie y por ello, al combinar sus resultados, los errores de unos podrían ser compensados por los errores de los demás y la predicción finalmente puede resultar más precisa.

Lo que permite el *bagging* es obtener la media de modelos donde en los datos que pudieran tener mucho “ruido”, puede reducirse.




Figura 22: Funcionamiento bagging (tomado de <https://machinelearningparatodos.com>)

En la siguiente figura, se muestra representado el cómo, para obtener el resultado se tienen en cuenta todos los resultados de los árboles paralelos para hacer la media y obtener el resultado más frecuente (Figura 23).




Figura 23: Funcionamiento elección de resultados (tomado de <https://www.iartificial.net/ensembles-voting-bagging-boosting-stacking/> [27])

Una vez introducido el concepto de *bagging* y del tipo de sistema de clasificación, a continuación, se introducen algunas cuestiones del algoritmo de bosque aleatorio.

Los pasos [28] a seguir para construir un bosque aleatorio, se resumen a continuación. En primer lugar, hay que construir los árboles. Para ello se debe escoger una muestra del conjunto de muestras de entrenamiento N para formar cada árbol, teniendo en cuenta que estas muestras se eligen con reemplazamiento. Si hay M variables de entrada, se especifican una cantidad de variables de entrada determinada m , para tomar la decisión sobre un nodo dado. Se debe tener en cuenta que, para que sea eficiente esta selección, m , deberá ser mucho menor que M y deberá mantenerse constante a lo largo de la generación de los árboles. Cada árbol debe crecer lo máximo posible y no deben cortarse ramas de los árboles en ningún caso. También hay que tener en cuenta que las siguientes instancias se elegirán mediante la media del conjunto de predicciones del resto de los árboles. Para cada predicción sobre un nuevo caso, se inserta una nueva rama del árbol y se asigna la etiqueta del nodo terminal.

Este proceso se repetirá por todos los árboles y una vez se detecte la etiqueta con el mayor número de ocurrencias, se designará dicha etiqueta como la predicción.

Bootstrap y Out of Bag

El *bootstrap* es el proceso de muestreo de los datos con reemplazo. El conjunto de datos totales se divide en tercios. Se utilizan dos tercios de los datos como datos de entrenamiento del algoritmo en la fase de aprendizaje y un tercio de los datos se podrán utilizar como *tests*. La distribución de los datos de muestreo entre los *bootstrap* no es crítica, aunque debe respetarse la estrategia de los tercios. Sin embargo, los dos tercios correspondientes al resto de los datos de muestreo deberán mantenerse durante todo el proceso (Figura 24). Al conjunto de estos datos se llama *Out-of-Bag* (OOB) [23] (Figura 25).



Figura 24. Conjunto OOB (tomado de <https://bookdown.org/content/2031/ensambladores-random-forest-parte-i.html>)

Los conjuntos OOB pueden tener errores a los que se denominará *Out-of-Bag-Error* (OOB error). Usar los conjuntos de prueba OOB es tan preciso como si se utilizaran conjuntos test de la misma dimensión que el conjunto de datos de entrenamiento.




Figura 25. Conjuntos OOB (tomado de (tomado de <https://bookdown.org/content/2031/ensambladores-random-forest-parte-i.html>)).

Los parámetros de entrada que caracterizan al bosque se denominan **hiperparámetros** y el más importante es el número de variables candidatas para generar cada ramificación. También hay que tener en cuenta:

- *ntree*: número de árboles en el bosque
- *mtry*: número de variables aleatorias candidatas por ramificación.
- *sampsiz*: el número de muestras de entrenamiento. Su valor suele estar dentro del rango entre 60-80%.
- *nodesize*: mínimo número de muestras en los nodos terminales.

- *maxnodes*: máximo número de nodos terminales.

Los valores de estos hiperparámetros permitirán optimizar el tiempo y eficiencia del algoritmo. Estos se establecen antes del proceso de prueba, por lo que, en muchos casos, es necesario que el usuario establezca en su metodología, etapas de prueba y error para encontrar la mejor combinación de valores para dichos parámetros.

El número de muestras de entrenamiento puede modificarse, pero siempre teniendo en cuenta, el caso de *overfitting* (*sobreentrenamiento*) [29], situación no adecuada en el caso de un algoritmo *Machine Learning*. Cuando el algoritmo de aprendizaje automático se entrena con muchos datos, se dice que está sobreajustado. En este caso, podría aprender del ruido y de las entradas de datos inexactas del conjunto de datos. Entonces, el clasificador no categorizará los datos correctamente. Una medida preventiva de esta situación puede ser el aplicar la estrategia de la “Validación Cruzada”.

La idea fundamental es utilizar los datos de entrenamiento inicial para generar múltiples divisiones de prueba. Esta técnica se basa en el método *K-Fold CV*. Como en el caso del bootstrapping, se divide la muestra total de datos en K separaciones (pliegues/*folds*). Si se dispone de 5 pliegues, se evalúan los K-1 pliegues en el pliegue K y se va iterando por cada K pliegue. De la siguiente forma (Figura 26):




Figura 26: Funcionamiento validación cruzada (tomado de <https://towardsdatascience.com/hyperparameter-tuning-the-random-forest-in-python-using-scikit-learn-28d2aa77dd74> [24])

Una vez se han evaluado los K pliegues, se comparan y se obtiene el mejor de ellos. Este conjunto será el que se evalúe en el conjunto de test.

2.5.2.5. API Random forest SNAP

La herramienta de SNAP proporciona una biblioteca que utiliza métodos de Machine Learning para realizar clasificaciones entre otras cosas. Esta biblioteca es la SNAP Machine Learning (SNAP ML) y en mayor medida proporciona modelos de entrenamiento lineales y basados en árboles de decisión. Como el Machine Learning se trata de un tipo de software en alza, esta biblioteca sigue actualizándose con nuevos modelos.

Actualmente dispone de:

- Regresión lineal
- Máquina de vectores de apoyo
- Regresión Logística

- Bosques aleatorios
- Árboles de decisión

En el caso de los bosques aleatorios, se pueden diferenciar dos clases: el *RandomForestClassifier* y el *RandomForestRegressor*. La gran capacidad de CPU e hilos concurrentes de la herramienta permite una ejecución rápida que puede ser acelerada incluso más mediante la división basada en histogramas.

Como ya se ha visto antes, el bosque aleatorio sirve para la clasificación de superficies para la cual necesita varios parámetros:

- ***n_estimators***: es un entero que define el número de árboles del bosque.
- ***criterion***: es un *string* que definirá la calidad del *split*. Por defecto es “gini” (***índice Gini***).
- ***max_depth***: es un entero que define la profundidad máxima del árbol. Si no se introduce ningún valor, la profundidad llegará hasta que se obtengan las últimas hojas de cada árbol.
- ***max_features***: es un entero o float o *string* o *None*. Para hacer que los árboles del bosque sean lo más distintos entre sí que se pueda, lo mejor es entrenarlos con muestra aleatorias de datos y hacer que sus atributos sean distintos. Este parámetro puede tomar los siguientes valores: *int*, *float*, *auto*, *sqrt*, *log2*, *None*. Para cada uno de esos valores el número total de atributos variará como una transformación de ***n_features***.
- ***min_samples_leaf***: es un entero o float. Define el mínimo número de muestras que debe haber en un nodo final (hoja). Un punto de división se considerará (a cualquier profundidad) si existen ***min_samples_leaf*** en cada rama de los extremos.
- ***bootstrap***: es un booleano que dependerá de si se usará *bootstrap* en la creación de árboles.
- ***use_gpu***: es un booleano que dependerá de si se usará la aceleración de la GPU.
- ***verbose***: será un booleano que dependerá de si se imprimirá información de depuración durante la ejecución.
- ***n_jobs***: será un entero o *None* que definirá la cantidad de procesos que trabajarán en paralelo.
- ***random_state***: es un entero o *None* que definirá el estado aleatorio de la semilla. Variará dependiendo de si es un entero o *None*.
- ***use_histogram***: es un booleano que dependerá de si se hacen divisiones convencionales o basadas en histogramas.
- ***hist_nbins***: es un entero que define la cantidad de papeleras para los histogramas.

Esta API tendrá tres funciones:

fit: está función ajustará el modelo según los datos de entrenamiento.

Parámetros:

X_train: serán los datos de entrenamiento.

Y_train: será el vector objetivo correspondiente al X_train.

sample_weigh: Será el peso de las muestras.

get_params: devolverá los valores de los parámetros de los modelos.

predict: devolverá la estimación de las clases.

Parámetros:

X: será el conjunto de datos usados para las predicciones de las clases.

num_threads: es un entero que definirá el número de hilos usados.

Retorno:

proba: será la clase resultante de la predicción.

2.5.2.6. Índice Gini

Uno de los factores más importantes a la hora de generar el bosque aleatorio (Figuras 27 y 28), es el criterio de saber cuándo se ramifica el árbol. Elegir concretamente cuándo hacer la ramificación afecta en gran medida a la eficiencia del árbol. Estos criterios varían según el tipo de algoritmo (regresión o clasificación). Nosotros elegimos el *Índice Gini* para determinar las ramificaciones.




Figura 27: funcionamiento Índice Gini

(http://games.cmm.uchile.cl/media/uploads/posts/RF_presentation.pdf)

Esencialmente se basa en tomar la clase más representada y ver por qué atributo se distingue más. Tiene las siguientes características:

- La variable objetivo será “Success” o “Failure”
- Se podrán hacer solo divisiones binarias
- La homogeneidad será mayor a mayor índice de Gini

Para calcular el índice Gini de los subnodos se utiliza la fórmula de la suma de los cuadrados de probabilidad para *success* y *failure*:

Se calcula Gini para la división usando la puntuación Gini para cada nodo de la división.




Figura 28: funcionamiento Índice Gini 2
(<https://theanalyticsbay.wordpress.com/2020/04/18/decision-trees-in-machine-learning/>)

3. Impacto con Objetivos de Desarrollo Sostenible

Este Trabajo de Fin de Grado, al estar basado en el seguimiento de la deforestación en la zona del Amazonas, está directamente relacionado con los Objetivos de Desarrollo Sostenible de: Acción por el Clima (Objetivo 13) y Vida de Ecosistemas Terrestres (Objetivo 15).

En el primer objetivo está relacionado porque la cantidad de zonas verdes existentes en nuestro planeta afecta directamente a la generación de gases de efecto invernadero de la Tierra. En el caso en la zona del Amazonas, existe un gran interés en monitorizar la cantidad de vegetación que hay ya que se considera “el pulmón del planeta” y la deforestación de ese espacio, resulta una amenaza grave contra el cambio climático.

En el segundo objetivo, Vida de Ecosistemas Terrestres, de la misma forma que para el primero, “es de vital importancia prevenir, detener y revertir la degradación de los ecosistemas del mundo” (según la página oficial de los Objetivos de Desarrollo Sostenible). Este trabajo también servirá de ayuda para realizar un seguimiento de nuevo, del impacto de la deforestación en la falta de biodiversidad de las zonas del Amazonas afectadas, ya que, de las 8,300 razas de animales conocidas, el 8% está extinto y el 22% está en peligro de extinción.

4. Metodología

4.1. Actividad con SeNtinel Application Platform (SNAP)

SNAP es la herramienta que aglomera todo lo que se ha comentado hasta ahora, del programa Copernicus. Se trata de una aplicación gratuita y abierta al público para la obtención y procesamiento de imágenes por satélite. Estas imágenes pueden haber sido tomadas por cualquiera de los satélites mencionados con anterioridad (de Sentinel) y permite obtener una gran variedad de tipos de imagen, dependiendo de lo que se pretenda observar. Desde imágenes de color verdadero a imágenes infrarrojas. SNAP proporciona una gran cantidad de información variada al usuario.

Es por esto por lo que, evidentemente, se usará esta herramienta para la obtención y el análisis de las imágenes.

4.1.1. Cómo descargar imágenes

4.1.1.1. Tipos de imágenes

Se disponen de distintos niveles para descargar las imágenes (Figura 29). En la figura se muestra el caso de Sentinel 2

Producto	Descripción
Level 0	Datos brutos comprimidos que contienen toda la información requerida para generar todos los niveles de procesamiento del producto de nivel 1 y superiores.
Level 1A	Datos brutos sin comprimir, con bandas espectrales groseramente coregistradas y datos complementarios adjuntos.
Level 1B	Imágenes en valores de radiancia corregidos radiométricamente.
Level 1C	Ortoimágenes en el WGS84 en la proyección UTM, en el huso correspondiente a la ubicación geográfica. Reflectancia aparente en el techo la atmósfera (TOA, Top - Of - Atmosphere reflectances).
Level 2A	Evolución del Nivel 1C en el que se aplican correcciones atmosféricas para proporcionar las ortoimágenes con niveles digitales expresados en valores de reflectancia reales a nivel de superficie (BOA, Bottom - Of - Atmosphere reflectances).

Figura 29. Niveles de imágenes Sentinel.

En este caso se usará el nivel 2A.

4.1.2. Obtener imágenes

Debido a las trayectorias de los satélites, imágenes cercanas geográficamente pueden ser registradas en fechas distintas. Por ejemplo, para ver la distribución de fechas del registro de las imágenes de España, se puede consultar la página de **Plan Nacional de Teledetección → Misiones Sentinel → Acceso a imágenes**.

En “Sentinel Grid Kml” se pueden descargar imágenes de cualquier parte del planeta mediante Google Earth para ver las *teselas*⁷.

En Copernicus Open Access Hub, se pueden obtener también las imágenes. Copernicus **Open Access Hub → Open Hub**. Para descargar imágenes Sentinel

habrá que estar registrado. Copernicus permite moverse y hacer zoom en todo el territorio. También existe la opción de seleccionar un polígono concreto, ya sea un polígono irregular de varios puntos o un rectángulo (manteniendo pulsado). Después habrá que rellenar una serie de parámetros para obtener las imágenes (Figura 30).

En **Advanced Search**, para hallar las imágenes habrá que rellenar el siguiente formulario:

The screenshot shows the 'Advanced Search' interface with the following fields and options:

- Insert search criteria** (header)
- Sensing Date** (dropdown menu)
- Descending** (dropdown menu)
- Sensing period** (date range: 2020/09/15 to 2020/10/15)
- Ingestion period** (empty date range)
- Mission: Sentinel-1** (selected)
- Satellite Platform** (dropdown menu)
- Polarisation** (dropdown menu)
- Relative Orbit Number (from 1 to 175)** (text input)
- Product Type** (dropdown menu)
- Sensor Mode** (dropdown menu)
- Collection** (dropdown menu)
- Mission: Sentinel-2** (selected)
- Satellite Platform** (dropdown menu)
- Relative Orbit Number (from 1 to 143)** (text input)
- Product Type** (dropdown menu, showing S2MSI2A)
- Cloud Cover % (e.g [0 TO 9.4])** (text input, showing [0 TO 15])

Figura 30. Formulario para descarga de imágenes.

Si se pasa el cursor por encima del enlace de la imagen, saldrá el área que cubre. Se pueden abrir también los detalles de la imagen (icono del ojo) que incluye la huella de la imagen, el **quicklook** (vista previa de la imagen) y metadatos. Además, permite añadir las imágenes a la cesta para descargarlo después o descargarlo directamente. Sentinel 2 registra imágenes en 13 bandas distintas.

El nombre de archivo de las imágenes (Figura 31) tiene el siguiente significado:

S2A_MSIL2A_20201003T110911_N0214_R137_T29SQA_20201003T140347.SAFE

S2A: Satélite (S2A o S2B)
MSIL2A: Instrumento MSI y nivel de procesado (MSIL1C, MSIL2A)
20201003T110911: Fecha de adquisición (inicio_final)
Formato de fecha: YYMMDDTHHMSS
N0214: Número de línea de base de procesamiento
R137: Número de líneas de procesamiento
T29SQA: Código de observación de la tile
20201003T140347: Fecha de generación del producto
.SAFE: formato del producto

Figura 31: Formato de imágenes Sentinel

El formato nativo de Sentinel 2 de las imágenes se descarga en varias carpetas. Para acceder a las imágenes como tal, la dirección es: **ARCHIVO.SAFE → GRANULE → ARCHIVO_INTERMEDIO → IMG_DATA → elegir resolución* (R10m, R20m, R60m etc).**

Dentro de la aplicación de SNAP se pueden descargar las imágenes desde:

Tools → Options → General → Product Library → Introducir usuario y contraseña de Sentinel → Ok

Una vez hecho eso, en el margen derecho se selecciona **Product Library** y se rellenan los parámetros (Figura 32):




Figura 32. Descarga de imágenes.

Presionando el botón derecho en la imagen, se puede descargar la imagen. Para cargar imágenes de Sentinel 2 en la herramienta, no es necesario descomprimir. Simplemente arrastrando el fichero a la sección de **Product Explorer** se pueden cargar los datos en la aplicación.

4.1.3. Funciones básicas de SNAP

Como ya se ha mencionado anteriormente, se le pueden incluir las imágenes en el formato original a la pestaña de **Product Explorer**. Desde la pestaña de **World View** se puede ver la posición de las imágenes en el mapa (Figura 33).




Figura 33. World View.

Se pueden visualizar cada una de las bandas abriendo el desplegable del archivo y seleccionar uno de los archivos de las bandas (B1,B2,B3,B4...).

4.1.3.1. Resolución de bandas

En la siguiente figura (Figura 34) se puede visualizar un esquema que indica las características de las bandas de Sentinel 2.




Figura 34. Bandas Sentinel 2.

Como se puede observar, las bandas de mayor resolución son las bandas 2, 3 y 4 junto a la 8 del infrarrojo cercano (NIR, near infrared) con 10 metros de resolución. Al abrir varias bandas, se abren en pestañas distintas en la aplicación, pero se le puede dar al recuadro de la vista (Figura 35) para observar de manera sincronizada ambas bandas.



Figura 35. Recuadro de vista.

Las distintas bandas permiten detectar mejor diferentes coberturas de terreno.

Para ver una imagen en color verdadero, hay que darle “click” derecho en el archivo en la pestaña de **Product Explorer** → **Open Image RGB**. Ahí se podrá visualizar en color verdadero, por defecto, aunque también se pueden seleccionar las bandas en el orden que se desee (Figura 36).




Figura 36. Visualización color.

4.1.3.2. Remuestreo

En caso de que una banda tenga una menor resolución y se requiera mejorar, se puede utilizar esta opción. Cada uno de los píxeles se dividirá convenientemente para lograr la resolución, a este proceso se le conoce como *resampling* (Figura 37).




Figura 37. *Resampling*.

El procedimiento a seguir requiere de las siguientes instrucciones **Raster → Geometric → Resampling**.

Esta acción va a requerir una gran capacidad de memoria en caso de que se desee guardar. Si no se guarda, se genera una imagen virtual en la web al presionar **By reference**, y se elige la banda con la resolución deseada. En **Upsampling method** se selecciona como mejor opción el “resampling” bicúbico. Al finalizar, se creará un archivo en *Product Explorer* con un archivo que acaba en *resampled*.

En la pestaña inferior a la izquierda (el realce) se puede aplicar un filtro a las imágenes para cambiar la visualización (Figura 38).




Figura 38. Histograma de banda GREEN.

4.1.3.3. Subset

Si se quieren obtener imágenes con X bandas y recortar la imagen actual, se puede hacer con *Subset*. Para ello, habrá que presionar en **Raster → Subset**.

Una vez ahí se puede elegir en el **Spatial Subset**, un recorte de la imagen. En **Band Subset** se puede seleccionar el número de bandas que se elegirán.

Si se eligen 2 imágenes que se solapan y se les realiza un “resampling” igual a ambas, se pueden guardar a continuación. Desde el menú, se siguen las siguientes instrucciones **Raster → Geometric → Mosaiking** (Figura 39).

En los parámetros de entrada, se le dará la indicación de las imágenes de entrada:




Figura 39. Mosaiking.

En la pestaña de **Map Projection Definition** (Figura 40) se realizó “resampling” en base a la Banda 2 que presenta 10m como resolución espacial.




Figura 40. Mosaiking 2.

En el menú (Figura 41) de **Variables & Conditions**, se seleccionarán las 5 bandas y se oprime **Run**.




Figura 41. Mosaicking 3.

Una vez haya cargado, se tendrá el mosaico generado. Se puede exportar el mosaico al seguir las siguientes instrucciones en **File** → **Export** → **GeoTIFF/BigTIFF**. Finalmente, se seleccionará desde la pestaña de **Subset** → **Spatial Subset** las bandas que sean de interés sin contar las que tengan el sufijo “_count” (Figura 42).




Figura 42. Specify Product Subset.

Finalmente se presiona a *Aceptar* y aparecerá esta pestaña donde se seleccionará que “No” (Figura 43).




Figura 43. Specify Product Subset 2.

4.2. Clasificación de imágenes [45]

En la pestaña inferior izquierda se encuentra el **World View** que será el mapa del mundo donde se podrá ver la sección seleccionada.

Para poder clasificar los datos, se hará uso de las figuras disponibles en la barra de superior derecha (Figura 44).




Figura 44. Menú.

4.2.1. Obtención de mapa NDVI

Como se ha mencionado anteriormente, para estimar las clases en las áreas de deforestación o pérdida de vegetación se utiliza el índice NDVI (Normalized Difference Vegetation Index). Este índice da idea de la cantidad de vegetación en un área concreta. Para obtener el mapa con los valores de NDVI, en primer lugar hay que seleccionar las bandas necesarias, tanto para imágenes Landsat como para Sentinel (sesores utilizados en este estudio). Las bandas son la banda roja (R) y la infrarroja cercana (NIR). En Landsat corresponden a la banda 4 (655 nm) y la banda 5 (865 nm) mientras que en Sentinel, a la banda 4 (665 nm) y la banda 8 (842 nm). Para obtener el mapa NDVI (Figura 45) hay que acceder mediante **Optical → Thematic Land Processing → Vegetation Radiometric Indices → NVDI**. El valor irá desde -1 a +1, siendo este el correspondiente a el mayor porcentaje de vegetación. Su descripción se verá más adelante.




Figura 45. Optical.

Aparece esta pantalla (Figura 46):




Figura 46. NDVI.

Y en el menú de **Processing Parameters** se deben seleccionar las bandas roja e infrarroja (Figura 47) en los campos de **Red source band** y **NIR source band**.




Figura 47. NDVI 2.

Al dar a **Run** se obtiene el archivo nuevo (Figura 48) con terminación **_ndvi** y en el apartado de bandas se obtiene el campo de NDVI donde se ve la representación de NDVI de la imagen seleccionada.




Figura 48. NDVI 3.

Se puede hacer uso del menú de **Colour Manipulation** para cambiar el color a la imagen y poder modificar los tonos iniciales por tonos verdes o rojizos, por ejemplo (Figura 49).




Figura 49. Color Manipulation.

Usando una tonalidad verde se obtiene la siguiente imagen (Figura 50):




Figura 50. Color Manipulation (verde).

En este caso, las zonas más verdes indican una cantidad mayor de vegetación mientras que las menos verdes zonas de menor cantidad de vegetación.

Para poder observar los valores del NDVI (Figura 51) simplemente hay que dirigirse al menú de **Pixel Info** en la parte superior izquierda y fijarse en el valor **ndvi**.

Position	
Image-X	3419 pixel
Image-Y	1764 pixel
Time	
Bands	
ndvi	0.16375
Tie-Point Grids	
Flags	

Figura 51. Valores de NDVI.

4.2.2. Obtención de áreas de entrenamiento

Para obtener las áreas de entrenamiento, primero habrá que elegir los vectores para seleccionarlos. Mediante **Vector → New Vector Data Container** se le indica un nombre al vector que se quiere usar (Figura 52). En este caso se puede dar, por ejemplo, el nombre de “agua”, “vegetación”, “ciudad” etc. Además, se le puede asignar una descripción:




Figura 52. New Vector Data Container.

Se obtendrá el Vector creado en la siguiente carpeta (Figura 53):




Figura 53. New Vector Data Container 2.

En el caso de este estudio, se ha denominado al vector “Grado 0” representando el nivel más bajo de deforestación o pérdida de vegetación.

A continuación, se deben seleccionar las áreas de entrenamiento de dicho Vector. Para ello habrá que moverse a una zona con nivel de deforestación cero.

Para que se pueda ver visualmente, se han elegido zonas considerablemente más verdes que el resto (Figura 54). Ahora se recogen las áreas con la siguiente herramienta del menú mostrado.




Figura 54. New Vector Data Container 2.

Se seleccionan las áreas, para ello hay que dar “click” al *Vector Data* donde se quieren guardar dichos polígonos (Figura 55).




Figura 55. Vector Data.

Usando la función polígono anteriormente indicada, se seleccionan las áreas (Figura 56):



Figura 56. Selección de áreas.

4.2.3. Información de las áreas

SNAP proporciona de una gran variedad de recursos para poder estudiar las superficies. En este caso se verán un par de esos recursos.

4.2.3.1. Análisis Espectral

Para ver información del píxel que se ha seleccionado en un momento dado en el mapa, se puede visualizar los valores (Figura 57) mediante **Optical** → **Spectrum View**.




Figura 57. Spectrum View.

Aparece una ventana siguiente, en la que se muestra la firma espectral (Figura 58).




Figura 58. Firma espectral del área seleccionada

4.2.3.2. Análisis de Dispersograma

Si se requiere más información en un espacio bidimensional espectral, se puede obtener mediante **Analysis** → **Scatter Plot** y obtener los gráficos correspondientes 2D entre bandas (Figura 59).




Figura 59. Obtención de Scatter Plot

En la ventana de **Scatter Plot**, habrá que oprimir el icono de refrescar para que se visualice (Figura 60) el dispersograma o *Scatter Plot*. En ROI mask (arriba a la derecha) se seleccionan el conjunto de Vector y para este caso, se seleccionan la banda roja y la banda infrarroja cercana.




Figura 60. Visualización del Scatter Plot

4.2.3.3. Análisis de Histograma

Se pueden visualizar los histogramas de las bandas utilizadas. Igual que el *Scatter Plot*, se encuentra en la pestaña de Analysis (Figura 61) y mediante **Analysis → Histogram** se puede visualizar (Figura 62).




Figura 61. Analysis →Histogram

Igual que en el caso del Scatter Plot, se pueden seleccionar uno de los vectores para analizar los datos como se ve a continuación:




Figura 62. Visualización de histogramas

El histograma expone la frecuencia de los diferentes valores radiométricos.

4.2.3.4. Análisis de Estadísticas

También se pueden comparar distintos conjuntos de vectores haciendo uso de la pestaña **Analysis** → **Statistics** de nuevo (Figura 63).




Figura 63. Analysis → Statistics

Esto lo que muestra, dependiendo de la banda que esté cargada, es el número de píxeles en esa banda y la distribución de los píxeles. Se pueden comparar simultáneamente las gráficas estadísticas de la imagen, como se ve a continuación en la siguiente figura (Figura 64).




Figura 64. Visualización de estadísticas

Conviene que las gráficas sean suficientemente distintas, lo que significa buena diferenciación entre los conjuntos de áreas.

4.3. Clasificación con Random Forest

Una vez se tienen todos los conjuntos de áreas de entrenamiento, que se desean utilizar para clasificar con Random Forest, se procede a aplicar el clasificador. Para eliminar la visualización de las áreas de entrenamiento durante este proceso, lo único que hay que hacer es darle al botón indicado (Figura 65).




Figura 65. Eliminación de la visualización de áreas.

No obstante, mediante **Layer manager** a la derecha, se pueden ver las distintas capas y áreas de entrenamiento para activarlas o desactivarlas (Figura 66).




Figura 66. Layer Manager.

Para ir al apartado del algoritmo mediante **Raster -> Classification -> Supervised Classification -> Random Forest Classifier**, aparecerá el siguiente menú (Figura 67):




Figura 67. Random Forest Classifier.

Apretando el botón de **Help** aparecerá más información del clasificador. Para añadir el conjunto de datos al clasificador hay que darle click al conjunto de datos y presionar el botón superior a la derecha (Figura 68).




Figura 68. Random Forest Classifier 2.

Como solo es de interés clasificar el conjunto de datos original, se puede eliminar cualquier archivo no necesario seleccionándolo y dándole al botón superior a la derecha (Figura 69):




Figura 69. Random Forest Classifier 3

En la pestaña de **Write** se escribirá el nombre con el que se quiere guardar y la ruta. El nombre por defecto tendrá el sufijo **_RF** (Figura 70).




Figura 70. Random Forest Classifier 4

En la pestaña de **Random-Forest-Classififer** se elegirán las siguientes opciones (Figura 71) relacionadas con el análisis a realizar:




Figura 71. Random Forest Classifier 5

Después de darle a **Run**, tardará un poco en ejecutar y se genera el siguiente archivo en la pestaña de productos (Figura 72a). Si se abre la carpeta, se puede ver la imagen clasificada (Figura 72b).




Figura 72. Fichero clasificado.

En la parte inferior izquierda se puede observar **Colour Manipulation** con una lista con las clases, sus colores y porcentajes (Figura 73). Si se da click en el color se puede cambiar.




Figura 73. Resultados con las clases obtenidas.

Para poder comparar adecuadamente varias imágenes clasificadas, se guardará la paleta de colores usada para poder importarla a otras imágenes (Figura 74).





Figura 74. Paleta de colores.

Yendo a la imagen donde se quiere importar la paleta de colores (Figura 75), se realizan las acciones representadas en la figura (Figura 76).




Figura 75. Paleta de colores 2




Figura 76. Paleta de colores 3.

De esa forma se pueden clasificar imágenes distintas (Figura 77).




Figura 77. Imágenes clasificadas.

4.4. Validación de los datos obtenidos

A continuación, se realiza la validación de la clasificación. Para ello, se necesita hacer uso de datos de validación.

Hay varias formas de obtener datos de validación, pero la que se utiliza en este estudio en adelante, es la implementada en el propio SNAP. Se accede a la imagen de color verdadero y se obtendrán los datos para validación manualmente. Se usa la estrategia de colocar pines (Figura 78) en las zonas supervisadas y reconocidas por el usuario. Se da click al producto en el que se desea recoger las muestras y luego al icono del pin.




Figura 78. Pin placing tool.

El número de muestras a recoger va a depender de diferentes criterios. Se pueden recoger entre unas 20 a 30 muestras por clase para poder tener unos datos de validación que se consideran adecuados. Para colocar los pines únicamente hay que darle a click izquierdo (Figura 79).




Figura 79. Imagen con pines colocados.

Se seleccionan los pines en clases concretas coincidentes con las de las áreas de interés. Esto servirá como “supervisión verdadera de terreno”.

A continuación, se accederá al **Pin Manager** (Figura 80).





Figura 80. Pin Manager.


Se muestra una tabla en la parte inferior de la pantalla (Figura 81).



X	Y	Lon	Lat	Color	Label
354.500	2327.5...	130.820962	-12.443096		Pin 1
686.500	2269.5...	130.827061	-12.442006		Pin 2
69.500	3136.5...	130.815821	-12.457756		Pin 3
253.500	3439.5...	130.819244	-12.463210		Pin 4
941.500	3420.5...	130.831897	-12.462781		Pin 5
570.500	2890.5...	130.825006	-12.453247		Pin 6
1984.5...	2994.5...	130.851028	-12.454950		Pin 7
2310.5...	3135.5...	130.857043	-12.457457		Pin 8
2956.5...	3454.5...	130.868967	-12.463142		Pin 9
3117.5...	3728.5...	130.871964	-12.468074		Pin 10

Figura 81. Pin Manager 2.

La X y la Y son las coordenadas de los píxeles, **Lon** que es la longitud y **Lat** que es la latitud, así como un color y el **Label** (o etiqueta) del píxel. Para clasificarlo en un tipo de vector, hay que dar doble click en **Label** y se escribe el nombre del Vector (Figura 82).



X	Y	Lon	Lat	Color	Label
354.500	2327.5...	130.820962	-12.443096		Water
686.500	2269.5...	130.827061	-12.442006		Water
69.500	3136.5...	130.815821	-12.457756		Pin 3
253.500	3439.5...	130.819244	-12.463210		Pin 4
941.500	3420.5...	130.831897	-12.462781		Pin 5
570.500	2890.5...	130.825006	-12.453247		Pin 6
1984.5...	2994.5...	130.851028	-12.454950		Pin 7
2310.5...	3135.5...	130.857043	-12.457457		Pin 8
2956.5...	3454.5...	130.868967	-12.463142		Pin 9
3117.5...	3728.5...	130.871964	-12.468074		Pin 10

Figura 82. Pin Manager 3.

Se repite el proceso hasta tener todos los pines correspondientes a las clases de de todas las áreas de entrenamiento. Se pueden copiar todos los pines obtenidos anteriormente y se pasan a otros productos para no tener que repetir todo el proceso para cada producto. Para ello, en la pestaña de **Pin Manager** habrá que darle click al botón inferior a la derecha del menú de la derecha. Hay que seleccionar todos los pines que se desea pasar dándole click encima de ellos (Figura 83).



Figura 83. Pin Manager 4.

Al dar click aparece el siguiente menú y se pueden seleccionar los productos donde se quiera que se trasladen los pines (Figura 84).




Figura 84. Pin Manager 5.

A continuación, se verifican los datos de validación con el algoritmo de clasificación. Para ello, a la derecha del menú de **Pin Manager** habrá que darle click al botón señalado en la Figura 85.




Figura 85. Validación.

Seleccionando, **LabeledClasses** aparecen los valores de las **LabeledClasses** para cada pin (Figura 86).




Figura 86. Validación 2.

Al darle click, aparece en el menú de **Pin Manager**, una nueva columna **LabeledClasses** que tiene un número numerado del 0 al número de clases/vectores que se tenga (Figura 87).

Pin Manager						
X	Y	Lon	Lat	Color	Label	LabeledClas...
2344.5...	464.500	130.857325	-12.409170		SportsField	4.0
354.500	2327.5...	130.820962	-12.443096		Water	0.0
686.500	2269.5...	130.827061	-12.442006		Water	0.0
69.500	3136.5...	130.815821	-12.457756		Water	0.0
253.500	3439.5...	130.819244	-12.463210		Water	0.0
941.500	3420.5...	130.831897	-12.462781		Water	0.0
570.500	2890.5...	130.825006	-12.453247		Water	0.0
1984.5...	2994.5...	130.851028	-12.454950		Water	0.0
2310.5...	3135.5...	130.857043	-12.457457		Water	0.0
2956.5...	3454.5...	130.868967	-12.463142		Water	0.0
3117.5...	3728.5...	130.871964	-12.468074		Water	0.0
2415.5...	2520.5...	130.858895	-12.446327		Mangroves	1.0
2308.5...	2750.5...	130.856957	-12.450498		Mangroves	1.0
2451.5...	2902.5...	130.859607	-12.453228		Mangroves	1.0
3402.5...	2774.5...	130.877082	-12.450793		Mangroves	1.0
3762.5...	2763.5...	130.883703	-12.450548		Mangroves	3.0
942.500	394.500	130.831532	-12.408080		Mangroves	1.0
1307.5...	436.500	130.838250	-12.408794		Mangroves	1.0
1519.5...	252.500	130.842126	-12.405442		Mangroves	1.0
1572.5...	279.500	130.843104	-12.405923		Mangroves	1.0
1600.5...	39.500	130.843588	-12.401581		Mangroves	1.0
2268.5...	1666.5...	130.856082	-12.430908		Buildings	5.0
2892.5...	1563.5...	130.867545	-12.428967		Buildings	5.0
3326.5...	1389.5...	130.875505	-12.425767		Buildings	5.0
3376.5...	1687.5...	130.876463	-12.431147		Buildings	5.0
3612.5...	1384.5...	130.880764	-12.425640		Buildings	5.0
605.500	3139.5...	130.825681	-12.457743		Buildings	5.0
374.500	2984.5...	130.821412	-12.454970		Buildings	5.0
1405.5...	3296.5...	130.840417	-12.460482		Buildings	5.0
1460.5...	3404.5...	130.841442	-12.462427		Buildings	5.0
1222.5...	3029.5...	130.837016	-12.455678		SportsField	5.0
670.500	3009.5...	130.826860	-12.455385		SportsField	4.0
478.500	3102.5...	130.823340	-12.457090		SportsField	4.0
814.500	3082.5...	130.829518	-12.456687		SportsField	4.0
1020.5...	2803.5...	130.833272	-12.451618		SportsField	4.0
1151.5...	2829.5...	130.835685	-12.452072		SportsField	4.0
1395.5...	1161.5...	130.839961	-12.421889		SportsField	4.0
1668.5...	1329.5...	130.845003	-12.424892		SportsField	NaN
1613.5...	1341.5...	130.843993	-12.425116		SportsField	4.0
2464.5...	1007.5...	130.859602	-12.418971		SportsField	4.0

Figura 87. Validación 3.

Ese número corresponderá al número del menú de **Colour Manipulation** a la izquierda para cada una de las áreas (Figura 88).



Label	Colour	Value	Frequency	Description
no data		-1	0.000%	no data
Water		0	35.074%	
Mangrove		1	12.298%	
DenseVeg...		2	8.040%	
Savanna		3	16.654%	
SportsField		4	2.833%	
Buildings		5	9.180%	
Tarmac		6	4.462%	
BareSoil		7	11.458%	

Figura 88. Validación 4.

Volviendo a la tabla anterior, se puede ver la tasa de acierto que se ha obtenido para los distintos pines (Figura 89).

En el menú de **Pin Manager** a la derecha se puede seleccionar que la tabla anterior se guarde en un archivo para poder analizarla detenidamente (Figura 91).




Figura 89. Validación 5.

Con los datos de la tabla anterior se puede crear la *matriz de error* o *matriz de confusión* para poder ver la precisión del algoritmo en la clasificación para calcular el coeficiente Kappa.

5. Selección de datos

5.1. Introducción

Como se ha mencionado anteriormente, las imágenes que se pretenden estudiar para este seguimiento temporal son las de la zona anexa al río Amazonas. En concreto, se eligen de una zona situada en el centro de Sudamérica, al oeste de Brasil, en el estado de Rondonia, entre las ciudades de Nova Mamoré y Guayaramerín (Figura 90). El estudio se centra en discriminar los niveles de deforestación de dicha zona a lo largo de aproximadamente la última década (2013-2021).




Figura 90. Localización de la zona de estudio (Longitud: -64.97491649°
Latitud: -10.61854913°)

Para realizar la descarga de imágenes se han utilizado dos plataformas distintas. La primera el USGS Earth Explorer, para obtener las imágenes de Landsat 8/9 y, por otro lado, la aplicación de Sentinel, SNAP para poder obtener las imágenes de Sentinel 2.

El proceso de descarga se ha realizado teniendo en cuenta varios factores:

- La zona debía tener el área aproximada a la mostrada en la Fig. 90. Dado que los satélites pueden tener diferentes trayectorias, en imágenes


relativamente grandes (como es el caso) podrían coincidir entre dos trayectorias (tanto Sentinel 2 como Landsat 8/9) y es por eso, por lo que algunas de las imágenes pueden estar cortadas en una sección. No obstante, la zona deseada se encuentra dentro de las imágenes obtenidas por lo que no ha supuesto ningún problema.

- La cobertura nubosa debía de ser baja. Dado que se trata de una zona de selva, donde, frecuentemente hay clima húmedo y lluvioso la mayor parte del año, al filtrar las imágenes en ambas plataformas por poca cobertura nubosa (de 0% a un 10% “[0 TO 10]”), apenas se obtuvieron resultados, no obstante, se pudieron obtener imágenes relativamente despejadas. Aquellas imágenes que contienen un poco más de superficie nubosa serán clasificadas asumiendo dicha cobertura.
- Para elegir las fechas en las que se descargan las imágenes, lo ideal parecía ser que compartieran la estación del año, para realizar la comparativa multitemporal. Por suerte, se pudieron obtener imágenes de poca cobertura nubosa de la zona deseada de meses próximos. En este caso, se obtuvieron de los meses: junio, agosto, septiembre y octubre. Por tanto, las imágenes se han tomado de aproximadamente las estaciones de invierno/primavera (dado que es el hemisferio sur).

Para el estudio multitemporal, se escogen imágenes en un intervalo de tiempo de 9 años, empezando desde 2013 hasta 2018 con imágenes Landsat 8 y continuando desde 2019 hasta 2021 con Sentinel 2. Se ha decidido utilizar dos satélites distintos para ampliar el intervalo temporal con imágenes de media/alta resolución espacial. Las imágenes de Landsat (resolución media) datan de fechas anteriores por lo que se puede realizar un estudio temporalmente más amplio de la deforestación, sin embargo, las imágenes Landsat tienen una resolución de 30m x 30m. No obstante, a partir de 2018 se empiezan a seleccionar imágenes de Sentinel 2 (debido al lanzamiento del segundo gemelo), para poder realizar una clasificación de bosques aleatorios más precisa ya que su resolución es de 10m x 10m.

Las imágenes presentan el siguiente nombre de archivo (nomenclatura):

Landsat:



[6] LC08_L2SP_233067_20130818_20200912_02_T1
[7] LC08_L2SP_233067_20140618_20200911_02_T1
[8] LC08_L2SP_233067_20140821_20200911_02_T1
[9] LC08_L2SP_233067_20150621_20200909_02_T1
[10] LC08_L2SP_233067_20160623_20200906_02_T1
[11] LC08_L2SP_233067_20170626_20200903_02_T1
[12] LC08_L2SP_233067_20180629_20200831_02_T1

Sentinel:


- [1] S2B_MSIL2A_20190822T143759_N0213_R096_T20LKP_20190822T184656
- [4] S2B_MSIL2A_20200925T143729_N0214_R096_T20LKP_20200925T182858
- [5] S2B_MSIL2A_20211010T143729_N0301_R096_T20LKP_20211010T191115

Las imágenes en composición color natural en SNAP, se muestran en la siguiente figura (Figura 91):


Landsat 18-08-2013



Landsat 18-06-2014




Landsat 21-06-2015



Landsat 23-06-2016



Landsat 26-06-2017



Landsat 29-06-2018



Sentinel 22-08-2019



Sentinel 25-09-2020



Sentinel 10-10-2021



Figura 91. Composición color natural de las imágenes utilizadas

Para la visualización color natural (RGB) se situarán las siguientes bandas en los distintos campos de SNAP (Figura 92):




Figura 92. Realización de composición color con SNAP

Las imágenes mostradas en la Figura 91 son las originales descargadas desde las plataformas indicadas. Se puede comprobar mediante la composición color natural, como las imágenes de Landsat y de Sentinel difieren un poco en la calidad por lo comentado anteriormente respecto a su diferente resolución espacial. Por otro lado, en las imágenes más actuales (Sentinel 25-09-2020 y Sentinel 10-10-2021) se puede observar cómo hay un cierto porcentaje de nubes

en la zona. Debido a las características climáticas de la zona, se presenta mucha dificultad en seleccionar imágenes sin cobertura nubosa alguna. En este caso fueron las imágenes con menos nubes que se pudieron encontrar (con filtro de selección para cobertura nubosa entre 0% y 10%). Esas imágenes probablemente sean las que discriminen peor las coberturas para clasificar, no obstante, se asumirá este hecho, resultando interesante poder ver y analizar los resultados que devuelve el algoritmo de bosques aleatorios.

5.2. Categorización de niveles de deforestación

Para poder introducir áreas de entrenamiento al algoritmo supervisado de bosques aleatorios se necesita en primer lugar, saber cuáles serán las posibles clases finales. Para ello, se distinguirán las superficies en varias categorías, para informar en la fase de entrenamiento al proceso de clasificación. Como esta investigación está orientada al estudio de la deforestación en la zona del Amazonas, se decide seleccionar áreas de entrenamiento en base al “grado” de deforestación o pérdida de vegetación que sufren la cobertura boscosa y en general la cobertura vegetativa.

A continuación, se visualiza una gran área de imagen (Figura 93) donde se podrían distinguir dichas áreas mencionadas.



Figura 93. Zona ejemplo para distinción de áreas.

Como se ha comentado anteriormente, para la clasificación de los grados de pérdida de vegetación se utiliza el índice NDVI (Normalized Difference Vegetation Index). El índice NDVI es una medida de la cantidad de vegetación que existe en un área determinada. El NDVI es el índice preferido para el seguimiento global de la vegetación, ya que ayuda a compensar cambios en las condiciones de iluminación, la pendiente de la superficie sobre la cual se asientan las plantas, exposiciones y otros factores externos. Su fórmula viene determinada por la siguiente ecuación:

$$NDVI = \frac{(NIR - Red)}{(NIR + Red)}$$

Los valores de este índice presentan un intervalo comprendido entre -1 a +1. El cálculo de este índice mediante la aplicación de álgebra de imágenes en la imagen multibanda original permite seleccionar las áreas de interés en un espacio reducido de información, donde se destaca las características espectrales de la vegetación.


Para seleccionar las áreas de interés y poder estimar las clases finales de la clasificación supervisada, se toman cuatro grados de vegetación. A continuación (Figura 94) se muestra la imagen en color junto con la imagen resultante del cálculo del NDVI para aclarar la selección realizada:

Grado 0: estas serán las áreas que no han sido afectadas prácticamente, por influencias antropogénicas. Se puede ver una vegetación natural y sin indicios de posibles daños. Su NDVI está en el rango de valores entre 0.80 y 1.0.

Grado 1: estas áreas podrían haber sido deforestadas en un menor grado por el ser humano o tener una pequeña pérdida de vegetación por algún motivo natural. Su NDVI está en el rango de valores entre 0.5 y 0.799

Grado 2: estas serán las áreas que han sido un poco más afectadas. Estarán a un nivel medio de deforestación o pérdida vegetativa. Su NDVI está en el rango de valores entre 0.2 y 0.499.

Grado 3: será el grado máximo de deforestación o pérdida vegetativa. No parece haber indicios de vegetación, en el caso de que hubiera inicialmente ya que ha sido completamente eliminada. Su NDVI está en el rango de valores comprendido entre -1 y 0.199.






Figura 94. Zonas de distinción de diferentes grados de cobertura vegetativa.

De acuerdo a lo comentado anteriormente, la estimación de clases inicial para las superficies deforestadas o con disminución de cobertura vegetativa son las mostradas en la Figura 94. Se escogerán de estas zonas, las áreas para entrenar al algoritmo. Las áreas deforestadas parecen estar divididas en cuadrículas de unos 500 metros de lado (según la herramienta de medición de SNAP).

5.3. Recortado de imágenes

Para realizar el estudio, se recortan las imágenes a las dimensiones de un área cerrada de la zona que se desea estudiar. De las imágenes de Landsat, se tiene el área total de las imágenes descargadas, según se muestra como ejemplo de una de ellas en la siguiente figura (Figura 95):



Figura 95. Ejemplo de imagen Landsat.

El siguiente paso metodológico es recortar la imagen para estudiar la zona de interés seleccionada de acuerdo a que parece que hay un mayor índice de deforestación, según se muestra en la Figura 96.



Figura 96. Recorte del ejemplo de imagen Landsat.

Para ello se utilizará la función de SNAP de **subset**.

Se utilizarán las coordenadas geográficas mostradas en la Figura 97 para obtener un área estimada de la zona.




Figura 97. Parámetros utilizados en el recorte mediante SNAP.

Una vez realizado el **subset** se obtiene el siguiente conjunto de imágenes:

```
[11] subset_0_of_LC08_L2SP_233067_20130818_20200912_02_T1
[12] subset_0_of_LC08_L2SP_233067_20140821_20200911_02_T1
[13] subset_0_of_LC08_L2SP_233067_20150621_20200909_02_T1
[14] subset_0_of_LC08_L2SP_233067_20160623_20200906_02_T1
[15] subset_0_of_LC08_L2SP_233067_20170626_20200903_02_T1
[16] subset_0_of_LC08_L2SP_233067_20180629_20200831_02_T1
```

Téngase en cuenta que se ha reducido el tamaño de las imágenes Landsat al tamaño de las imágenes de Sentinel unificando dimensiones.

5.4. Selección de áreas de entrenamiento

Como se ha mencionado antes, se elegirán 4 tipos de áreas de entrenamiento para clasificar la deforestación, por lo que tendremos al menos, 4 tipos de vectores para entrenar al algoritmo. Para la obtención de estas áreas se ha decidido buscar áreas que tuvieran un valor de NDVI constante tanto en la primera como en la última imagen. De esta manera nos aseguramos de que dichas áreas no hayan sido alteradas durante esos años y se pueden considerar cómo las áreas de entrenamiento para todos los años.

Para las áreas de grado 0, no deforestadas, (Figura 98) se observan aquellas secciones que se mantienen estables durante los 9 años.




Figura 98. Áreas de entrenamiento de grado 0

Todas las áreas seleccionadas desde 2013 a 2021 tienen un valor de NDVI de aproximadamente 0.85.

Para las áreas de grado 1, parcialmente deforestadas, (Figura 99) se observan estas secciones (verde y azul claros) que se mantienen estables durante los 9 años.




Figura 99. Áreas de entrenamiento de grado 1

Todas las áreas seleccionadas desde 2013 a 2021 tienen un valor de NDVI de aproximadamente 0.60.

Para las áreas de grado 2, moderadamente deforestadas, (Figura 100) se mirarán estas secciones (azul claro y morado) que se mantienen estables durante los 9 años.



Figura 100. Áreas de entrenamiento de grado 2

Todas las áreas seleccionadas desde 2013 a 2021 tienen un valor de NDVI de aproximadamente 0.40.

En cuanto a las áreas de grado 3, totalmente deforestadas (Figura 101) como varían de forma tan radical a lo largo de los años no se han podido recoger

muestras iguales a lo largo del tiempo por lo que se han cogido muestras de zonas distintas para cada año. Se muestran las áreas para 2013 y 2021.



Figura 101. Áreas de entrenamiento de grado 3

Todas las áreas seleccionadas desde 2013 a 2021 tienen un valor de NDVI de aproximadamente 0.19.

Además, se seleccionan como áreas de entrenamiento el agua y la zona urbana (Figura 102) para poder tener una representación más precisa de lo que representa el clasificador.




Figura 102. Áreas de entrenamiento de clases agua y urbano

Como las zonas urbanas y de agua seleccionadas no han variado con el paso de los años, serán áreas de alta fidelidad para la clasificación.

5.5. Aplicación del algoritmo de Random Forest

Una vez se seleccionan las áreas, se procede a aplicar el algoritmo. Se ha decidido utilizar la siguiente paleta de colores (Figura 103) para representar las distintas áreas.

Label	Colour	Value
no data		-1
Agua		0
Grado 0		1
Grado 1		2
Grado 2		3
Grado 3		4
Urbano		5

Figura 103. Paleta de colores utilizada

Azul claro para el agua, verde oscuro para la vegetación densa, verde de un tono más claro para las zonas parcialmente deforestadas, verde claro para las zonas moderadamente deforestadas, amarillo para las zonas completamente deforestadas y marrón para las zonas urbanas.

Las imágenes clasificadas, se muestran a continuación (Figuras 104-112).




Figura 104. Imagen clasificada (Landsat 18-08-2013)




Figura 105. Imagen clasificada (Landsat 21-08-2014)




Figura 106. Imagen clasificada (Landsat 21-06-2015)




Figura 107. Imagen clasificada (Landsat 23-06-2016)



Figura 108. Imagen clasificada (Landsat 26-06-2017)




Figura 109. Imagen clasificada (Landsat 29-06-2018)




Figura 110. Imagen clasificada (Sentinel 22-08-2019)




Figura 111. Imagen clasificada (Sentinel 25-09-2020)



Figura 112. Imagen clasificada (Sentinel 10-10-2021)

Para las últimas imágenes se ha decidido crear 2 tipos de áreas de entrenamiento más: nubes y sombra de nubes. Esto se ha realizado ya que la clasificación sin estas áreas, provocaba unos resultados bastante confusos y los porcentajes de las áreas de interés se veían alterados para dar resultados no representativos.

6. Estudio de resultados

6.1. Porcentajes de clases

A continuación, se muestran los porcentajes de las clases (Figura 113) para cada una de las imágenes en estudio, cual es la evolución de las distintas áreas a lo largo del tiempo. Téngase en cuenta que los Label (etiquetas) correspondientes a los nombres de las áreas pueden ser ligeramente distintos, debido al proceso de exportación/importación de áreas entre imágenes.

Label	Colour	Value	Frequency	Description
no data		-1	0.000%	no data
Agua		0	3.932%	
Grado 0		1	71.011%	
Grado 1		2	13.166%	
Grado 2		3	7.574%	
Grado 3		4	2.143%	
Urbano		5	2.174%	

Landsat 18-08-2013

Label	Colour	Value	Frequency	Description
no data		-1	0.000%	no data
Agua_Polygon		0	4.258%	
Grado%200...		1	69.216%	
Grado%201...		2	14.729%	
Grado%202...		3	4.218%	
Grado%203...		4	6.070%	
Urbano_Pol...		5	1.509%	

Landsat 21-08-2014

Label	Colour	Value	Frequency	Description
no data		-1	0.000%	no data
Agua_Polygon		0	4.121%	
Grado%200...		1	72.519%	
Grado%201...		2	13.897%	
Grado%202...		3	3.867%	
Grado%203...		4	4.714%	
Urbano_Pol...		5	0.882%	

Landsat 21-06-2015

Label	Colour	Value	Frequency	Description
no data		-1	0.000%	no data
Agua_Polygon		0	4.139%	
Grado%200...		1	71.000%	
Grado%201...		2	9.274%	
Grado%202...		3	7.224%	
Grado%203...		4	7.370%	
Urbano_Pol...		5	0.992%	

Landsat 23-06-2016

Label	Colour	Value	Frequency	Description
no data		-1	0.000%	no data
Agua_Polygon		0	3.900%	
Grado%200...		1	74.243%	
Grado%201...		2	9.460%	
Grado%202...		3	6.588%	
Grado%203...		4	5.052%	
Urbano_Pol...		5	0.757%	

Landsat 26-06-2017

Label	Colour	Value	Frequency	Description
no data		-1	0.000%	no data
Agua_Polygon		0	3.983%	
Grado%200...		1	70.499%	
Grado%201...		2	12.421%	
Grado%202...		3	4.301%	
Grado%203...		4	7.938%	
Urbano_Pol...		5	0.857%	

Landsat 29-06-2018				
Label	Colour	Value	Frequency	Description
no data		-1	0.000%	no data
Agua_Polygon		0	3.651%	
Grado%200...		1	69.899%	
Grado%201...		2	13.781%	
Grado%202...		3	2.535%	
Grado%203...		4	9.636%	
Urbano_Pol...		5	0.498%	
Sentinel 22-08-2019				
Label	Colour	Value	Frequency	Description
no data		-1	0.000%	no data
Agua_Polygon		0	5.171%	
Grado%200...		1	65.007%	
Grado%201...		2	9.717%	
Grado%202...		3	6.449%	
Grado%203...		4	8.768%	
Urbano_Pol...		5	1.308%	
Nubes		6	2.441%	
Sombra de n...		7	1.139%	
Sentinel 25-09-2020				
Label	Colour	Value	Frequency	Description
no data		-1	0.000%	no data
Agua_Polygon		0	4.007%	
Grado%200...		1	64.880%	
Grado%201...		2	9.749%	
Grado%202...		3	3.564%	
Grado%203...		4	12.304%	
Urbano_Pol...		5	1.194%	
Nubes		6	2.718%	
Sombra de n...		7	1.584%	
Sentinel 10-10-2021				

Figura 113. Porcentajes de clasificación

A continuación, se muestra una recopilación de resultados con la evolución de los porcentajes por clases (Figura 114):

	2013	2014	2015	2016	2017	2018	2019	2020	2021
No data	0	0	0	0	0	0	0	0	0
Agua	3.932	4.258	4.121	4.139	3.900	3.983	3.651	5.171	4.007
Grado 0	71.011	69.216	72.519	71.000	74.243	70.499	69.899	65.007	64.880
Grado 1	13.166	14.729	13.897	9.274	9.460	12.421	13.781	9.717	9.749
Grado 2	7.574	4.218	3.867	7.224	6.588	4.301	2.535	6.449	3.564
Grado 3	2.143	6.070	4.713	7.370	5.052	7.938	9.636	8.768	12.304
Urbano	2.174	1.509	0.882	0.992	0.757	0.857	0.498	1.308	1.194
Nubes	-	-	-	-	-	-	-	2.441	2.718
Sombra de nubes	-	-	-	-	-	-	-	1.139	1.584

Figura 114. Tabla de porcentajes de áreas

Como se puede observar, el porcentaje de las áreas deforestadas o afectadas por una disminución de la cobertura vegetativa, a lo largo del tiempo va aumentando, mientras que las áreas de valores altos en el índice de vegetación van disminuyendo (Figura 114).

Desde 2013 a 2021, las áreas de Grado 0 han pasado de un porcentaje del 71.011% a un 64.880%, las áreas de Grado 1 han pasado de un 13.166% a un 9.749%, las áreas de Grado 2 han pasado de un 7.574% a un 3.564% y las áreas de Grado 3 han pasado de un 2.143% a un 12.304%.

En cuanto a las superficies que no están relacionadas con coberturas vegetales y por lo tanto presentan valores muy bajos del NDVI, como son las clases etiquetadas como *Urbano* y *Agua*, se puede observar, cómo van variando a lo largo del tiempo, esto se puede deber a varios motivos:

- La variación de caudal y áreas con agua (charcas, ríos de menor tamaño, etc).
- La construcción y/o destrucción de zonas urbanas.
- La clasificación errónea de las áreas por otros motivos.

6.2. Estudio individual de las zonas

Para estudiar por qué estas áreas se van modificando, se compara como ejemplo representativo, la imagen en color natural de Sentinel 2 de 2019 (Figura 115a) (buena resolución y menor cobertura nubosa) junto con su respectiva clasificada por Random Forest (Figura 115b).




Figura 115a. Imagen Sentinel 2019



Figura 115b. Sentinel 2019 clasificada con Random Forest

6.2.1. Zona urbana

Para saber cuáles son los conjuntos clasificados erróneamente de las zonas urbanas, se va a realizar un análisis de las zonas urbanas supervisadas en la imagen. Hay que tener en cuenta que las áreas urbanas reales son las señaladas en la imagen de la Figura 116a. Estas son las zonas urbanas que hay en esa imagen (áreas redondeadas con círculos rojos) que se ha comprobado accediendo a la zona en Google Earth y buscando las poblaciones que hay manualmente. Como se puede observar en la Figura 116b, existen áreas que están siendo catalogadas como urbanas cuando en realidad no lo son.

A continuación, se muestra únicamente las zonas urbanas en negro (Figura 117). En este caso, se ha decidido cambiar la paleta de colores de las zonas clasificadas para mostrar solo las zonas urbanas en negro, para lo cual se han pintado las demás áreas de color blanco.




Figura 116a. Zonas urbanas reales en imagen Sentinel 2 de 2019



Figura 116b. Zonas urbanas erróneamente clasificadas en imagen Sentinel 2 de 2019




Figura 117. Zonas urbanas representadas en negro en imagen Sentinel 2 de 2019

Como se puede ver existen píxeles clasificados como zona urbana en toda la imagen. Esto se puede deber a que la imagen ha tenido que ser remuestreada para unificar la resolución espacial. Es por eso por lo que muchos de los píxeles aparentemente urbanos realmente son píxeles claros o pertenecientes a los caminos existentes entre las zonas deforestadas. Se puede ver como el algoritmo clasifica el río principal adecuadamente, sin embargo, los ríos secundarios (de menor luminosidad) son erróneamente clasificados y confundidos con píxeles urbanos o coberturas de suelo.

El histograma de la zona urbana (áreas de entrenamiento) se muestra a continuación (Figura 118):




Figura 118. Histograma de las zonas urbanas

6.2.2. Zona de agua

A continuación, se mostrará el mismo tipo de mapa del análisis anterior(en negro), pero en el caso del agua (Figura 119).



Figura 119. Zonas de agua (en negro) en imagen Sentinel 2 de 2019

En este caso se pueden ver más destacadas las zonas que contienen agua, sin embargo, parece que el algoritmo sigue confundiéndose en la apreciación de zonas de agua en las zonas de vegetación.

El histograma de la zona de agua se muestra a continuación (Figura 120):




Figura 120. Histograma de las zonas de agua

Como se puede ver, el histograma presenta máximos a valores bajos de niveles de gris. Como se ha mencionado antes, se dispone de una resolución relativamente media/grande, por lo que, será posible llegar a un cierto nivel de precisión. Además, hay que destacar que el resto de clases no presentan un histograma con valores parecidos a este.

6.2.3. Zona de vegetación de grado 0

A continuación, se estudiarán las zonas de grado 0 de vegetación con el mismo mapa blanco y negro (Figura 121).




Figura 121. Zonas de grado 0 (en negro) en imagen de Sentinel 2 de 2019

Como se puede ver, el algoritmo parece que acierta plenamente clasificando este tipo de cobertura porque es un área espectralmente muy diferente al resto. Esto se puede verificar en las imágenes ndvi de las diferentes clases.

El histograma de la zona de grado 0 se muestra a continuación (Figura 122):




Figura 122. Histograma de las zonas de grado 0

6.2.4. Zona de vegetación de grado 1

A continuación, se estudiarán las zonas de grado 1 de vegetación con el mismo mapa blanco y negro (Figura 123).




Figura 123. Zonas de grado 1 (en negro) en imagen Sentinel 2 de 2019

Parece ser que clasifica en su mayoría de forma correcta. Como las zonas urbanas y cercanas al agua tienen ese tipo de vegetación cerca, no resulta raro apreciar que se ve de forma más destacada en esas zonas.

El histograma de la zona de grado 1 se muestra a continuación (Figura 124):




Figura 124. Histograma de las zonas de grado 1

6.2.5. Zonas de vegetación de grado 2

A continuación, se estudiarán las zonas de grado 2 de vegetación con el mismo mapa blanco y negro (Figura 125).



Figura 125. Zonas de grado 2 (en negro) en imagen Sentinel 2 de 2019

Como se puede observar existe mucha menos cantidad de zona de vegetación de grado 2 debido a que en la imagen original hay menos cantidad. Resulta interesante apreciar como el algoritmo, al intentar clasificar esta zona, se puede ver que clasifica los ríos pequeños como este tipo de área. Esto se puede deber a que estos ríos con la imagen remuestreada y los factores de iluminación, obtienen un tono muy parecido al de las zonas de deforestación moderada.

El histograma de la zona de grado 2 se muestra a continuación (Figura 126):




Figura 126. Histograma de las zonas de grado 2

6.2.6. Zonas de vegetación de grado 3

A continuación, se estudiarán las zonas de grado 3 de vegetación con el mismo mapa blanco y negro (Figura 127).



Figura 127. Zonas de grado 3 (en negro) en imagen Sentinel 2 de 2019

Por último, se puede observar las zonas de vegetación de grado 3. En este caso, al tratarse de la imagen de Sentinel de 2019, se puede ver que la deforestación es más prominente en esta imagen. Si se compara con la imagen de 2013 de Landsat (Figura 128), se puede ver la gran diferencia que hay en esos 7 años.



Figura 128. Zonas de grado 3 (en negro) en imagen Landsat de 2013

Poniéndolas lado a lado se puede ver la gran diferencia de las zonas a continuación (Figura 129).




Figura 129. Comparación de zonas de grado 3 entre imagen Landsat de 2013 y de imagen Sentinel de 2019

Se puede observar, como era de esperar, como ha habido un aumento en las zonas deforestadas, justificado en la tabla de porcentaje de asignación de clases. Hay algunas que se mantienen constantes porque se trata de zonas cercanas a la ciudad que, por un motivo u otro, se han mantenido iguales.

El histograma de la zona de grado 3 se muestra a continuación (Figura 130):




Figura 130. Histograma de las zonas de grado 3

Como se puede ver, existen en este caso 3 picos. Esto se puede dar porque haya varios tipos de áreas deforestadas (tierra seca, tierra mojada, tierra negra, terrenos arcillosos, etc). Esto supone que exista variabilidad espectral y, por lo tanto, diferentes valores en el histograma.

6.3. Validación de resultados

Para la parte de validación se utilizará la herramienta de pines y se usará la imagen de Landsat de 2013. Se seleccionan unos 20 pines para cada área de entrenamiento, para poder ver si el algoritmo clasifica adecuadamente los puntos elegidos. Habrá que tener en cuenta la clasificación según la paleta de colores obtenida antes (Figura 131), ya que el número asignado a cada área (denominado por **Value**) servirá para saber si la clasificación se ha realizado correctamente.

Label	Colour	Value	Frequency	Description
no data		-1	0.000%	no data
Agua		0	3.932%	
Grado 0		1	71.011%	
Grado 1		2	13.166%	
Grado 2		3	7.574%	
Grado 3		4	2.143%	
Urbano		5	2.174%	

Figura 131. Paleta de colores de las zonas clasificadas

6.3.1. Zona urbana

A continuación, se muestra una escena de la imagen en visualización color en la que se ha realizado la recogida de pines para la zona urbana (Figura 132):



Figura 132. Pines seleccionados en zona urbana

Se obtiene la siguiente tabla de pines (Figura 133):

1541.500	3050.500	-65.323965	-10.772700		Zona urbana
1572.500	3037.500	-65.315501	-10.769151		Zona urbana
1569.500	3072.500	-65.316320	-10.778707		Zona urbana
1493.500	3082.500	-65.337070	-10.781437		Zona urbana
1532.500	3093.500	-65.326422	-10.784441		Zona urbana
1542.500	3077.500	-65.323692	-10.780072		Zona urbana
1435.500	3258.500	-65.352906	-10.829491		Zona urbana
1449.500	3242.500	-65.349084	-10.825123		Zona urbana
1417.500	3255.500	-65.357821	-10.828672		Zona urbana
1407.500	3273.500	-65.360551	-10.833587		Zona urbana
1399.500	3265.500	-65.362736	-10.831403		Zona urbana
1401.500	3247.500	-65.362190	-10.826488		Zona urbana
1412.500	3244.500	-65.359186	-10.825669		Zona urbana
1443.500	3265.500	-65.350722	-10.831403		Zona urbana
1460.500	3265.500	-65.346080	-10.831403		Zona urbana
1440.500	3282.500	-65.351541	-10.836044		Zona urbana
1483.500	3101.500	-65.339801	-10.786625		Zona urbana
1606.500	3029.500	-65.306218	-10.766967		Zona urbana
1560.500	3022.500	-65.318777	-10.765055		Zona urbana
1548.500	3027.500	-65.322054	-10.766421		Zona urbana

Figura 133. Tabla de pines de zona urbana

Al exportar la tabla de pines (Figura 133) a la imagen clasificada obtenemos lo siguiente (Figura 134):




Figura 134. Transición de pines de zona urbana de imagen original a imagen clasificada

Se obtiene la siguiente clasificación de pines (Figura 135):

1541.500	3050.500	-65.323965	-10.772700		Zona urbana	5.0
1572.500	3037.500	-65.315501	-10.769151		Zona urbana	5.0
1569.500	3072.500	-65.316320	-10.778707		Zona urbana	5.0
1493.500	3082.500	-65.337070	-10.781437		Zona urbana	5.0
1532.500	3093.500	-65.326422	-10.784441		Zona urbana	5.0
1542.500	3077.500	-65.323692	-10.780072		Zona urbana	5.0
1435.500	3258.500	-65.352906	-10.829491		Zona urbana	5.0
1449.500	3242.500	-65.349084	-10.825123		Zona urbana	5.0
1417.500	3255.500	-65.357821	-10.828672		Zona urbana	4.0
1407.500	3273.500	-65.360551	-10.833587		Zona urbana	5.0
1399.500	3265.500	-65.362736	-10.831403		Zona urbana	4.0
1401.500	3247.500	-65.362190	-10.826488		Zona urbana	5.0
1412.500	3244.500	-65.359186	-10.825669		Zona urbana	5.0
1443.500	3265.500	-65.350722	-10.831403		Zona urbana	5.0
1460.500	3265.500	-65.346080	-10.831403		Zona urbana	5.0
1440.500	3282.500	-65.351541	-10.836044		Zona urbana	5.0
1483.500	3101.500	-65.339801	-10.786625		Zona urbana	5.0
1606.500	3029.500	-65.306218	-10.766967		Zona urbana	5.0

Figura 135. Tabla de pines de zona urbana clasificados

En este caso se obtiene una tasa de acierto de 18/20, es decir, un 90%.

6.3.2. Zona de agua

A continuación, se muestra una escena de la imagen en visualización color en la que se ha realizado la recogida de pines para la zona de agua (Figura 136):



Figura 136. Pines seleccionados en zona de agua

Se obtiene la siguiente tabla de pines (Figura 137):

1617.500	1124.500	-65.303214	-10.246837		Zona de agua
1596.500	1144.500	-65.308948	-10.252297		Zona de agua
1641.500	1074.500	-65.296661	-10.233185		Zona de agua
1591.500	1189.500	-65.310313	-10.264584		Zona de agua
1573.500	1216.500	-65.315228	-10.271956		Zona de agua
1572.500	1258.500	-65.315501	-10.283423		Zona de agua
1551.500	1290.500	-65.321234	-10.292160		Zona de agua
1551.500	1258.500	-65.321234	-10.283423		Zona de agua
1643.500	959.500	-65.296115	-10.201786		Zona de agua
1623.500	916.500	-65.301576	-10.190046		Zona de agua
1516.500	1366.500	-65.330791	-10.312911		Zona de agua
1461.500	1393.500	-65.345807	-10.320283		Zona de agua
1318.500	1646.500	-65.384851	-10.389360		Zona de agua
1292.500	1634.500	-65.391950	-10.386084		Zona de agua
1481.500	1369.500	-65.340347	-10.313730		Zona de agua
1337.500	1782.500	-65.379664	-10.426493		Zona de agua
1193.500	2035.500	-65.418981	-10.495571		Zona de agua
1459.500	2880.500	-65.346354	-10.726285		Zona de agua
1452.500	2968.500	-65.348265	-10.750312		Zona de agua
1452.500	2682.500	-65.348265	-10.672224		Zona de agua

Figura 137. Tabla de pines de zona urbana

Al pasar la tabla de pines (Figura 137) a la imagen clasificada obtenemos lo siguiente (Figura 138):



Figura 138. Transición de pines de zona de agua de imagen original a imagen clasificada

Se obtiene la siguiente clasificación de pines (Figura 139):

1617.500	1124.500	-65.303214	-10.246837		Zona de agua	0.0
1596.500	1144.500	-65.308948	-10.252297		Zona de agua	0.0
1641.500	1074.500	-65.296661	-10.233185		Zona de agua	0.0
1591.500	1189.500	-65.310313	-10.264584		Zona de agua	0.0
1573.500	1216.500	-65.315228	-10.271956		Zona de agua	0.0
1572.500	1258.500	-65.315501	-10.283423		Zona de agua	0.0
1551.500	1290.500	-65.321234	-10.292160		Zona de agua	0.0
1551.500	1258.500	-65.321234	-10.283423		Zona de agua	0.0
1643.500	959.500	-65.296115	-10.201786		Zona de agua	0.0
1623.500	916.500	-65.301576	-10.190046		Zona de agua	0.0
1516.500	1366.500	-65.330791	-10.312911		Zona de agua	0.0
1461.500	1393.500	-65.345807	-10.320283		Zona de agua	0.0
1318.500	1646.500	-65.384851	-10.389360		Zona de agua	0.0
1292.500	1634.500	-65.391950	-10.386084		Zona de agua	0.0
1481.500	1369.500	-65.340347	-10.313730		Zona de agua	0.0
1337.500	1782.500	-65.379664	-10.426493		Zona de agua	0.0
1193.500	2035.500	-65.418981	-10.495571		Zona de agua	0.0
1459.500	2880.500	-65.346354	-10.726285		Zona de agua	0.0
1452.500	2968.500	-65.348265	-10.750312		Zona de agua	0.0
1452.500	2682.500	-65.348265	-10.672224		Zona de agua	0.0

Figura 139. Tabla de pines de zona de agua clasificados

En este caso se obtiene una tasa de acierto de 20/20, es decir, un 100%.

6.3.3. Grado 0

A continuación, se muestra una escena de la imagen en visualización color en la que se ha realizado la recogida de pines para la zona de grado 0 (Figura 140):



Figura 140. Pines seleccionados en zona de grado 0

Se obtiene la siguiente tabla de pines (Figura 141):

X	Y	Lon	Lat	Color	Label
1791.500	1916.500	-65.255706	-10.463080		Grado 0
1900.500	1915.500	-65.225946	-10.462807		Grado 0
1857.500	1992.500	-65.237686	-10.483830		Grado 0
1993.500	1955.500	-65.200553	-10.473728		Grado 0
2085.500	1928.500	-65.175434	-10.466356		Grado 0
2095.500	2085.500	-65.172704	-10.509222		Grado 0
2226.500	1782.500	-65.136936	-10.426493		Grado 0
2206.500	1980.500	-65.142397	-10.480554		Grado 0
2010.500	2168.500	-65.195912	-10.531884		Grado 0
1869.500	2121.500	-65.234410	-10.519052		Grado 0
2178.500	2134.500	-65.150042	-10.522601		Grado 0
2244.500	2063.500	-65.132022	-10.503216		Grado 0
2110.500	2027.500	-65.168608	-10.493386		Grado 0
1996.500	2090.500	-65.199734	-10.510588		Grado 0
1726.500	2077.500	-65.273453	-10.507038		Grado 0
1555.500	1904.500	-65.320142	-10.459803		Grado 0
1725.500	1849.500	-65.273726	-10.444786		Grado 0
1834.500	1772.500	-65.243966	-10.423763		Grado 0
1671.500	1792.500	-65.288470	-10.429223		Grado 0
1516.500	1836.500	-65.330791	-10.441237		Grado 0

Figura 141. Tabla de pines de zona de grado 0

Al pasar la tabla de pines (Figura 141) a la imagen clasificada obtenemos lo siguiente (Figura 142):




Figura 142. Transición de pines de zona de grado 0 de imagen original a imagen clasificada

Se obtiene la siguiente clasificación de pines (Figura 143):

X	Y	Lon	Lat	Color	Label	LabeledClas...
2134.500	2051.500	-65.162056	-10.499939		Grado 0	1.0
1812.500	1919.500	-65.249973	-10.463899		Grado 0	1.0
2010.500	1945.500	-65.195912	-10.470998		Grado 0	1.0
2207.500	1951.500	-65.142124	-10.472636		Grado 0	1.0
1845.500	2009.500	-65.240962	-10.488472		Grado 0	1.0
1997.500	1827.500	-65.199461	-10.438780		Grado 0	1.0
1832.500	1765.500	-65.244512	-10.421852		Grado 0	1.0
1673.500	1805.500	-65.287924	-10.432773		Grado 0	1.0
1562.500	1919.500	-65.318231	-10.463899		Grado 0	1.0
1776.500	2036.500	-65.259802	-10.495844		Grado 0	1.0
1845.500	2112.500	-65.240962	-10.516594		Grado 0	1.0
1914.500	2011.500	-65.222123	-10.489018		Grado 0	1.0
2047.500	2149.500	-65.185810	-10.526697		Grado 0	1.0
2253.500	2156.500	-65.129564	-10.528608		Grado 0	1.0
2299.500	2057.500	-65.117005	-10.501577		Grado 0	1.0
2117.500	2194.500	-65.166697	-10.538983		Grado 0	1.0
1901.500	2193.500	-65.225672	-10.538710		Grado 0	1.0
1837.500	2198.500	-65.243147	-10.540075		Grado 0	1.0
2495.500	1934.500	-65.063490	-10.467994		Grado 0	1.0
2511.500	1722.500	-65.059122	-10.410111		Grado 0	1.0

Figura 143. Tabla de pines de zona de grado 0 clasificados

En este caso se obtiene una tasa de acierto de 20/20, es decir, un 100%.

6.3.4. Grado 1

A continuación, se muestra una escena de la imagen en visualización color en la que se ha realizado la recogida de pines para la zona de grado 1 (Figura 144):



Figura 144. Pines seleccionados en zona de grado 1

Se obtiene la siguiente tabla de pines (Figura 145):

1821.500	1356.500	-65.247515	-10.310181		Grado 1
1689.500	1548.500	-65.283556	-10.362603		Grado 1
1678.500	1571.500	-65.286559	-10.368883		Grado 1
2066.500	1685.500	-65.180622	-10.400009		Grado 1
2058.500	1675.500	-65.182806	-10.397278		Grado 1
2065.500	1702.500	-65.180895	-10.404650		Grado 1
2134.500	1708.500	-65.162056	-10.406289		Grado 1
2200.500	1554.500	-65.144035	-10.364241		Grado 1
1558.500	1338.500	-65.319323	-10.305266		Grado 1
2102.500	1836.500	-65.170793	-10.441237		Grado 1
2192.500	1762.500	-65.146220	-10.421032		Grado 1
1319.500	2049.500	-65.384578	-10.499393		Grado 1
1216.500	1903.500	-65.412701	-10.459530		Grado 1
1647.500	2170.500	-65.295023	-10.532430		Grado 1
1376.500	2182.500	-65.369015	-10.535707		Grado 1
1514.500	1962.500	-65.331337	-10.475639		Grado 1
1642.500	1159.500	-65.296388	-10.256393		Grado 1
1749.500	1082.500	-65.267174	-10.235369		Grado 1
1765.500	1069.500	-65.262805	-10.231820		Grado 1
1750.500	1071.500	-65.266901	-10.232366		Grado 1

Figura 145. Tabla de pines de zona de grado 1

Al pasar la tabla de pines (Figura 145) a la imagen clasificada obtenemos lo siguiente (Figura 146):




Figura 146. Transición de pines de zona de grado 1 de imagen original a imagen clasificada

Se obtiene la siguiente clasificación de pines (Figura 147):

1821.500	1356.500	-65.247515	-10.310181		Grado 1	2.0
1689.500	1548.500	-65.283556	-10.362603		Grado 1	2.0
1678.500	1571.500	-65.286559	-10.368883		Grado 1	2.0
2066.500	1685.500	-65.180622	-10.400009		Grado 1	2.0
2058.500	1675.500	-65.182806	-10.397278		Grado 1	2.0
2065.500	1702.500	-65.180895	-10.404650		Grado 1	2.0
2134.500	1708.500	-65.162056	-10.406289		Grado 1	2.0
2200.500	1554.500	-65.144035	-10.364241		Grado 1	2.0
1558.500	1338.500	-65.319323	-10.305266		Grado 1	2.0
2102.500	1836.500	-65.170793	-10.441237		Grado 1	2.0
2192.500	1762.500	-65.146220	-10.421032		Grado 1	2.0
1319.500	2049.500	-65.384578	-10.499393		Grado 1	2.0
1216.500	1903.500	-65.412701	-10.459530		Grado 1	2.0
1647.500	2170.500	-65.295023	-10.532430		Grado 1	2.0
1376.500	2182.500	-65.369015	-10.535707		Grado 1	2.0
1514.500	1962.500	-65.331337	-10.475639		Grado 1	2.0
1642.500	1159.500	-65.296388	-10.256393		Grado 1	2.0
1749.500	1082.500	-65.267174	-10.235369		Grado 1	2.0
1765.500	1069.500	-65.262805	-10.231820		Grado 1	2.0
1750.500	1071.500	-65.266901	-10.232366		Grado 1	2.0

Figura 147. Tabla de pines de zona de grado 1 clasificados

En este caso se obtiene una tasa de acierto de 20/20, es decir, un 100%.

6.3.5. Grado 2

A continuación, se muestra una escena de la imagen en visualización color en la que se ha realizado la recogida de pines para la zona de grado 2 (Figura 148):




Figura 148. Pines seleccionados en zona de grado 2

Se obtiene la siguiente tabla de pines (Figura 149):

1638.500	1401.500	-65.297480	-10.322467		Grado 2
1623.500	1391.500	-65.301576	-10.319737		Grado 2
1621.500	1378.500	-65.302122	-10.316187		Grado 2
1646.500	1309.500	-65.295296	-10.297348		Grado 2
2198.500	1837.500	-65.144581	-10.441510		Grado 2
2191.500	1835.500	-65.146493	-10.440964		Grado 2
2189.500	1841.500	-65.147039	-10.442602		Grado 2
2023.500	1735.500	-65.192362	-10.413661		Grado 2
2021.500	1731.500	-65.192908	-10.412568		Grado 2
2108.500	1818.500	-65.169154	-10.436322		Grado 2
2353.500	1724.500	-65.102261	-10.410657		Grado 2
2339.500	1713.500	-65.106084	-10.407654		Grado 2
2356.500	1713.500	-65.101442	-10.407654		Grado 2
2419.500	1817.500	-65.084241	-10.436049		Grado 2
2480.500	1681.500	-65.067586	-10.398917		Grado 2
2471.500	1677.500	-65.070043	-10.397825		Grado 2
2483.500	1673.500	-65.066767	-10.396732		Grado 2
1988.500	1737.500	-65.201919	-10.414207		Grado 2
1931.500	1724.500	-65.217481	-10.410657		Grado 2
2008.500	1680.500	-65.196458	-10.398644		Grado 2

Figura 149. Tabla de pines de zona de grado 2

Al pasar la tabla de pines (Figura 149) a la imagen clasificada se obtiene lo siguiente (Figura 150):




Figura 150. Transición de pines de zona de grado 2 de imagen original a imagen clasificada

Se obtiene la siguiente clasificación de pines (Figura 151):

1638.500	1401.500	-65.297480	-10.322467		Grado 2	3.0
1623.500	1391.500	-65.301576	-10.319737		Grado 2	3.0
1621.500	1378.500	-65.302122	-10.316187		Grado 2	NaN
1646.500	1309.500	-65.295296	-10.297348		Grado 2	3.0
2198.500	1837.500	-65.144581	-10.441510		Grado 2	2.0
2191.500	1835.500	-65.146493	-10.440964		Grado 2	2.0
2189.500	1841.500	-65.147039	-10.442602		Grado 2	3.0
2023.500	1735.500	-65.192362	-10.413661		Grado 2	2.0
2021.500	1731.500	-65.192908	-10.412568		Grado 2	3.0
2108.500	1818.500	-65.169154	-10.436322		Grado 2	2.0
2353.500	1724.500	-65.102261	-10.410657		Grado 2	3.0
2339.500	1713.500	-65.106084	-10.407654		Grado 2	3.0
2356.500	1713.500	-65.101442	-10.407654		Grado 2	3.0
2419.500	1817.500	-65.084241	-10.436049		Grado 2	3.0
2480.500	1681.500	-65.067586	-10.398917		Grado 2	2.0
2471.500	1677.500	-65.070043	-10.397825		Grado 2	3.0
2483.500	1673.500	-65.066767	-10.396732		Grado 2	2.0
1988.500	1737.500	-65.201919	-10.414207		Grado 2	2.0
1931.500	1724.500	-65.217481	-10.410657		Grado 2	2.0
2008.500	1680.500	-65.196458	-10.398644		Grado 2	3.0

Figura 151. Tabla de pines de zona de grado 2 clasificados

En este caso se obtiene una tasa de acierto de 11/20, es decir, un 55%.

6.3.6. Grado 3

A continuación, se muestra una escena de la imagen en visualización color en la que se ha realizado la recogida de pines para la zona de grado 3 (Figura 152):




Figura 152. Pines seleccionados en zona de grado 3

Se obtiene la siguiente tabla de pines (Figura 153):

1442.500	1589.500	-65.350995	-10.373798		Grado 3
1447.500	1579.500	-65.349630	-10.371067		Grado 3
1772.500	1588.500	-65.260894	-10.373525		Grado 3
1904.500	1580.500	-65.224853	-10.371340		Grado 3
1919.500	1578.500	-65.220758	-10.370794		Grado 3
1906.500	1538.500	-65.224307	-10.359873		Grado 3
1906.500	1573.500	-65.224307	-10.369429		Grado 3
2072.500	1504.500	-65.178984	-10.350590		Grado 3
2071.500	1500.500	-65.179257	-10.349498		Grado 3
1988.500	1459.500	-65.201919	-10.338303		Grado 3
1974.500	1444.500	-65.205741	-10.334208		Grado 3
1974.500	1439.500	-65.205741	-10.332842		Grado 3
2017.500	1416.500	-65.194001	-10.326563		Grado 3
2058.500	1440.500	-65.182806	-10.333115		Grado 3
1975.500	1490.500	-65.205468	-10.346767		Grado 3
1967.500	1463.500	-65.207652	-10.339395		Grado 3
2019.500	1482.500	-65.193454	-10.344583		Grado 3
2076.500	1432.500	-65.177892	-10.330931		Grado 3
2078.500	1406.500	-65.177345	-10.323832		Grado 3
2038.500	1402.500	-65.188267	-10.322740		Grado 3

Figura 153. Tabla de pines de zona de grado 3

Al pasar la tabla de pines (Figura 153) a la imagen clasificada obtenemos lo siguiente (Figura 154):




Figura 154. Transición de pines de zona de grado 3 de imagen original a imagen clasificada

Se obtiene la siguiente clasificación de pines (Figura 155):

1442.500	1589.500	-65.350995	-10.373798		Grado 3	4.0
1447.500	1579.500	-65.349630	-10.371067		Grado 3	NaN
1772.500	1588.500	-65.260894	-10.373525		Grado 3	4.0
1904.500	1580.500	-65.224853	-10.371340		Grado 3	4.0
1919.500	1578.500	-65.220758	-10.370794		Grado 3	4.0
1906.500	1538.500	-65.224307	-10.359873		Grado 3	3.0
1906.500	1573.500	-65.224307	-10.369429		Grado 3	4.0
2072.500	1504.500	-65.178984	-10.350590		Grado 3	4.0
2071.500	1500.500	-65.179257	-10.349498		Grado 3	NaN
1988.500	1459.500	-65.201919	-10.338303		Grado 3	2.0
1974.500	1444.500	-65.205741	-10.334208		Grado 3	3.0
1974.500	1439.500	-65.205741	-10.332842		Grado 3	4.0
2017.500	1416.500	-65.194001	-10.326563		Grado 3	4.0
2058.500	1440.500	-65.182806	-10.333115		Grado 3	4.0
1975.500	1490.500	-65.205468	-10.346767		Grado 3	4.0
1967.500	1463.500	-65.207652	-10.339395		Grado 3	4.0
2019.500	1482.500	-65.193454	-10.344583		Grado 3	3.0
2076.500	1432.500	-65.177892	-10.330931		Grado 3	2.0
2078.500	1406.500	-65.177345	-10.323832		Grado 3	2.0
2038.500	1402.500	-65.188267	-10.322740		Grado 3	2.0

Figura 155. Tabla de pines de zona de grado 3 clasificados

En este caso se obtiene una tasa de acierto de 11/20, es decir, un 55%.

6.3.7. Análisis de resultados

Tras haberse estudiado los resultados, se puede llegar a varias conclusiones parciales, calculando los errores de la clasificación.

Para realizar un análisis preciso se construye la matriz de error y se calculan la precisión global, las de usuario y productor (error por comisión y omisión), y el coeficiente Kappa [46]. La precisión global se calcula como el número total de pines de test correctamente clasificados dividido por el número total de pines test. El índice Kappa mide el acuerdo que existe por encima del esperado por azar, es decir es el cociente entre la diferencia entre precisión observada menos la esperada partido por 1 menos la precisión esperada. El error por omisión aparece cuando un píxel que pertenece a una determinada categoría, no resulta clasificado en ella (falso negativo). Se plantea como riesgo del productor. Sin embargo, el error por comisión ocurre cuando un píxel resulta clasificado en una categoría y en realidad pertenece a otra (falso positivo). En este caso se plantea como riesgo del usuario. Los resultados se muestran a continuación (Figura 156).

	Precisión global	83,33%	Índice Kappa	0,78%
	Errores por omisión (%)		Errores por comisión (%)	
Clase Urbano	10		0	
Clase Grado 3	45		15,4	
Clase Grado 2	45		21,4	
Clase Grado 1	0		37,5	
Clase Grado 0	0		0	
Clase Agua	0		0	

Figura 156. Errores y precisión en la clasificación

En primer lugar, parece que tanto las áreas de agua como de zona urbana, son clasificadas con una elevada precisión entre el 90 y el 100%. Esto se debe a que evidentemente, son las áreas que son más diferenciables de las zonas de vegetación de las imágenes debido a su respuesta espectral. Por otro lado, están las áreas del grado de deforestación. Como se ha podido observar, estas áreas fluctúan un poco más respecto al resto, por el hecho de que, esencialmente, se está estudiando el mismo tipo de cobertura (vegetal) y los valores del NDVI frontera elegidos para limitar las clases, no distan tanto los unos de los otros. Esto se puede ver de manera más destacada en las clases desde el Grado 1 al Grado 3. Sin embargo, si se revisan los errores calculados (Figura 156) se puede ver como las áreas que se han clasificado de manera errónea para las áreas deforestadas, no distan mucho de su clase original, es decir, para las áreas de grado 3, se puede ver que las áreas que ha clasificado erróneamente las clasifica con la clase más parecida a la suya, la de Grado 2, y pasa lo mismo con las otras áreas.

Cabe mencionar que, para el paso de validación de los datos, se ha decidido presentar únicamente en este documento, los resultados para una de las fechas, dado que se ha realizado ese mismo proceso una vez por cada una de las imágenes, y no ha proporcionado información relevante y diferente a la obtenida en este caso.

7. Conclusiones

En primer lugar, se exponen las principales dificultades que se han presentado con las imágenes, así como su resolución. Como ya se ha mencionado durante el desarrollo del trabajo, se han descargado las imágenes de dos plataformas: Open Access Hub (para Sentinel) y USGS (para Landsat).

En cuanto a la aplicación para Sentinel, se valora tanto la interfaz, como el acceso a las imágenes de manera positiva, resultando ser muy intuitivo. Además, con la gran cantidad de imágenes de las que disponen hay gran variedad a la hora de seleccionar. No obstante, el problema principal que se encontró durante la selección fue que la mayoría de las imágenes de Sentinel 2 estaban en estado *offline*, y había que realizar un pedido previo con el consiguiente retraso en el envío. Esto supuso que, el periodo de selección de imágenes fuera un periodo más largo de lo previsto en el plan inicial de trabajo, pues la plataforma no responde con el tiempo de espera. No obstante, el tiempo de espera fue entre 24 y 48 horas. Pero, en general, se considera que Open Access Hub es una buena herramienta para descargar imágenes.

Otro problema que surgió fue que, para la zona seleccionada, no existían suficientes imágenes con poca cobertura nubosa que permitieran realizar el estudio de manera óptimamente previsto. Esto llevó al hecho de que debieran escogerse imágenes con cierta cobertura nubosa. No obstante, la zona a estudiar era la que se mostraba como un objetivo prioritario de estudio siguiendo un planteamiento de objetivos de desarrollo sostenible.

Por otro lado, se utilizó la herramienta de USGS. Esta herramienta resultó, en términos de interfaz, un poco menos amigable que la de Open Access Hub y, en general, se evaluó como de respuesta más lenta. No obstante, disponía de una gran cantidad de imágenes de la zona exacta que se quería estudiar. La imagen original, al ser mucho más grande que la que proveía Open Access Hub resultaba más fácil a la hora de poder recortarla, no obstante, se realizó el subset en SNAP y ello condujo a un mayor costo de proceso. Un inconveniente de descarga de las imágenes desde USGS fue que, las imágenes debían ser solicitadas y descargadas desde una aplicación externa (Bulk). Esta aplicación, además de resultar bastante poco intuitiva, no disponía de apenas documentación que obligó a llevar una búsqueda para poder seguir los pasos de manera sencilla. Resultó ser muy lenta para descargar finalmente las imágenes. Como se descargaron las 6 imágenes de Landsat desde aquí, se puede indicar que se tardó aproximadamente 1 hora en descargarlas todas.

Las imágenes descargadas, a pesar de lo mencionado anteriormente, resultan adecuadas para realizar el estudio planificado. El único problema fue que las dos imágenes de Sentinel 2 más actuales, contenían un cierto porcentaje de superficie con nubes, lo que llevaba a pensar que podían resultar un problema a la hora de utilizar el algoritmo con un buen resultado. Sin embargo, finalmente sí se pudo clasificar de manera precisa tanto las nubes como su sombra y eliminar la posible confusión con otras clases. Sin embargo, el inconveniente principal era inescusable en el hecho de que esas nubes podían tapar píxeles que se restarían a los porcentajes asignados a esas clases. No obstante, habiendo realizado el estudio, se observa que, tanto las nubes como sus sombras, no generan un error suficientemente representativo para que supusieran un problema a la hora de analizar temporalmente, el crecimiento de deforestación o pérdida de vegetación.

En cuanto a la herramienta SNAP, ha sido la herramienta principal que se ha utilizado durante el desarrollo del trabajo y es donde se ha ejecutado el algoritmo de bosques aleatorios. De la herramienta, se puede concluir que se trata de una muy buena herramienta para el estudio y procesado de imágenes registradas por satélites. Dispone de muchísimas funcionalidades como: el poder generar imágenes según bandas determinadas (así como el NDVI, subsets o imágenes remuestreadas), el muestreo de información detallada (mediante histogramas, análisis estadístico, información por píxel...), la geolocalización de las imágenes, para poder desplazarse a la vez en varias imágenes en las mismas zonas, así como todos los algoritmos de clasificación que dispone (tanto supervisados como no supervisados). La herramienta no ha supuesto demasiados problemas y, solo en una ocasión hubo que reiniciarla cuando se intentaron borrar más de 20 pines a la vez. Los tiempos de ejecución son todos extremadamente rápidos, por ejemplo, a la hora de hacer el *resampling* (prácticamente instantáneo), al ejecutar el algoritmo de bosques aleatorios (unos 15 segundos en total), al abrir/cerrar o mover imágenes o incluso al realizar los subsets. Sin embargo, donde sí que la aplicación resultaba ir más lenta, era en el *reprojection*, donde, normalmente tardaba en torno a 1 minuto.

Analizando los errores que presentó SNAP durante el estudio, se podía indicar que no fueron muchos, aunque en algunos casos, decisivos para la investigación. En primer lugar, hubo problemas a la hora de guardar la sesión. Se desconoce si se trataba de un problema de rutas o un problema de que los archivos no se estaban guardando bien, pero resultó ser una inconveniencia ya que hubo que dejar el ordenador encendido durante 5 días para que no se perdiera el progreso hasta que se pudo solucionar. Por otro lado, a la hora de ejecutar el algoritmo de bosques aleatorios surgieron dos errores principales: “*index out of bounds*”, para lo cual hubo que consultar en foros que se debían de resmuestrear y reproyectar las imágenes, y otro error en relación a la cantidad de bandas que se aplicaban. Resulta que, los archivos de tanto Sentinel como Landsat, en los dataset originales, disponen de bandas con diferente dimensión de la imagen, y, al ejecutar el algoritmo por defecto, se estaban utilizando todas. Se deben elegir previamente las bandas adecuadas para el estudio programado. Aparte de lo comentado, la utilización de SNAP no supuso ningún otro problema adicional.

En cuanto al algoritmo de bosques aleatorios de SNAP, hay que concluir que, a pesar de los problemas mencionados anteriormente, resulta un algoritmo que permite la clasificación con buenos resultados. La precisión con la que clasifica las áreas de las imágenes resulta bastante buena. Es cierto que las áreas que mejor clasifica son las que tienen los atributos más diferenciables como el grado 0, el agua o la zona urbana, mientras que las zonas de grados de deforestación intermedios se podían confundir. Además, por lo comentado anteriormente, acerca de la cobertura nubosa, las imágenes utilizadas que se han estudiado, no son las más sencillas para clasificar, debido, además, a su complejidad y gran tamaño. Por lo que se puede decir que el algoritmo de bosques aleatorios es un algoritmo fiable y que necesita de poca información para poder clasificar una imagen entera.

Durante el desarrollo del TFG, me he visto involucrado con muchos conceptos, herramientas y problemas que me he ido encontrando. Por tanto, he adquirido una serie de conocimientos y entendimiento para poder describir adecuadamente mi experiencia a lo largo del trabajo.

En general, he aprendido bastante sobre el procesado y análisis de imágenes registradas mediante teledetección. También tengo que considerar mi aprendizaje relativo a la utilización de la herramienta de SNAP. Considero que esta investigación me ha servido, no solo para afianzar los conocimientos aprendidos sino también para poder abarcar otros grandes proyectos en un futuro relacionados con los objetivos de desarrollo sostenible. Ha supuesto un desafío el adentrarme en un tema que del que conocía poco, pero, considero que he adquirido cierto grado de competencias en este ámbito de investigación.

8. Bibliografía

- [1]. *Información programa Copernicus*, Instituto Geográfico Nacional,
Tomado de: <https://www.ign.es/web/ign/portal/copernicus/presentacion> de:
- [2]. *Información adicional programa Copernicus (acceso a servicios)*, Copernicus,
Tomado de: <https://www.copernicus.eu/es>
- [3]. *Información servicio Copernicus “Vigilancia atmosférica”*, Copernicus,
Tomado de: <https://atmosphere.copernicus.eu/>
- [4]. *Información servicio Copernicus “Cambio climático”*, Copernicus,
Tomado de: <https://cds.climate.copernicus.eu/#!/home>
- [5]. *Información servicio Copernicus “Ayuda a la acción externa”*, Copernicus,
Tomado de: <https://sea.security.copernicus.eu/>
- [6]. *Información servicio Copernicus “Vigilancia marítima”*, Copernicus,
Tomado de: <http://www.emsa.europa.eu/copernicus.html>
- [7]. *Información servicio Copernicus “Vigilancia de fronteras”*, Copernicus,
Tomado de: <http://frontex.europa.eu/news/frontex-to-implement-border-surveillance-services-as-part-of-copernicus-Z1r4A0>
- [8]. *Información servicio Copernicus “Seguridad”*, Copernicus,
Tomado de: <https://www.copernicus.eu/es/servicios/seguridad>
- [9]. *Información servicio Copernicus “Emergencias”*, Copernicus,
Tomado de: emergency.copernicus.eu.
- [10]. *Detalles de información de previsiones de inundaciones*, EFAS Portal de la Comisión Europea de Inundaciones,
Tomado de: www.efas.eu.
- [11]. *Información de incendios forestales en Europa*, EFFIS Portal de Sistema de Información de la Comisión Europea de Incendios,
Tomado de: effis.jrc.ec.europa.eu.
- [12]. *Información sobre los distintos tipos de satélites*, Carlos P. Ruiz del Dpto. de Ingeniería Cartográfica,
Tomado de: <https://www.slideshare.net/ford81/tipos-de-sensores-40465788>
- [13]. *Información general del escáner multiespectral*, Karen Schuckman, John A. Dutton de la Universidad de Pensilvania,
Tomado de: <https://www.e-education.psu.edu/geog480/node/494>
- [14]. *Especificaciones escáner multiespectral Landsat*,
Tomado de: https://en.wikipedia.org/wiki/Multispectral_Scanner

- [15]. *Especificaciones cámara Sentinel2, Agencia Espacial Europea (ESA)*,
Tomado de: https://www.esa.int/Space_in_Member_States/Spain/La_camara_de_Sentinel-2
- [16]. *Detalles de teledetección, Earth Observing System*,
Tomado de: <https://eos.com/es/blog/teledeteccion/>
- [17]. *Satélites de teledetección de recursos naturales*,
Tomado de: [http://concurso.cnice.mec.es/cnice2006/material121/unidad3/sat_td.htm#:~:text=Los%20sat%C3%A9lites%20Landsat%20disponen%20de,el%20MSS%20\(6%20bits\).](http://concurso.cnice.mec.es/cnice2006/material121/unidad3/sat_td.htm#:~:text=Los%20sat%C3%A9lites%20Landsat%20disponen%20de,el%20MSS%20(6%20bits).)
- [18]. *Información sobre algoritmos de clasificación, Redacción España*,
Tomado de: <https://agenciab12.com/noticia/que-son-regresion-clasificacion-machine-learning#:~:text=El%20aprendizaje%20no%20supervisado%20est%C3%A1,m%C3%A9todo%20exploratorio%20o%20de%20an%C3%A1lisis.>
- [19]. *Información sobre machine Learning y tipos de algoritmos, Ed Burns*,
Tomado de: [https://www.techtarget.com/searchenterpriseai/definition/machine-learning-ML#:~:text=Machine%20learning%20\(ML\)%20is%20a,to%20predict%20new%20output%20values.](https://www.techtarget.com/searchenterpriseai/definition/machine-learning-ML#:~:text=Machine%20learning%20(ML)%20is%20a,to%20predict%20new%20output%20values.)
- [20]. *Información sobre machine learning y tipos de algoritmos, Paloma Recuero de los Santos*,
Tomado de: <https://empresas.blogthinkbig.com/que-algoritmo-elegir-en-ml-aprendizaje/>
- [21]. *Información sobre machine learning y tipos de algoritmos*,
Tomado de: <https://interactivechaos.com/es/manual/tutorial-de-machine-learning/aplicaciones>
- [22]. *Métodos bagging y boosting*,
Tomado de: <https://machinelearningparatodos.com/cual-es-la-diferencia-entre-los-metodos-de-bagging-y-los-de-boosting/>
- [23]. *Out of bag, Johanna Orellana Alvear*,
Tomado de: <https://bookdown.org/content/2031/ensambladores-random-forest-parte-i.html#random-forest>
- [24]. *Optimización mediante hyper-parámetros, Will Koehrsen*,
Tomado de: <https://towardsdatascience.com/hyperparameter-tuning-the-random-forest-in-python-using-scikit-learn-28d2aa77dd74>
- [25]. *Información sobre algoritmo random forest, Leo Breiman del departamento de estadística de la Universidad de California, Berkeley*,

- Tomado de: <https://www.stat.berkeley.edu/~breiman/randomforest2001.pdf>
- [26]. *Información sobre algoritmo random forest*, Jose Martínez Heras,
Tomado de: <https://www.iartificial.net/random-forest-bosque-aleatorio/>
- [27]. *Información sobre algoritmo random forest*, Leo Breiman del departamento de estadística de la Universidad de California, Berkeley,
Tomado de: <https://link.springer.com/content/pdf/10.1023/A:1010933404324.pdf>
- [28]. *Información sobre algoritmo random forest*,
Tomado de: [https://es.wikipedia.org/wiki/Random_forest#Caracter%C3%ADsticas_\(o_rasgos\)_y_Ventajas](https://es.wikipedia.org/wiki/Random_forest#Caracter%C3%ADsticas_(o_rasgos)_y_Ventajas)
- [29]. *Información sobre algoritmo random forest*,
Tomado de: http://games.cmm.uchile.cl/media/uploads/posts/RF_presentation.pdf
- [30]. *Información sobre algoritmo random forest*,
Tomado de: <https://medium.com/analytics-vidhya/mathematics-behind-random-forest-and-xgboost-ea8596657275>
- [31]. *Clasificación de métodos de machine learning*, Jose Martínez Heras,
Tomado de: <https://www.iartificial.net/clasificacion-o-regresion/>
- [32]. *Información sobre el Índice Gini*, Johanna Orellana Alvear,
Tomado de: <https://bookdown.org/content/2031/arboles-de-decision-parte-i.html>
- [33]. *Información sobre SciKit*,
Tomado de: <https://en.wikipedia.org/wiki/Scikit-learn>
- [33]. *Información sobre SciKit, página oficial de SciKit*,
Tomado de: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>
- [33]. *Información sobre SciKit*, Avinash Navlani,
Tomado de: <https://www.datacamp.com/community/tutorials/random-forests-classifier-python>
- [34]. *Información sobre Landsat 1*, USGS,
Tomado de: [Landsat 1 | U.S. Geological Survey \(usgs.gov\)](https://landsat1.usgs.gov/)
- [35]. *Información sobre Landsat 2*, USGS,
Tomado de: [Landsat 2 | U.S. Geological Survey \(usgs.gov\)](https://landsat2.usgs.gov/)
- [36]. *Información sobre Landsat 3*, USGS,

- Tomado de: [Landsat 3 | U.S. Geological Survey \(usgs.gov\)](https://www.usgs.gov/landsat)
- [37]. *Información sobre Landsat 4, USGS,*
Tomado de: [Landsat 4 | U.S. Geological Survey \(usgs.gov\)](https://www.usgs.gov/landsat)
- [38]. *Información sobre Landsat 5, USGS,*
Tomado de: [Landsat 5 | U.S. Geological Survey \(usgs.gov\)](https://www.usgs.gov/landsat)
- [39]. *Información sobre Landsat 6, USGS,*
Tomado de: [Landsat 6 | U.S. Geological Survey \(usgs.gov\)](https://www.usgs.gov/landsat)
- [40]. *Información sobre Landsat 7, USGS,*
Tomado de: [Landsat 7 | U.S. Geological Survey \(usgs.gov\)](https://www.usgs.gov/landsat)
- [41]. *Información sobre Landsat 8, USGS,*
Tomado de: [Landsat 8 | U.S. Geological Survey \(usgs.gov\)](https://www.usgs.gov/landsat)
- [42]. *Información sobre Landsat 9, USGS,*
Tomado de: [Landsat 9 | U.S. Geological Survey \(usgs.gov\)](https://www.usgs.gov/landsat)
- [43]. Debie, E and Shafi, K. 2019. __Pattern Anal Applic 22, 519–536.
<https://doi.org/10.1007/s10044-017-0649-0>
- [44]. H. Hashim, Z. A. Latif, N. A. Adnan, 2019, Urban Vegetation Classification with NVDI Threshold Value Method with Very High Resolution (VHR) Pleiades Imagery,
<https://www.int-arch-photogramm-remote-sens-spatial-inf-sci.net/XLII-4-W16/237/2019/isprs-archives-XLII-4-W16-237-2019.pdf>
- [45]. Prof. Shaun R. Levick, <https://www.geospatialecology.com>
- [46] R. G. Congalton and K. Green, Assessing the Accuracy of Remotely Sensed Data - Principles and Practices. 2 nd . ed. NY, USA, CRC Press, Taylor & Francis Group, 2009, pp. 159–170.

9. Anexo

Definiciones

[1]:Geolocalizar:Determinar la ubicación geográfica de alguien o de algo valiéndose de medios técnicos avanzados, como el GPS.

[2]:Forzamiento climático: es la diferencia entre la insolación (luz solar) absorbida por la Tierra y la energía irradiada de vuelta al espacio.

[3]:Biogeoquímico: las interacciones que se establecen entre los seres vivos y los compuestos químicos.

[4]:Overfitting: situación en la que un algoritmo rinde mejor con los datos de entrenamiento que con los nuevos.

[5]:Cluster: grupo de cosas o personas similares situadas de manera cercana los unos a los otros.

[6]:NumPy, SciPy: son librerías de Python de carácter científico que aprovisiona de fórmulas o algoritmos de optimización y más conceptos relacionados con el tema.

[7]:Teselas: divisiones de imágenes por el barrido del satélite.

Este documento esta firmado por



Firmante	CN=tfgm.fi.upm.es, OU=CCFI, O=ETS Ingenieros Informaticos - UPM, C=ES
Fecha/Hora	Mon May 30 15:33:32 CEST 2022
Emisor del Certificado	EMAILADDRESS=camanager@etsiinf.upm.es, CN=CA ETS Ingenieros Informaticos, O=ETS Ingenieros Informaticos - UPM, C=ES
Numero de Serie	561
Metodo	urn:adobe.com:Adobe.PPKLite:adbe.pkcs7.sha1 (Adobe Signature)