



Universidad
de Alcalá

Caracterización de la Severidad de los Incendios Forestales: Caso de Estudio en la Sierra de la Culebra (2022)

Characterization of Wildfire Severity: A Case Study in the Sierra de la Culebra (2022)

Máster Universitario en Tecnologías de la Información Geográfica

Presentado por:

D. Jaime Villalón Demmer

Dirigido por:

Dra. Patricia Oliva Pavón

Alcalá de Henares, a de de

Índice

1. Introducción	1
2. Materiales y métodos	2
2.1. Área de estudio.....	2
2.2. Flujo metodológico	4
2.3. Datos	4
2.3.1. Datos de campo	4
2.3.2. Datos de satélite	6
2.4. Técnicas y métodos empleados.....	6
2.4.1. Cálculo de índices espectrales	6
2.4.2. Sensibilidad a la fecha post-incendio.....	8
2.4.3. Análisis de la influencia de los estratos de vegetación	8
4. Resultados.....	9
4.1 Análisis de índices diferenciales.....	9
4.2 Análisis de la importancia de los estratos	13
5. Discusión.	13
6. Conclusiones.....	16
7. Referencias bibliográficas	17

Índice de figuras

Figura 1. Mapa de los LICs afectados durante los incendios.	3
Figura 2. Mapa de localización de las parcelas seleccionadas para los índices de campo. 3	
Figura 3. Diagrama de flujo de trabajo.	4
Figura 4. Evolución de los índices NDVI y NBR.....	9
Figura 5. Distribución de la severidad en los índices calculados.	10

Índice de tablas

Tabla 1. Ejemplos de las zonas de toma de datos.	5
Tabla 2. Fechas tomadas para las imágenes Sentinel-2.	6
Tabla 3. Índices calculados.	7
Tabla 4. Correlación entre los índices satelitales y el CBI.....	11
Tabla 5. Correlación entre los índices satelitales y el GeoCBI.....	12
Tabla 6. Relevancia entre los estratos del GeoCBI y los índices satelitales.	13
Tabla 7. Importancia de las variables de los índices de campo para cada índice satelital. 14	
Tabla 1 Anexo I. Correlación entre el índice CBI y las variables de cada estrato.	23
Tabla 2 Anexo I. Correlación entre el índice CBI y las variables de cada estrato.	24

Caracterización de la Severidad de los Incendios Forestales: Caso de Estudio en la Sierra de la Culebra (2022)

JAIME VILLALÓN DEMMER

¹jaime.villalon@edu.uah.es

RESUMEN

Los incendios forestales extremos son una amenaza creciente en el contexto del cambio climático. El incendio de Sierra de la Culebra en Zamora ocurrido en 2022 supone una interesante área de estudio debido a las características diversas de severidad y cantidad de biomasa. Este trabajo evalúa la capacidad de estimar la severidad de los incendios utilizando diferentes índices espectrales (dNBR, RdNBR, RBR) y de campo (CBI, GeoCBI), a partir de la aplicación de modelos Random Forest. Los resultados destacan que el GeoCBI tiene la mayor correlación con índices satelitales con el dNBR ($R^2 = 0.71$) y que los estratos arbóreos superiores e intermedios son los más influyentes en la evaluación de severidad. Asimismo, se ha confirmado que las fechas cercanas al incendio son clave para obtener mediciones precisas de severidad de quemado. Este análisis nos ha permitido establecer cuáles son los índices espectrales con mejor capacidad de estimar la severidad de quemado y cuáles son los estratos que están marcando el valor del índice de severidad en campo.

Palabras clave: Severidad, incendios forestales, CBI, GeoCBI, índices de severidad, Sentinel-2

Characterization of Wildfire Severity: A Case Study in the Sierra de la Culebra (2022)

ABSTRACT

Extreme wildfires are an increasing threat in the context of climate change. The Sierra de la Culebra wildfire in Zamora, which occurred in 2022, represents an interesting area of study due to its diverse characteristics in terms of severity and biomass quantity. This work evaluates the ability to estimate fire severity using different spectral indices (dNBR, RdNBR, RBR) and field indices (CBI, GeoCBI), applying Random Forest models. The results highlight that GeoCBI has the highest correlation with satellite indices, particularly with dNBR ($R^2 = 0.71$), and that the upper and intermediate arboreal strata are the most influential in severity assessment. Furthermore, it has been confirmed that dates close to the fire event are crucial for obtaining accurate measurements of burn severity. This analysis has allowed us to determine which spectral indices have the best capability to estimate burn severity and which strata significantly influence the field severity index value.

Keywords: Severity, wildfires, CBI, GeoCBI, severity indices, Sentinel-2

1. Introducción

El cambio climático representa una amenaza global que afecta tanto a los sistemas naturales como a las actividades humanas. Su aceleración, impulsada por actividades antrópicas, ha incrementado significativamente la magnitud y frecuencia de fenómenos adversos que impactan el medio físico, y afectan a las actividades económicas (MITECO, 2021). En este contexto, los incendios forestales han emergido como un fenómeno crítico, no solo por los daños inmediatos que ocasionan en los ecosistemas, sino también por su influencia en los patrones climáticos a través de la liberación masiva de emisiones de carbono y su interacción con el ciclo global del carbono. Instituciones internacionales, como la ONU (UNEP, 2022) y la Unión Europea (European Commission, 2024), junto con investigaciones recientes (de Groot et al., 2013; Liu et al., 2013; Burson et al., 2023), subrayan la urgencia de integrar estrategias de gestión del territorio que aborden esta problemática multifacética.

En España, esta problemática es particularmente relevante debido a la vulnerabilidad del paisaje mediterráneo y a las transformaciones del régimen de incendios causadas por el cambio climático (Urbietta et al., 2016). Durante el periodo 2022-2023, se quemaron aproximadamente 270 000 ha, siendo el año con mayor impacto sobre la superficie forestal de la década, según datos oficiales del Ministerio para la Transición Ecológica (MITECO, 2022). A esta elevada superficie quemada se suma el preocupante aumento en la intensidad de los incendios forestales, caracterizados por un comportamiento extremo e impredecible observándose en grandes incendios con más de 500 ha, como fue el incendio de Sierra de la Culebra, caso de estudio del presente trabajo que afectó un total de más de 50.000 ha en 2022 (BOE, 2024).

En la actualidad, gracias al desarrollo de sensores avanzados combinados con sistemas de monitoreo y análisis de datos, se ha mejorado la detección y la prevención de incendios. Estas nuevas tecnologías se han convertido en un factor determinante, ya que ayudan a la gestión forestal y facilitan la coordinación de los recursos en el proceso de extinción, optimizando la protección de los ecosistemas en los que se desarrollan (Arantec, 2021).

Los datos de satélite permiten el estudio de superficies de forma remota, limitando el empleo de recursos para la toma de datos en campo (Lentile *et al.* 2006). Los datos de satélite han sido utilizados para mapear y cuantificar el daño provocado por los incendios, generando mapas de distribución de severidad (French et al., 2008) Sin embargo, pese a que el concepto de severidad de quemado se ha empleado ampliamente desde la última década, aún no existe un consenso que establezca una definición clara ni una metodología estándar para su cuantificación ya que la severidad es diferente en función de la vegetación afectada (Han et al., 2021; Keely, 2009). Con el Sistema de Monitoreo e Inventariado de los Efectos del Fuego (FIREMON) se establece la definición de severidad de quemado como el grado de cambio ambiental acumulativo causado por el fuego, abarcando alteraciones físicas, químicas y estructurales en el paisaje, tales como cambios en el suelo, conversión de la vegetación en carbono inorgánico y transformaciones que generan nuevos microclimas y ensamblajes de especies (Lutes et al., 2006).

Los índices espectrales derivados de la teledetección han sido herramientas clave para evaluar la severidad de quemado de forma más objetiva y eficiente. La diferencia del Índice de Quemado Normalizado (dNBR) se ha presentado como uno de los índices más robustos por su combinación entre el Infrarrojo Cercano (NIR) y el Infrarrojo de Onda Corta (SWIR) (Delegido et al., 2018), pero hay otros índices de severidad como el Índice de Área quemado (BAI), el Índice de Perturbaciones (DI) o el índice de Recuperación Forestal (FRI) (Flores et al., 2021). Pese a la cantidad de índices de severidad existentes, los más utilizados son el dNBR y sus modificaciones, el RdNBR y el RBR (Delcourt et al., 2021).

Estos índices pueden ser aplicados en diferentes programas de monitoreo de incendios, como el programa Monitoring Trends in Burn Severity (MTBS) dirigido por el USGS y la NASA (MTBS, 2018), que genera mapas de severidad de incendios utilizando imágenes satelitales, como las de Landsat, para evaluar los impactos de los incendios en grandes áreas a través de diferentes índices como el dNBR o el RdNBR. Los resultados proporcionan información clave sobre las tendencias de severidad, ayudando en la comprensión de los efectos inmediatos y a largo plazo,

y en la planificación de la gestión y restauración de ecosistemas post-incendio (Eidenshink et al., 2007).

Conociendo la amplia aplicación que tienen los índices espectrales, estos deben ser evaluados por diferentes índices de campo para dar una estimación más aproximada de la severidad (Keeley, 2009). Existen muchas aproximaciones a la medición de la severidad en campo, desde mediciones del consumo de biomasa hasta cambios en propiedades del suelo, como la repelencia al agua, la erodibilidad y la disponibilidad de nutrientes (Morgan et al., 2014). El índice más utilizado para el cálculo de la severidad es el Índice Compuesto de Quemado (CBI), que mide de manera semi-cuantitativa la severidad del fuego en comunidades forestales al evaluar los cambios producidos en un área dividida en cinco estratos, abarcando desde el suelo hasta el dosel superior. Este índice considera atributos como el consumo de hojarasca, la alteración del follaje y la altura del carbón, asignando puntuaciones numéricas por estrato (Saulino et al. 2020). Se han elaborado diferentes modificaciones de este índice, entre las que destacan el CBI estructurado geométricamente (GeoCBI), donde se incluye la influencia de la cobertura vegetal sobre los estratos (de Santis y Chuvieco, 2009).

Este estudio tiene como objetivo evaluar la capacidad de diferentes índices espectrales para caracterizar la severidad de los incendios ocurridos en la Sierra de la Culebra en 2022. Para ello, se analiza la correlación entre los índices de campo, CBI y GeoCBI, y los índices espectrales (dNDVI, dNBR, RdNBR y RBR) aplicando una aproximación con Random Forest. Además, se evalúa la importancia de las variables que componen los índices de campo sobre la respuesta espectral observada en los índices espectrales en función del nivel de severidad, con el propósito de determinar qué estratos vegetales tienen mayor influencia sobre la severidad.

2. Materiales y métodos

2.1. Área de estudio

El área de estudio se localiza dentro de los márgenes de los incendios acaecidos en la provincia de Zamora el año 2022, en especial, los incendios de Ferreras y de Losacio (véase figura 1). Los incendios de la zona se desarrollaron a lo largo de tres Lugares de Interés Comunitario (LIC), las lagunas de Tera y Vidriales, la ribera del río Tera y sus afluentes y la Sierra de la Culebra, quedando este último como el más afectado.

La Sierra de la Culebra es un LIC ordenado en 1998, de 61 300 ha de superficie, con un clima predominantemente mediterráneo-continental, con inviernos fríos y largos y veranos cálidos y cortos. La vegetación predominante son pinares de repoblación, entre los que destacan los pinos silvestres (*Pinus sylvestris*) y los pinos resineros (*Pinus pinaster*). Sin embargo, la vegetación climácica de la zona corresponde al rebollo (*Quercus pyrenaica*), con pequeñas formaciones de robledales (*Quercus suber*) y encinares (*Quercus illex*). El estrato arbustivo se caracteriza por la predominancia de especies leñosas como los brezos (*Erica aragonensis* y *arborea*), escobonales (*Cistus multiflorus*), jaras (*Cistus ladanifer*), con presencia de distintas especies de salvias (*Salvia sp.*) y esparto (*Macrochloa tenacissima*) (Junta de Castilla y León, 2017).




Figura 1. Mapa de los LICs afectados durante los incendios.

Fuente: Elaboración propia.

El área de estudio fue afectada por dos incendios distintos producidos por tormentas eléctricas (Figura 2); el incendio de la Sierra de la Culebra, iniciado el 15 de junio de 2022 en el término municipal de Ferreras de Arriba, llegando a una superficie de 25 000 ha (Copernicus Emergency Management Service, 2024a); y el incendio de Ferruelas, comenzado el 17 de julio en el término municipal de Losacio, afectando un área de 31 000 ha (Copernicus Emergency Management Service, 2024b).




Figura 2. Mapa de localización de las parcelas seleccionadas para los índices de campo.

Fuente: Elaboración propia a través de los datos tomados en campo y de la información publicada por Copernicus Emergency Management Service.

2.2. Flujo metodológico

Los datos tratados se han obtenido, para los datos satelitales, del navegador del programa Copernicus de la Agencia Espacial Europea (ESA), mientras que para los datos de campo ha sido necesario el traslado a la zona afectada. Una vez obtenidos los datos, ha sido necesario adaptarlos a las necesidades del proyecto para generar el dataset con el que entrenar el algoritmo de Random Forest.




Figura 3. Diagrama de flujo de trabajo.

2.3. Datos

2.3.1. Datos de campo

Para la realización del presente trabajo se han empleado datos satelitales y datos tomados en campo. Para el cálculo de los índices de campo, se siguió la metodología descrita por de Key y Benson (2006) y de Santis y Chuvieco (2009) para calcular los índices CBI y GeoCBI, respectivamente.

El Composite Burn Index (CBI) es un índice desarrollado para medir la magnitud del cambio ecológico causado por un incendio, proporcionando una visión holística de sus efectos sobre los distintos estratos de vegetación. Para calcularlo, se recopilan datos de campo en parcelas circulares de 30 metros de diámetro, espaciadas entre sí por al menos 90 metros. Estas parcelas deben ser representativas de los efectos del fuego y de la diversidad de condiciones presentes, además de abarcar todos los niveles de severidad del incendio. Dentro de cada parcela, los estratos evaluados incluyen el sustrato, que analiza el impacto del incendio en el suelo, la hojarasca y los restos orgánicos; las hierbas y arbustos bajos, que abarcan la vegetación menor a 1 metro; los arbustos altos y árboles pequeños, con alturas de 1 a 5 metros; los árboles intermedios, de entre 5 y 20 metros; y los árboles grandes, superiores a 20 metros. Para cada uno de estos estratos, se realizan evaluaciones visuales que incluyen el análisis de cambios en el suelo, la vegetación consumida, la altura alcanzada por el carbón y la regeneración de la vegetación. Los resultados se asignan en una escala que varía entre 0, que indica la ausencia de severidad, y 3, que representa la máxima severidad registrada, asemejándose a los niveles de severidad modelados por Landsat (Key y Benson, 2006).

A pesar de la versatilidad y facilidad de aplicación del índice, diversos estudios han señalado varias desventajas importantes (Amroussia et al., 2023; Cansler y McKenzie, 2012; Densmore et al., 2023). El CBI presenta limitaciones en la interpretación ecológica, ya que no logra capturar adecuadamente los cambios ecológicos en diversas regiones. Además, su relación no lineal con los índices satelitales limita la capacidad de estos últimos para predecir con precisión los valores del CBI. La ponderación de los estratos utilizada para calcular el índice de campo

puede reducir la influencia de los estratos más sensibles al fuego, lo que impide que se reflejen correctamente las prioridades ecológicas de cada región. Asimismo, la falta de una evaluación adecuada de los sesgos al correlacionar el CBI con los índices satelitales disminuye la fiabilidad de las estimaciones sobre la severidad del incendio.


De Santis y Chuvieco (2009) proponen el Índice de Severidad de Incendios Estructurado Geométricamente (GeoCBI), que introduce una serie de modificaciones para mejorar la estimación de la severidad de los incendios mediante teledetección, manteniendo el enfoque ecológico del CBI. Estas modificaciones incluyen la incorporación de nuevas variables que complementan las ya utilizadas en el CBI. En particular, se reemplazan el porcentaje de cambio en la cobertura de arbustos altos y árboles pequeños, así como el cambio porcentual en el volumen del follaje de la copa de los árboles intermedios y grandes, por el Índice de Área Foliar (LAI). Además, se añaden la Fracción de Cobertura cubierta (Fcov), expresada como porcentaje, y los rebrotes post-incendio.

Para este estudio, los datos de campo se recolectaron los días 4 y 27 de mayo de 2023. Los pivots fueron seleccionados en el propio campo en función de la severidad y de la biomasa consumida, y buscando la heterogeneidad de especies en cada estrato para cada parcela (Tabla 1). La severidad se clasificó en tres niveles, 1 para no quemado, 2 para severidad baja y 3 para severidad alta. En el caso de la biomasa, las categorías dadas corresponden a 1 para biomasa alta, 2 para biomasa baja y 3 para biomasa media. La severidad se clasificó utilizando los umbrales de dNBR del producto MTBS, y la clasificación estructural se realizó a partir del análisis de los datos de la segunda cobertura LiDAR del PNOA. Una vez establecido el pivot, se delimitó un área de 30x30 m para establecer la parcela, desde la que se tomaron los valores para cada estrato. Se establecieron un total de 32 pivots repartidos por el área quemada.

En la Tabla 1 se puede observar un ejemplo del tipo de parcelas que se tomaron. La parcela 224 fue clasificada como parcela de severidad baja, debido a la presencia de acículas en los individuos, tanto vivas como secas; y con una biomasa catalogada como baja debido a la juventud de los individuos y a la poca vegetación del sotobosque. Por otro lado, la parcela 316 fue clasificada como zona quemada de severidad alta debido al consumo de las acículas durante el incendio, ya que no se observaron acículas secas caídas tras el paso del incendio; y de alta biomasa a causa de la existencia de vegetación arbustiva y al mayor desarrollo de los individuos.

Tabla 1. Ejemplos de las zonas de toma de datos.

Parcela 224	Parcela 316
	



Fuente: Elaboración propia con imágenes tomadas en campo.

2.3.2. Datos de satélite

Los datos satelitales empleados provienen de los satélites Sentinel-2 debido a su alta resolución espacial y temporal, lo que facilita el estudio y el seguimiento de las coberturas del suelo (Murayama *et al.* 2020). Sentinel-2 es un sistema binario de satélites colocados con una órbita heliosíncrona, que toma datos de la superficie terrestre con un periodo de 5 días, con imágenes de 290 km de ancho, recogiendo información espectral en 13 bandas, de las que se emplean para el presente trabajo las pertenecientes al espectro visible, al infrarrojo cercano o NIR y al infrarrojo de onda media o SWIR. La resolución que tiene el sistema de satélites es de 10x10 m de píxel para el espectro visible y el NIR, y de 20x20 m para el SWIR (ESA, 2015).

Las imágenes post-incendio empleadas (Tabla 2) han sido seleccionadas en el rango de la finalización de los incendios y la toma de datos en campo, buscando en las imágenes satelitales una cobertura de nubes del 15-20%. Como imagen pre-incendio, se ha decidido tomar dos meses antes de la ocurrencia de los incendios, con la misma condición de cobertura de nubes que las imágenes post-incendio, tomando como fecha el 21 de abril de 2022. La escena de sentinel empleada ha sido la T30TTM.

Tabla 2. Fechas tomadas para las imágenes Sentinel-2.

Fechas	19-08-22	21-09-22	05-11-22	11-01-23	31-01-23	18-02-23	02-03-23	27-03-23	06-04-23	19-04-23
--------	----------	----------	----------	----------	----------	----------	----------	----------	----------	----------

2.4. Técnicas y métodos empleados

Para el desarrollo del presente trabajo ha sido necesario tratar los datos tanto satelitales como de campo. Para los datos satelitales se ha calculado una serie de índices diferenciales que, después, han sido relacionados con los datos de campo empleando machine learning.

2.4.1. Cálculo de índices espectrales

En materia de incendios, el NDVI funciona como indicador de severidad debido al consumo de vegetación que se produce, pero existen otros índices más adaptados al estudio de la severidad. El índice principal empleado en este campo es el NBR (Normalized Burn Ratio) ya que combina las bandas del NIR, que varía en función de la vegetación sana, y del infrarrojo de onda corta o SWIR, que varía en función de la humedad, la exposición del suelo y las sombras generadas por la vegetación (Pérez-Cabello *et al.*, 2021). Este índice se emplea para calcular el dNBR (Differenced Normalized Burn Ratio), que es la diferencia entre el NBR pre-incendio y el NBR post-incendio que indica el cambio producido en las bandas del NIR y del SWIR, haciéndolo sensible al cambio en la cobertura vegetal (Song *et al.*, 2021).

Pese a su versatilidad, el dNBR queda demasiado influenciado por los niveles de clorofila de la vegetación pre-incendio, por lo que Miller y Thode formularon un nuevo índice, el RdNBR (Relative Differenced Normalized Burn Ratio) que facilitara resultados de severidad independientes a las condiciones pre-incendio (Botella-Martínez y Fernández-Manso, 2017). De esta forma, mientras que el dNBR indica la cantidad de vegetación consumida, el RdNBR correlaciona esta vegetación consumida con la cobertura vegetal anterior al incendio. Este índice mejoraba la comparación de incendios en el espacio-tiempo y producía precisiones más altas para las categorías de mayor severidad en ecosistemas heterogéneos a la hora de representar visualmente (Miller y Thode, 2007)

Parks et al. (2014), sin embargo, repararon en la problemática producida por los valores bajos de NBR pre-incendio tratados en el denominador de la función, que generan valores muy polarizados de RdNBR, independientemente de la severidad del incendio, tendiendo al infinito para valores cercanos al 0. Para evitar este problema, idearon el RBR (Relativized burn Ratio), el cual divide el dNBR entre el NBR pre-incendio, sumándole 1.001 para asegurar que el denominador será siempre mayor de 0. Obtuvieron correlaciones mayores entre el CBI y el RBR que el RdNBR, demostrando un mayor acercamiento a la severidad real.

En general, para el estudio de la severidad de los incendios aplicando índices satelitales, los índices que más se ajustan a los índices de campo son el dNDVI y los basados en el NBR (Llovería et al., 2014), mientras que otros emplean métodos no tan extendidos, como el uso de índices basados en el espectro térmico y RADAR (Miller et al., 2023); el uso de índices como el SMI que emplea las bandas del SWIR y del Infrarrojo de onda media (MIR) (Veraverbeke et al., 2012); o de las bandas red-edge de Sentinel (Fernández-Manso et al., 2016; Mallinis et al., 2018).

En la Tabla 3 se muestran los índices empleados en este estudio. Se ha evaluado la relación entre CBI y GeoCBI con los índices espectrales dNDVI, dNBR, RdNBR y RBR. Como los índices utilizados son diferenciales (pre-incendio – post-incendio), se ha evaluado la correlación entre los índices calculados para cada fecha post-incendio y los valores de los índices de campo, para analizar el efecto de la fecha post-incendio en el cálculo de la severidad de quemado.

Han sido calculados los índices NDVI y NBR de cada imagen Sentinel para calcular después sus índices diferenciales correspondientes, dNDVI, dNBR, RdNBR y RBR debido a su alta correlación con los índices CBI y GeoCBI (Chen et al., 2018) (Tabla 3).

Tabla 3. Índices calculados.

Índice	Fórmula
Normalized Difference Vegetation Index	$NDVI = \frac{(B8 - B4)}{(B8 + B4)}$
Normalized Burnt Ratio	$NBR = \frac{(B8 - B12)}{(B8 + B12)}$
Differenced Normalized Vegetation Index	$dNDVI = NDVI_{pre} - NDVI_{post}$
Differenced Normalized Burnt Index	$dNBR = NBR_{pre} - NBR_{post}$
Relative differenced Normalized Burnt Index	$RdNBR = \frac{dNBR}{\sqrt{ABS(NBR_{pre}/1000)}}$
Relativized Burnt Ratio	$RBR = \frac{dNBR}{NBR_{pre} + 1.001}$

Fuente: Elaboración propia a partir de las tablas de Mallinis *et al.* (2018) con las bandas de Sentinel-2.

2.4.2. Sensibilidad a la fecha post-incendio

Una vez calculados los índices diferenciales, se ha calculado su correlación con los índices CBI y GeoCBI para ver qué índice se adapta mejor a la zona de estudio y para conocer la fecha más representativa, obteniendo tanto la correlación lineal como la polinomial.

2.4.3. Análisis de la influencia de los estratos de vegetación

Para valorar la influencia de cada estrato del índice de campo (CBI) sobre la respuesta espectral valorada a través de los índices satelitales, se ha utilizado un modelo de Random Forest (RF). Este algoritmo ha demostrado su eficacia para calcular la regresión de distintas variables al combinar un número n de modelos más simples, basados en el algoritmo de Árboles de Decisión y Regresión (CART) (Röder *et al.*, 2021).

El algoritmo CART es una técnica de aprendizaje automático utilizada para clasificación y regresión. Este enfoque comienza tomando una muestra del conjunto de datos y construyendo un árbol de decisión que se divide en nodos y ramas. En cada nodo, el algoritmo evalúa diferentes posibles divisiones de los datos, eligiendo aquellas que maximicen la separabilidad. Para la clasificación, se utiliza el índice de Gini, que mide la impureza de los nodos, buscando dividir los datos de manera que se logre una mayor pureza en las hojas del árbol. Cuanto menor sea el índice de Gini, mayor será la homogeneidad de la clase en ese nodo (Shalev-Shwartz y Ben-David, 2014).

En el caso de la regresión, CART emplea el error cuadrático medio (MSE) como criterio de división, buscando minimizar la variabilidad en los valores de salida de las muestras en cada nodo. El proceso de división se repite recursivamente hasta que se cumple un criterio de detención, como alcanzar una profundidad máxima del árbol o un número mínimo de muestras en los nodos (Alaminos-Fernández, 2022).

Con el método RF, se genera un número definido de árboles de decisión alimentados por una muestra aleatoria de los datos originales en el método *bagging*, de forma que se añade diversidad en el modelo, mejorando su precisión. A su vez, se proporcionan estimaciones continuas del error de generalización del conjunto combinado de árboles, así como estimaciones de la fuerza y la correlación de las variables. Esto se lleva a cabo midiendo, durante el proceso, la reducción de impureza al dividir cada nodo, indicando mayor importancia de la variable a mayor reducción de la impureza producida por dicha variable. Una vez entrenado el modelo, se mide su rendimiento predictivo modificando las variables y calculando su rendimiento, si el rendimiento empeora significativamente, la variable estará altamente correlacionada con el resultado (Breiman, 2001).

Con esto en mente, se ha empleado el modelo de regresión de RF para estimar la importancia de cada estrato tomado en cuenta en el GeoCBI para cada índice satelital. Para ello, se ha empleado de la librería *scikit-learn* la clase *RandomForestRegressor*, estableciendo los índices satelitales como variables dependientes y los índices de cada estrato del GeoCBI como variables independientes. Para el entrenamiento del modelo, se ha establecido una dimensión de 100 árboles de decisión con una profundidad máxima de 10 nodos. Una vez entrenado el algoritmo, se calcula la importancia de cada característica mediante la suma normalizada de las reducciones de impureza calculadas con el índice Gini (Scikit-Learn, 2023).

Una vez calculadas las importancias de cada estrato en cada índice satelital, se ha estudiado el peso que tiene cada variable de los índices de campo con su estrato correspondiente y con los índices de campo.

4. Resultados.

4.1 Análisis de índices diferenciales

Atendiendo a la figura 4, se observa el salto de valores en los índices NDVI y NBR tras los incendios, donde tienden a mantenerse estables en cierta medida. Esto puede llevar a pensar que no existirá diferencia a la hora de emplear una imagen satelital más cercana al incendio de una imagen satelital más cercana a la toma de datos.

Además, se representa visualmente la evolución de los índices calculados en las parcelas con el GeoCBI mayor y menor. Tras el incendio, ambas parcelas desarrollan unos valores muy dispares en cada índice, siendo los valores mayores en NDVI y menores en NBR para la parcela catalogada como severidad media, mientras que los valores menores de NDVI y mayores de NBR pertenecen a la parcela catalogada como severidad alta, lo que demuestra la diferencia en la severidad que se han sufrido. Antes del incendio, por otra parte, los valores de ambas parcelas quedan invertidos a los valores post incendio, lo que podría indicar que, pese a que ambas parcelas son catalogadas con alta biomasa, es la parcela 316 la que mayor biomasa presenta.




Figura 4. Evolución de los índices NDVI y NBR. En azul quedan representados los promedios de los índices satelitales junto con sus desviaciones estándar; en verde se representan los valores de la parcela con los valores de GeoCBI más bajos; y en naranja se representan los valores de la parcela con los valores de GeoCBI más altos.

Fuente: Elaboración propia.

Por ello se han calculado los índices diferenciales con mayor correlación con los índices CBI y GeoCBI (Figura 5), para ver esa variación de correlación a medida que pasa el tiempo, lo que queda plasmado en las tablas 4 y 5. Aquí se muestra que los mejores ajustes de regresión pertenecen a funciones polinómicas, y que son los índices calculados a partir de las imágenes más cercanas a los incendios los que tienen una mayor correlación, siendo estos los que menor MSE presentan.




Figura 5. Distribución de la severidad en los índices calculados.

Fuente: Elaboración propia con los índices calculados con las imágenes de Sentinel-2 con la fecha más cercana al incendio (19-08-2022). Los rangos de severidad empleados se toman del trabajo de Botella-Martínez y Fernández-Manso (2017).

En el caso del índice CBI, los valores más altos de R^2 corresponden a los índices dNBR y NBR, con valores de 0.46 y 0.47 respectivamente; mientras que el valor más bajo corresponde al índice RdNBR, con una R^2 que no supera el 0.15. Para este índice, las fechas que tienen mayor correlación se distribuyen en los dos primeros meses, con la excepción del RdNBR que tiene mayor correlación a los seis meses.

Por otro lado, el índice GeoCBI presenta una R^2 de 0.71 para el NBR y de 0.66 para el RBR, dejando nuevamente el valor más bajo para el RdNBR con un valor de 0.31. En este caso, las correlaciones más altas se dan en los meses más cercanos al fin de los incendios.

Comparando ambos índices de campo, es el GeoCBI el que tiene una correlación más alta para cada índice satelital, concentrando estos valores en las fechas cercanas a los incendios, mientras que el índice CBI, que tiene unos valores de R^2 menores para todos los índices satelitales, los distribuye más en el tiempo.

Tabla 4. Correlación entre los índices satelitales y el CBI.

Correlación de los índices con el CBI									
Fechas	Tipo	dNDVI		dNBR		RdNBR		RBR	
		R ²	MSE	R ²	MSE	R ²	MSE	R ²	MSE
19/08/2022	Lineal	0.368157	0.182420	0.400405	0.173110	0.037887	0.277773	0.370098	0.181860
	Polinómica	0.394488	0.174818	0.404134	0.172033	0.076351	0.266667	0.428030	0.165134
21/09/2022	Lineal	0.349466	0.187816	0.433700	0.163497	0.023989	0.281785	0.375386	0.180333
	Polinómica	0.363762	0.183689	0.460849	0.155659	0.043192	0.276241	0.473632	0.151968
05/11/2022	Lineal	0.323161	0.195411	0.399249	0.173443	0.063453	0.270391	0.330875	0.193184
	Polinómica	0.342161	0.189925	0.445639	0.160050	0.132274	0.250522	0.422261	0.166799
11/01/2022	Lineal	0.275701	0.209113	0.301112	0.201776	0.147127	0.246234	0.275032	0.209306
	Polinómica	0.275725	0.209106	0.301925	0.201542	0.150478	0.245266	0.299576	0.202220
31/01/2022	Lineal	0.260295	0.213561	0.324080	0.195145	0.079078	0.265880	0.289441	0.205146
	Polinómica	0.260699	0.213444	0.327863	0.194053	0.102377	0.259154	0.321970	0.195755
18/02/2023	Lineal	0.253053	0.215652	0.357716	0.185434	0.016519	0.283942	0.311079	0.198899
	Polinómica	0.253472	0.215531	0.361903	0.184226	0.076318	0.266677	0.351288	0.187290
02/03/2023	Lineal	0.236830	0.220336	0.344945	0.189121	0.030311	0.279960	0.304125	0.200907
	Polinómica	0.238037	0.219987	0.347517	0.188379	0.073227	0.267570	0.338926	0.190859
27/03/2023	Lineal	0.230746	0.222092	0.316750	0.197262	0.016662	0.283900	0.290589	0.204815
	Polinómica	0.236435	0.220449	0.317291	0.197106	0.061864	0.270850	0.306021	0.200359
06/04/2023	Lineal	0.232366	0.221624	0.331136	0.193108	0.023010	0.282068	0.299629	0.202205
	Polinómica	0.236519	0.220425	0.331204	0.193089	0.071221	0.268149	0.318291	0.196817
19/04/2023	Lineal	0.247077	0.217377	0.341281	0.190180	0.034312	0.278805	0.307414	0.199957
	Polinómica	0.248192	0.217055	0.341282	0.190179	0.082924	0.264770	0.329058	0.193708

Fuente: Elaboración propia. En negrita quedan resaltados valores más altos de correlación.

Tabla 5. Correlación entre los índices satelitales y el GeoCBI.

Correlación de los índices con el GeoCBI									
Fechas	Tipo	dNDVI		dNBR		RdNBR		RBR	
		R ²	MSE	R ²	MSE	R ²	MSE	R ²	MSE
19/08/2022	Lineal	0.368139	0.222086	0.586662	0.145280	0.131603	0.305224	0.456474	0.191038
	Polinómica	0.450753	0.193049	0.669899	0.116024	0.306552	0.243733	0.656196	0.120840
21/09/2022	Lineal	0.305411	0.244134	0.569241	0.151403	0.087180	0.320838	0.418282	0.204462
	Polinómica	0.347356	0.229391	0.712023	0.101218	0.203310	0.280020	0.641278	0.126084
05/11/2022	Lineal	0.214899	0.275947	0.391669	0.213816	0.107542	0.313681	0.296501	0.247266
	Polinómica	0.224043	0.272733	0.486916	0.180339	0.270168	0.256521	0.401542	0.210346
11/01/2022	Lineal	0.144857	0.300565	0.200248	0.281097	0.094547	0.318248	0.184426	0.286658
	Polinómica	0.156353	0.296525	0.200442	0.281028	0.109694	0.312924	0.189410	0.284906
31/01/2022	Lineal	0.130336	0.305669	0.200470	0.281019	0.026296	0.342237	0.183737	0.286900
	Polinómica	0.147208	0.299739	0.201287	0.280731	0.029291	0.341184	0.187333	0.285636
18/02/2023	Lineal	0.132066	0.305061	0.237161	0.268122	0.001458	0.350967	0.206855	0.278774
	Polinómica	0.146845	0.299867	0.237634	0.267956	0.024770	0.342774	0.214505	0.276085
02/03/2023	Lineal	0.116167	0.310649	0.232234	0.269854	0.010151	0.347912	0.204871	0.279472
	Polinómica	0.137618	0.303110	0.233284	0.269485	0.018550	0.344960	0.210971	0.277328
27/03/2023	Lineal	0.102868	0.315324	0.201628	0.280611	0.001673	0.350892	0.187197	0.285684
	Polinómica	0.130139	0.305739	0.210756	0.277403	0.015826	0.345917	0.187806	0.285470
06/04/2023	Lineal	0.104981	0.314581	0.193638	0.283420	0.001390	0.350991	0.181282	0.287763
	Polinómica	0.129296	0.306035	0.203390	0.279992	0.012455	0.347102	0.181584	0.287656
19/04/2023	Lineal	0.100269	0.316237	0.183208	0.287086	0.000942	0.351149	0.175347	0.289849
	Polinómica	0.126086	0.307163	0.197099	0.282203	0.013051	0.346893	0.175347	0.289849

Fuente: Elaboración propia. En negrita quedan resaltados los valores más altos de correlación.

4.2 Análisis de la importancia de los estratos

Una vez establecida la fecha más cercana al incendio como fecha con la que se va a trabajar, se saca la importancia de los diferentes estratos para cada índice satelital. Como muestra la tabla 6, salvo para el dNBR, el estrato con más peso es el estrato D, con valores entre 0.4 y 0.5, siendo para el RdNBR y el RBR el estrato C el que queda con mayor relevancia, mientras que para el dNDVI es el estrato B. En el caso del dNBR, los estratos con los valores más altos son los estratos arbóreos bajo y medio, siendo el estrato C el de más peso con 0.442. En todos los índices se cumple que el estrato con menor importancia es el estrato E, lo que puede deberse a la poca cantidad de pivots tomados con este estrato presente.

Tabla 6. Relevancia entre los estratos del GeoCBI y los índices satelitales.

Estratos	dNDVI	dNBR	RdNBR	RBR
A	0.088130	0.137343	0.084775	0.118708
B	0.238887	0.072178	0.187146	0.084948
C	0.192489	0.442234	0.297159	0.300247
D	0.478601	0.348245	0.430849	0.494175
E	0.001893	0.000000	0.000070	0.001922

Fuente: Elaboración propia con las variables para calcular el GeoCBI y los índices satelitales. En negrita quedan resaltados los valores más altos de correlación.

A estos análisis se les añade el análisis realizado para conocer la importancia que tiene cada variable para su estrato correspondiente al CBI. En la tabla 1 del Anexo I se muestra la importancia de la puntuación de cada estrato para el índice y, dentro de cada estrato, la influencia que tiene cada variable. En este caso, el estrato D es el que más peso tiene dentro del índice de campo, con un peso de 0.36, seguido del estrato A, con un peso de 0.34, y de los estratos B, C y E, de los que E tiene menor peso. La importancia que tiene cada variable dentro de cada estrato con vegetación muestra cómo son las variables que afectan directamente al individuo, como el porcentaje de individuos vivos y el porcentaje de hojas marrones/negras, es decir, que no se han consumido, pero han quedado secas. Por otro lado, la variable con mayor peso en el conjunto de las variables es el consumo de la materia orgánica,

Si, por otro lado, se aplica el mismo método sobre el GeoCBI, como se representa en la tabla 2 del Anexo I, el orden de los pesos varía significativamente. En este caso, el mayor peso, al igual que sucede con los índices satelitales, recae en el estrato D, suponiendo un peso de entorno a 0.51. Dentro de este estrato, la variable que más influye es la altura de quemado, con una importancia del 0.41, seguida del porcentaje de cambio de ramas de 1º y 2º orden con un peso de 0.03. A este estrato le sigue el estrato C, con un peso de 0.42, con el porcentaje en el cambio de ramas de 1º y 2º orden como variable más significativa con 0.37, seguido de la cobertura foliar con 0.02. A este estrato le siguen el estrato A, el B y el E respectivamente, con unos pesos menores a 0.04.

5. Discusión.

Los análisis realizados en este estudio proporcionan una visión holística sobre la severidad de los incendios forestales en la Sierra de la Culebra, integrando datos de campo y teledetección. A través de la comparación de los índices satelitales dNDVI, dNBR, RdNBR y RBR, con métricas de severidad de campo calculadas con los índices CBI y GeoCBI, se han identificado patrones clave en la relación entre las variables evaluadas, el tiempo post-incendio y los estratos de vegetación.

La correlación más alta entre los índices satelitales y los índices de campo empleados en este trabajo se observa en las fechas más próximas a la finalización del incendio. Esto concuerda con estudios como el de Harvey y Saberi (2023), que destacan cómo las observaciones inmediatas

posteriores al incendio capturan con mayor precisión la severidad del evento, reflejando de manera más clara las alteraciones iniciales en la estructura de la vegetación y el suelo. De manera similar, Gallegos-Rodríguez et al. (2022) demuestran que las etapas iniciales post-incendio son las más representativas para índices de severidad como el NBR y sus derivados diferenciales.

Atendiendo a los índices de campo calculados, las correlaciones más altas entre el CBI y los índices satelitales se extienden durante un periodo de tiempo más prolongado, mientras que las correlaciones del GeoCBI muestran mejores resultados en fechas más próximas a la finalización del incendio. Para el CBI, la mayor correlación se obtiene con el RBR, con un valor de 0.47, mientras que para el GeoCBI, el dNBR presenta la correlación más alta, alcanzando un valor de 0.71. A través de un análisis adicional, se calculó la contribución de cada variable a los índices satelitales (Tabla 7), destacando la importancia de la Fcov en el GeoCBI. Esto explica el aumento en la correlación del GeoCBI con respecto al CBI, ya que la FCOV refleja directamente la intensidad del impacto del fuego en el dosel y los estratos arbóreos. Por otro lado, la disminución de la correlación entre los índices con el paso del tiempo podría atribuirse a la caída de hojas soflamadas y al inicio de los rebrotes, lo que afecta la capacidad de los índices satelitales para representar con precisión la severidad inicial del incendio.

Tabla 7. Importancia de las variables de los índices de campo para cada índice satelital.

CBI							
dNDVI		dNBR		RdNBR		RBR	
suelo/ Roca/ substrato A	0.176938	% cambio de ramas de 1° y 2° orden C	0.456012	% cambio de ramas de 1° y 2° orden C	0.213837	% cambio de ramas de 1° y 2° orden C	0.274107
% cambio de ramas de 1° y 2° orden C	0.164886	Suelo/ Roca/ substrato A	0.200453	Rebrotes B	0.176449	Suelo/ Roca/ substrato A	0.258420
GeoCBI							
dNDVI		dNBR		RdNBR		RBR	
FCOV_D	0.398225	% cambio de ramas de 1° y 2° orden C	0.413590	% cambio de ramas de 1° y 2° orden C	0.150095	FCOV_D	0.362374
% cambio de ramas de 1° y 2° orden C	0.117561	FCOV_D	0.146330	FCOV_C	0.134904	% cambio de ramas de 1° y 2° orden C	0.220445

Fuente: Elaboración propia aplicando el método Random Forest Regressor a las variables del CBI y GeoCBI con cada índice satelital. Se representan sólo las dos variables con mayor peso, indicando el estrato al que pertenecen.

Al comparar la correlación entre los índices satelitales y los índices de campo, los resultados de este trabajo muestran que la mayor correlación se da entre el GeoCBI y el dNBR, alcanzando un valor notablemente alto de 0.71. Esto es especialmente relevante al contrastarlo con otras investigaciones, como las de Ariza et al. (2018), Goosens et al. (2012) o Güney et al. (2023). En el caso de Ariza et al. (2018), el estudio se centra en dos incendios propagados en Madrid y Guadalajara, los autores reportaron correlaciones máximas del dNBR con índices de campo en un rango de 0.60 y 0.81, dependiendo de la región y las condiciones climáticas. De forma similar, Goosens et al. (2012) analizan la severidad de los incendios producidos en la península del Peloponeso, obteniendo una correlación entre el GeoCBI y el dNBR de 0.65. Por otra parte, Güney et al. (2023) estudian cinco incendios producidos en Turquía, tres de los cuales se propagaron en zonas de clima mediterráneo, obteniendo una correlación de 0.75 para el dNBR con respecto al GeoCBI.

Los resultados obtenidos en este estudio en relación con el dNBR son consistentes con los hallazgos de otros trabajos realizados en zonas mediterráneas, como el área de estudio en cuestión. Sin embargo, en los estudios de Aritza y Güeney, los valores del índice RdNBR son ligeramente más altos, con un rango de 0.62 a 0.82 para Aritza y 0.74 para Güeney, contrastando con el valor de 0.31 obtenido en este trabajo. En cuanto al índice RBR, las correlaciones encontradas en este estudio son similares a las reportadas por Aritza, que oscilaron entre 0.63 y 0.83, mientras que el valor obtenido en este trabajo fue de 0.66. De manera similar, el dNDVI de Goosens que muestra una correlación de 0.46 con el GeoCBI, en comparación con el valor de 0.45 obtenido en este estudio, aunque no alcanza los valores de 0.61 a 0.77 presentados por Aritza. En resumen, los índices dNBR y RBR muestran las mayores similitudes con otros estudios, mientras que el RdNBR presenta la menor correlación.

En relación a la importancia relativa de las variables para el cálculo de los índices de campo, a pesar de la abundancia de investigaciones relacionadas con la severidad de los incendios forestales y su evaluación mediante índices como el CBI y el GeoCBI, no se han encontrado estudios que pongan en práctica dicho análisis, por lo que no se podrán comparar resultados.

Atendiendo a los resultados obtenidos para la importancia de cada variable en el cálculo del CBI y del GeoCBI, se puede observar que en ambos índices el estrato D, relacionado con el dosel arbóreo y la cobertura superior, tiene un peso significativo. Sin embargo, se destacan diferencias clave en la contribución de otros estratos: mientras que en el CBI el estrato A, correspondiente al sustrato, es el que presenta el segundo mayor peso después del estrato D; mientras que en el GeoCBI es el estrato C, correspondiente al dosel arbustivo alto y al dosel arbóreo medio, el que ocupa el segundo lugar en relevancia. Esta diferencia resalta cómo el GeoCBI incorpora un enfoque más centrado en la cobertura del dosel al incluir el FCOV, dando un enfoque heterogéneo a la cobertura vegetal de cada estrato y reflejando de forma más precisa la severidad del incendio (de Santis et al., 2009).

Como parte de un análisis adicional, se ha calculado la importancia de cada variable sobre el GeoCBI separando por grado de severidad y por cantidad de biomasa, pero no se han obtenido datos concluyentes a causa del bajo número de parcelas. También se ha querido comprobar la significancia de la severidad de cada parcela en función de la especie dominante y del tipo de vegetación dominante, separando entre especies leñosas y especies frondosas, pero debido a la predominancia de especies leñosas, en especial pinos, no se ha podido sacar estadísticos significativos.

Como fortalezas de este estudio, se puede destacar la alta correlación obtenida entre los índices satelitales y los índices de campo en las fechas cercanas a la finalización del incendio, lo que valida la metodología empleada. Además, la correlación entre los índices de campo y el dNBR contrasta favorablemente con estudios previos, lo que indica una correlación adaptada al clima mediterráneo. Igualmente, el uso del modelo de regresión de Random Forest ha permitido analizar la relevancia de los estratos arbóreos y la importancia de la Fcov, reforzando la importancia de su inclusión en la evaluación de severidad. Finalmente, con la integración de datos satelitales y de campo se proporciona una evaluación integral, lo que puede ser útil no solo en la investigación científica, si no a la hora de gestionar y restaurar áreas mediterráneas afectadas por incendios.

En cuanto a las debilidades presentadas por el estudio, la principal queda representada por el bajo número de parcelas tratadas, lo que puede limitar a la hora de realizar estudios estadísticos robustos o al analizar las parcelas, como ha sido el caso, en función de sus características de severidad, de biomasa o de vegetación. Respecto a las correlaciones entre índices satelitales y de campo, si bien es verdad que se han obtenido correlaciones significativas similares a las de otros estudios con respecto al dNBR y al RBR, el RdNBR da unos valores demasiado bajos, lo que puede indicar que no es un índice significativo para el ecosistema mediterráneo, lo que contrasta con el gran número de trabajos que ponen en valor este índice, o bien que no se adapte del todo a las condiciones del área de estudio.

Además de las limitaciones, existen una serie de amenazas que pueden afectar a la replicabilidad del estudio. La variabilidad ecológica de la Sierra de la Culebra puede alterar los

resultados obtenidos al aplicarse la metodología en otras regiones mediterráneas con características ecológicas diferentes. Otra amenaza reside en la dependencia de la tecnología satelital, ya que las limitaciones de los satélites actuales, como la resolución y las bandas espectrales de Sentinel-2, o la posible interrupción de futuras misiones, podrían afectar la replicabilidad de los resultados. A parte, el uso predominante del índice dNBR ha sido objeto de críticas, y el desempeño local del índice puede ser cuestionado si no se justifica adecuadamente.

Para finalizar, como oportunidades para futuros trabajos, se puede incluir el uso de nuevas tecnologías para poder hacer un estudio más preciso sobre la severidad, como por ejemplo con el uso de LiDAR, como hacen García et al. (2020), obteniendo resultados notorios. También se podría ampliar el número de parcelas para aumentar la representatividad y la robustez en el análisis, o emplear otros índices para complementar el estudio, incluyendo, por ejemplo, el GNDVI o el NDWI (Flores-Rodríguez et al., 2021), o el índice BAI (Guillem-Cogollos et al., 2017). Otra mejora podría ser la modificación del índice de campo, viendo la subjetividad a la hora de decidir la cobertura foliar después de un incendio a causa de la caída de hojas sofamadas, podrían incluirse estas como variable. Además, la aplicación de estos hallazgos podría guiar estrategias de restauración y monitoreo post-incendio en zonas similares.

6. Conclusiones.

El presente trabajo ha permitido avanzar en la caracterización de la severidad de los incendios forestales en la Sierra de la Culebra mediante el uso combinado de datos de campo y teledetección, demostrando la importancia de integrar metodologías tradicionales y tecnológicas en el análisis de eventos ambientales de gran impacto. La correlación entre los índices de severidad obtenidos en campo, como el CBI y el GeoCBI, y los índices satelitales, como el dNDVI, dNBR, RdNBR y RBR, evidencia que el uso conjunto de estas herramientas proporciona una visión más precisa y completa de los efectos de los incendios forestales. En particular, el GeoCBI muestra las correlaciones más altas, destacando su utilidad en ecosistemas mediterráneos. En este contexto, el dNBR se consolida como el índice más eficaz para caracterizar la severidad, con una correlación de $R^2 = 0.71$ con el GeoCBI, mientras que el RBR también demuestra ser una herramienta robusta. Por el contrario, el RdNBR presenta correlaciones más bajas, sugiriendo que este índice puede no ser tan representativo para las condiciones de la región estudiada.

Además, queda reflejada la efectividad del modelo de regresión de Random Forest para establecer las importancias de las variables en el cálculo del GeoCBI, con lo que se ha concluido la relevancia de los estratos arbóreos y arbustivos altos a la hora de establecer la severidad. Esto subraya la importancia del dosel arbóreo en la evaluación de incendios, especialmente cuando se emplean métricas como Fcov, que contribuyen a mejorar la interpretación de los resultados.

Pese a los logros alcanzados, este estudio presenta ciertas limitaciones, entre las que destaca el bajo número de parcelas y la poca variabilidad de especies en estas. De esta forma, para complementar este estudio, se propone aumentar el número de parcelas y la variabilidad en el tipo de vegetación analizado, junto con la aplicación de otras herramientas como LiDAR para poder realizar un estudio más inmersivo sobre qué variables son las que más afectan a la hora de establecer la severidad de una zona.

7. Referencias bibliográficas

- Alaminos-Fernández, A. (2022): Árboles de decisión en R con Random Forest. Alicante, Limencop. ISBN 978-84-09-49460-6, 134 p. Disponible en: <http://hdl.handle.net/10045/133067>
- Amroussia, M.; Viedma, O.; Achour, H.; Abbes, C. (2023): "Predicting Spatially Explicit Composite Burn Index (CBI) from Different Spectral Indices Derived from Sentinel 2A: A Case of Study in Tunisia", *Remote Sensing*, 15(2), 335. Disponible en: <https://doi.org/10.3390/rs15020335>.
- Ariza, A.; Salas Rey, J. F.; Merino de Miguel, S. (2018): "Comparison of Maximum Likelihood Estimators and Regression Models in Mediterranean Forests Fires for Severity Mapping Using Landsat TM and ETM+ Data", *Preprints*, 2018030245. Disponible en: <https://doi.org/10.20944/preprints201803.0245.v1>.
- BOE (18 de diciembre de 2024) Orden PJC/1430/2024, de 16 de diciembre, por la que se publica el Acuerdo del Consejo de Seguridad Nacional de 15 de octubre de 2024, por el que se aprueba la Estrategia Nacional de Protección Civil. Recuperado de <https://www.boe.es/buscar/doc.php?id=BOE-A-2024-26452>
- Botella-Martínez, M. A.; Fernández-Manso, A. (2017): "Estudio de la severidad post-incendio en la Comunidad Valenciana comparando los índices dNBR, RdNBR y RBR a partir de imágenes Landsat 8", *Revista de Teledetección*, 49, pp. 33-47. <https://doi.org/10.4995/raet.2017.7095>
- Breiman, L. (2001): "Random forests", *Machine Learning*, 45, 5–32. <https://doi.org/10.1023/A:1010933404324>
- Burson, D.; Donovan, V.; Baldwin, C.; Bauman, P.; Treadwell, M.; Twidwell, D.; Wonkka, C. L. (2023): *The new wildfire season*. Disponible en <https://agrilife.org/westtexasrangelands/files/2023/08/the-new-wildfire-season.pdf>
- Cansler, C. A.; McKenzie, D. (2012): "How Robust Are Burn Severity Indices When Applied in a New Region? Evaluation of Alternate Field-Based and Remote-Sensing Methods", *Remote Sensing*, 4(2), 456-483. Disponible en: <https://doi.org/10.3390/rs4020456>.
- Chen, D., Fu, C., Hall, J. V., Hoy, E. E., y Loboda, T. V. (2021): "Spatio-temporal patterns of optimal Landsat data for burn severity index calculations: Implications for high northern latitudes wildfire research," *Remote Sensing of Environment*, 258, 112393. <https://doi.org/10.1016/j.rse.2021.112393>
- Copernicus Emergency Management Service (2024a): *EMSR580 - European Union Copernicus Emergency Management Service: Map Archive*. [Consulta: 10-11-2024]. Disponible en <https://emergency.copernicus.eu/mapping/list-of-components/EMSR580>
- Copernicus Emergency Management Service (2024b): *EMSR602 - European Union Copernicus Emergency Management Service: Map Archive*. [Consulta: 10-11-2024]. Disponible en <https://emergency.copernicus.eu/mapping/list-of-components/EMSR602>
- Delcourt, C. J.; Combee, A.; Izbicki, B.; Mack, M. C.; Maximov, T.; Petrov, R.; Veraverbeke, S. (2021): "Evaluating the differenced normalized burn ratio for assessing fire severity using Sentinel-2 imagery in Northeast Siberian Larch Forests," *Remote Sensing*, 13(12), 2311. <https://doi.org/10.3390/rs13122311>
- Delegido, J.; Pezzola, A.; Casella, A.; Winschel C.; Urrego, E. P.; Jiménez, J. C.; Soria, G.; Sobrino, J. A.; Moreno, J. (2018): "Estimación del grado de severidad de incendios en el sur de la provincia de Buenos Aires, Argentina, usando Sentinel-2 y su comparación con Landsat-8", *Revista de Teledetección*, 52, pp. 45-60. Disponible en <https://doi.org/10.4995/raet.2018.8934>
- De Santis, A.; Chuvieco, E. (2009): "GeoCBI: A modified version of the Composite Burn Index for the initial assessment of the short-term burn severity from remotely sensed data",

International Journal of Applied Earth Observation and Geoinformation, 10, 4, pp. 311-321.
Disponible en: <https://doi.org/10.1016/j.rse.2008.10.011>

De Santis, A.; Chuvieco, E.; Vaughan, P. J. (2009): "Short-term assessment of burn severity using the inversion of PROSPECT and GeoSail models", *Remote Sensing of Environment*, 113(1), pp. 126-136. <https://doi.org/10.1016/j.rse.2008.08.008>

Densmore, V. S.; van Dongen, R. J.; Ong, R.; Harris, B. G. (2023): "OzCBI: The Composite Burn Index Adapted to Assess Fire Severity and Key Fauna Habitat Features in Australian Ecosystems", *Australian Journal of Botany*, 1-21. Disponible en: <https://doi.org/10.1080/00049158.2023.2168400>.

ESA (2015): *Sentinel-2*. [Consulta: 02-12-2024]. Disponible en https://www.esa.int/Space_in_Member_States/Spain/SENTINEL_2

European Commission (2024): *Consequences of Climate Change*. [Consulta: 02-12-2024]. Disponible en https://climate.ec.europa.eu/climate-change/consequences-climate-change_en

Fernández-Manso, A.; Fernández-Manso, O.; Quintano, C. (2016): "Sentinel-2A red-edge spectral indices suitability for discriminating burn severity", *International Journal of Applied Earth Observation and Geoinformation*, 50, pp. 170-175.

Flores-Rodríguez, A. G.; Flores-Garnica, J. G.; González-Eguiarte, D. R.; Gallegos-Rodríguez, A.; Zarazúa-Villaseñor, P.; Mena-Munguía, S. (2021): "Análisis comparativo de índices espectrales para ubicar y dimensionar niveles de severidad de incendios forestales", *Investigaciones Geográficas*, no. 106. Ciudad de México. Disponible en: <https://doi.org/10.14350/rig.60396>, <https://www.preprints.org/manuscript/201803.0245/v1>

Flores-Rodríguez, A. G.; Flores-Garnica, J. G.; Lomelí Z., M. E. (2021): *Análisis de imágenes satelitales y aplicación de índices espectrales en incendios forestales*. Folleto técnico, Núm. 1, INIFAP-CIRPAC, Campo Experimental Centro-Altos de Jalisco, Jalisco, México. 66 p. Disponible en: https://www.researchgate.net/profile/Jose-Flores-Garnica/publication/370124659_ANALISIS_DE_IMAGENES_SATELITALES_Y_APLICACION_DE_INDICES_ESPECTRALES_EN_INCENDIOS_FORESTALE/links/64403b162eca706c8b6d43cb/ANALISIS-DE-IMAGENES-SATELITALES-Y-APLICACION-DE-INDICES-ESPECTRALES-EN-INCENDIOS-FORESTALE.pdf

French, N. H. F.; Kasischke, E. S.; Hall, R. J.; Murphy, K. A.; Verbyla, D. L.; Hoy, E. E.; Allen, J. L. (2008): "Using Landsat data to assess fire and burn severity in the North American boreal forest region: an overview and summary of results," *International Journal of Wildland Fire*, 17(4), pp. 443-462. <https://doi.org/10.1071/WF08007>

García, M.; North, P.; Viana-Soto, A.; Stavros, N. E.; Rosette, J.; Martín, M. P.; Franquesa, M.; González-Cascón, R.; Riaño, D.; Becerra, J.; Zhao, K. (2020): "Evaluating the potential of LiDAR data for fire damage assessment: A radiative transfer model approach", *Remote Sensing of Environment*, 247, 111893. Disponible en: <https://doi.org/10.1016/j.rse.2020.111893>.

de Groot, W. J.; Flannigan, M. D.; Stocks, B. J. (2013): "El cambio climático y los incendios forestales", en *Memorias del cuarto simposio internacional sobre políticas, planificación y economía de los incendios forestales: Cambio climático e incendios forestales*, pp. 1-12.

Guillem-Cogollos, R.; Vinué-Visús, D.; Caselles-Mirallès, V.; Espinós-Morató, H. (2017): "Estudio crítico de los índices de severidad y la superficie afectada por el incendio de Sierra de Luna (Zaragoza)", *Revista de Teledetección*, 47, pp. 35-48. Disponible en <https://doi.org/10.4995/raet.2017.7117>.

Güney, C. O.; Mert, A.; Gülsoy, S. (2023): "Assessing fire severity in Turkey's forest ecosystems using spectral indices from satellite images", *Journal of Forestry Research*, 34, 1747-1761. Disponible en: <https://doi.org/10.1007/s11676-023-01620-7>

- Goosens, R.; Veraverbeke, S.; Lhermitte, S.; Verstraeten, W.W.(2012): Evaluation of pre/post-fire differenced spectral indices for assessing burn severity in a Mediterranean environment with Landsat Thematic Mapper. *International Journal of Remote Sensing*, vol. 32(12), 3521-3537. <https://doi.org/10.1080/01431161003752430>
- Han, D.; Di, X.; Yang, G.; Sun, L.; Weng, Y. (2021): “Quantifying fire severity: a brief review and recommendations for improvement”, *Ecosystem Health and Sustainability*, 7, 1, pp. 1-10. <https://doi.org/10.1080/20964129.2021.1973346>
- Jones, M. W.; Kelley, D. I.; Burton, C. A.; Di Giuseppe, F.; Barbosa, M. L. F.; Brambleby, E.; Hartley, A. J.; Lombardi, A.; Mataveli, G.; McNorton, J. R.; Spuler, F. R.; Wessel, J. B.; Abatzoglou, J. T.; Anderson, L. O.; Andela, N.; Archibald, S.; Armenteras, D.; Burke, E.; Carmenta, R.; Chuvieco, E.; Clarke, H.; Doerr, S. H.; Fernandes, P. M.; Giglio, L.; Hamilton, D. S.; Hantson, S.; Harris, S.; Jain, P.; Kolden, C. A.; Kurvits, T.; Lampe, S.; Meier, S.; New, S.; Parrington, M.; Perron, M. M. G.; Qu, Y.; Ribeiro, N. S.; Saharjo, B. H.; San-Miguel-Ayanz, J.; Shuman, J. K.; Tanpipat, V.; van der Werf, G. R.; Veraverbeke, S.; Xanthopoulos, G. (2024): State of Wildfires 2023–2024, *Earth Syst. Sci. Data*, 16, 3601–3685, <https://doi.org/10.5194/essd-16-3601-2024>
- UNEP (2022): *Spreading like Wildfire: The Rising Threat of Extraordinary Landscape Fires*. Nairobi, United Nations Environment Programme. [Consulta: 02-12-2024]. Disponible en <https://www.unep.org/resources/report/spreading-wildfire-rising-threat-extraordinary-landscape-fires>
- Junta de Castilla y León (2017): *Resumen de la propuesta de delimitación del LIC ES4190033 "Sierra de la Culebra"*. Valladolid, Junta de Castilla y León. [Consulta: 10-11-2024]. Disponible en <https://rednatura.jcyl.es/natura2000/LIC/Formularios%20oficiales/PDF%20LIC%20resumen/ES4190033.pdf>
- Keeley, J. E. (2009): “Fire intensity, fire severity and burn severity: a brief review and suggested usage”, *International Journal of Wildland Fire*, 18, 1, pp. 116-126. Disponible en: <https://doi.org/10.1071/WF07049>
- Key, C. H.; Benson, N. C. (2006): “Landscape assessment (LA)”, *FIREMON: Fire effects monitoring and inventory system*, 164, LA-1.
- Lentile, L. B.; Holden, Z. A.; Smith, A. M. S.; Falkowski, M. J.; Hudak, A. T.; Morgan, P.; Lewis, S. A.; Gessler, P. E.; Benson, N. C. (2006): “Remote sensing techniques to assess active fire characteristics and post-fire effects”, *International Journal of Wildland Fire*, 15(3), 319-345. Disponible en: <https://doi.org/10.1071/WF05097>
- Liu, Y.; Goodrick, S. L.; Stanturf, J. A. (2013): “Future U.S. wildfire potential trends projected using a dynamically downscaled climate change scenario”, *Forest Ecology and Management*, 294, pp. 120–135. <https://doi.org/10.1016/j.foreco.2012.06.049>
- Llovería, R. M.; Cabello, F. P.; Martín, A. G.; Vlassova, L.; de la Riva Fernández, J. R. (2014): “La severidad del fuego: revisión de conceptos, métodos y efectos ambientales”, en *Geoecología, cambio ambiental y paisaje: homenaje al profesor José María García Ruiz*, pp. 427-440.
- Lutes, D. C.; Keane, R. E.; Caratti, J. F.; Key, C. H.; Benson, N. C.; Sutherland, S.; Gangi, L. J. (2006): *FIREMON: fire effects monitoring and inventory system*. Fort Collins, U.S. Department of Agriculture, Forest Service, Rocky Mountain Research Station. 1 CD.
- Mallinis, G.; Mitsopoulos, I.; Chrysafi, I. (2018): “Evaluating and comparing Sentinel 2A and Landsat-8 Operational Land Imager (OLI) spectral indices for estimating fire severity in a Mediterranean pine ecosystem of Greece”, *GIScience Remote Sensing*, 55(1), pp. 1-18. Disponible en <https://doi.org/10.1080/15481603.2017.1354803>

- Miller, C. W.; Harvey, B. J.; Kane, V. R.; Moskal, L. M.; Alvarado, E. (2023): “Different approaches make comparing studies of burn severity challenging: a review of methods used to link remotely sensed data with the Composite Burn Index”, *International Journal of Wildland Fire*, 32(4), pp. 449-475. Disponible en <https://doi.org/10.1071/WF22050>
- Miller, J. D.; Thode, A. E. (2007): “Quantifying burn severity in a heterogeneous landscape with a relative version of the delta Normalized Burn Ratio (dNBR)”, *Remote Sensing of Environment*, 109(1), pp. 66-80. Disponible en <https://doi.org/10.1016/j.rse.2006.12.006>
- Ministerio para la Transición Ecológica y el Reto Demográfico (MITECO) (2021): *Guía resumida del Grupo de Trabajo I del IPCC: Bases físicas del cambio climático*. [Consulta: 12-12-2024]. Disponible en https://www.miteco.gob.es/content/dam/miteco/es/ceneam/recursos/mini-portales-tematicos/ipcc-guia-resumida-gt1-bases-fisicas-ar6_tcm30-533081.pdf
- Ministerio para la Transición Ecológica y el Reto Demográfico (MITECO) (2022): *Los Incendios Forestales en España. 1 enero – 31 diciembre 2022. Avance informativo*. Madrid, MITECO. [Consulta: 26-12-2024] Disponible en: https://www.miteco.gob.es/content/dam/miteco/es/biodiversidad/temas/incendios-forestales/avance_1_enero_31_diciembre_2022_tcm30-560521.pdf
- Morgan, P.; Keane, R. E.; Dillon, G. K.; Jain, T. B.; Hudak, A. T.; Karau, E. C.; Sikkink, P. G.; Holden, Z. A.; Stran, E. K. (2014). “Challenges of assessing fire and burn severity using field measures, remote sensing and modelling,” *International Journal of Wildland Fire*, 23, 1045-1060. <http://dx.doi.org/10.1071/WF13058>
- MTBS (2018): *Project overview*. [Consultado el: 31-12-2024]. Disponible en: <https://www.mtbs.gov/project-overview>
- Parks, S. A.; Dillon, G. K., ; Miller, C. (2014): “A new metric for quantifying burn severity: The relativized burn ratio”, *Remote Sensing*, 6(3), pp. 1827-1844. [Consulta: 15-12-2024]. Disponible en <https://doi.org/10.3390/rs6031827>
- Pérez-Cabello, F.; Montorio, R.; Borini Alves, D. (2021): “Remote sensing techniques to assess post-fire vegetation recovery”, *Current Opinion in Environmental Science Health*, 21, 100251. Disponible en: <https://doi.org/10.1016/j.coesh.2021.100251>.
- Röder, A.; Yang, Z.; Li, Z.; Cohn, M. (2021): “Random Forest classification of forest cover type from Landsat imagery: Effects of the number of samples, classes, and class imbalances”, *Journal of Insect Science*, 47, 1, pp. 31-42. Disponible en <https://doi.org/10.17849/insm-47-01-31-39.1>
- Saberi, S. J.; Harvey, B. J. (2023): “What Is the Color When Black Is Burned? Quantifying (Re)Burn Severity Using Field and Satellite Remote Sensing Indices”, *Fire Ecology*, 19, 24. Disponible en: <https://doi.org/10.1186/s42408-023-00178-3>.
- Saulino, L.; Rita, A.; Migliozi, A.; Maffei, C.; Allevato, E.; Garonna, A. P.; Saracino, A. (2020): “Detecting burn severity across Mediterranean forest types by coupling medium-spatial resolution satellite imagery and field data,” *Remote Sensing*, 12(4), 741. <https://doi.org/10.3390/rs12040741>
- Scikit-Learn (2023): *RandomForestRegressor — Scikit-Learn Documentation*. [Consulta: 10-11-2024]. Disponible en https://scikit-learn.org/dev/modules/generated/sklearn.ensemble.RandomForestRegressor.html#sklearn.ensemble.RandomForestRegressor.feature_importances_
- Shalev-Shwartz, S.; Ben-David, S. (2014): *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press. <https://doi.org/10.1017/CBO9781107298019>

Song, X.-P.; Hansen, M. C.; Stehman, S. V.; Potapov, P. V.; Tyukavina, A.; Vermote, E. F. (2021): “Global 30 m Landsat tree cover dynamics from 2000 to 2017: The global forest cover change dataset”, *Remote Sensing*, 13(12), 2311. Disponible en <https://doi.org/10.3390/rs13122311>

Urbietta, I. R.; Moreno, J. M.; Bedia, J.; Gutiérrez, J.; Vallejo, R. (2015): “Los incendios forestales en España ante el cambio climático”, en Herrero, A., Zavala, M. A. (Eds.): *Los bosques y la biodiversidad frente al cambio climático: impactos, vulnerabilidad y adaptación en España*. Ministerio de Agricultura, Alimentación y Medio Ambiente, pp. 395-405. Disponible en <https://www.researchgate.net/publication/294860577>

Veraverbeke, S.; Hook, S. J.; Harris, S. (2012): “An alternative spectral index for rapid fire severity assessments”, *Remote Sensing of Environment*, 123, pp. 72-80. Disponible en <https://doi.org/10.1016/j.rse.2012.02.025>

Eidenshink, J.; Schwind, B.; Brewer, K.; Zhu, Z. L.; Quayle, B.; Howard, S. (2007): “A project for monitoring trends in burn severity”, *Fire Ecology*, 3, pp. 3-21. <https://doi.org/10.4996/fireecology.0301003>

Anexo I

Tabla 1 Anexo I. Correlación entre el índice CBI y las variables de cada estrato.

Estrato A		Estrato B		Estrato C		Estrato D		Estrato E	
Variable	Importancia	Variable	Importancia	Variable	Importancia	Variable	Importancia	Variable	Importancia
Puntuación A	0.348151	Puntuación B	0.109119	Puntuación C	0.175155	Puntuación D	0.364028	Puntuación E	0.003547
Materia orgánica	0.273515	Frecuencia de individuos vivos	0.023599	% hojas negras/marrones	0.039886	% hojas negras/marrones	0.142273	Frecuencia de individuos vivos	0.000269
Suelo/Roca /substrato	0.081852	% hojas negras/marrones	0.018630	Frecuencia de individuos vivos	0.051039	% cambio de ramas de 1° y 2° orden	0.122412	% hojas negras/marrones	0.000195
Hojarasca /combustible fino	0.047651	Rebrotes	0.011484	Cambio de LAI	0.020179	Cambio de LAI	0.072139	Altura de quemado	0.000080
Combustible medio/pesado	0.032463			% cambio de ramas de 1° y 2° orden	0.009186	Frecuencia de individuos vivos	0.037321	% de verde no alterado	0.000048
						% de verde no alterado	0.010067	% cambio de ramas de 1° y 2° orden	0.000036
						Altura de quemado	0.005665	Cambio de LAI	0.000010

Fuente: Elaboración propia. Donde: Estrato A = Substrato; Estrato B = Hierbas, arbustos bajos y árboles menores a 1 m; Estrato C = Arbustos altos y árboles entre 1 y 5 m; Estrato D = Árboles intermedios de 5 a 20 m; Estrato E = Árboles altos mayores a 20 m.

Las puntuaciones de cada estrato indican el peso total de dicho estrato sobre el índice, quedando desglosados en las variables de cada estrato.

Tabla 2 Anexo I. Correlación entre el índice CBI y las variables de cada estrato.

Estrato A		Estrato B		Estrato C		Estrato D		Estrato E	
Variable	Importancia	Variable	Importancia	Variable	Importancia	Variable	Importancia	Variable	Importancia
Estrato A	0.04308	Estrato B	0.033436	Estrato C	0.422439	Estrato D	0.506318	Estrato E	0.010215
Suelo/Roca/substrato	0.019759	Frecuencia de individuos vivos	0.016130	% cambio de ramas de 1° y 2° orden	0.368732	Altura de quemado	0.409817	Altura de quemado	0.002952
Combustible medio/pesado	0.013489	FCOV	0.008957	FCOV	0.026306	% cambio de ramas de 1° y 2° orden	0.030727	FCOV	0.002221
Materia orgánica	0.006313	Rebrotes	0.007907	Frecuencia de individuos vivos	0.018724	% hojas negras/marrones	0.017926	% de verde no alterado	0.002015
Hojarasca/combustible fino	0.003519	% hojas negras/marrones	0.000442	% hojas negras/marrones	0.006538	FCOV	0.016071	% hojas negras/marrones	0.001530
				Cambio de LAI	0.002139	Cambio de LAI	0.011166	Frecuencia de individuos vivos	0.001270
						% de verde no alterado	0.003788	Cambio de LAI	0.000227
						Frecuencia de individuos vivos	0.001336	% cambio de ramas de 1° y 2° orden	0.000000

Fuente: Elaboración propia. Donde: Estrato A = Substrato; Estrato B = Hierbas, arbustos bajos y árboles menores a 1 m; Estrato C = Arbustos altos y árboles entre 1 y 5 m; Estrato D = Árboles intermedios de 5 a 20 m; Estrato E = Árboles altos mayores a 20 m.

Las puntuaciones de cada estrato indican el peso total de dicho estrato sobre el índice, quedando desglosados en las variables de cada estrato.